

LAPORAN PENELITIAN



**ANALISIS PERBANDINGAN MODEL MACHINE LEARNING DAN DEEP LEARNING UNTUK
KLASIFIKASI TANAMAN OBAT BERBASIS DATA CITRA DAN MULTIMODAL**

Oleh:

Rr. Dewi Handayani Untari Ningsih, M.Kom.	0616036902/6002493 [Ketua]
Dr. Drs. Eri Zuliarso, M.Kom.	0623116801/6120053 [Anggota 1]
Agus Prasetyo Utomo, S.Kom., M.Kom., M.M	0614087201/5998986 [Anggota 2]
Felix Andreas Sutanto, S.Kom., M.Cs	0625047801/5999970 [Anggota 3]
Hari Murti, S.Kom., M.Cs.	0611066501/6653979 [Anggota 4]
Reza Tanjung Setiawan	24.01.53.3001 [Anggota 5]
Sekar Ayu Ningtyas	25.01.55.7007 [Anggota 6]

**FAKULTAS TEKNOLOGI INFORMASI DAN INDUSTRI
UNIVERSITAS STIKUBANK (UNISBANK) S E M A R A N G
JULI – 2026**

HALAMAN PENGESAHAN LAPORAN PENELITIAN

1. Judul Penelitian : **ANALISIS PERBANDINGAN MODEL MACHINE LEARNING DAN DEEP LEARNING UNTUK KLASIFIKASI TANAMAN OBAT BERBASIS DATA CITRA DAN MULTIMODAL**
2. Jenis Penelitian : Penelitian Terapan
3. a. Bidang Penelitian : Engineering dan Technology
b. Kelompok : [2.18]
4. a. Tujuan Sosial Ekonomi : Information and Communication Services
b. Kelompok : 10.01 Computer Software and Services
5. Ketua Tim Pengusul :
 - Nama : Dewi Handayani Untari Ningsih, S.Kom., M.Kom.
 - NIY/NIDN/ID Sinta : YS.2.98.03.007/061603692/ 6002493
 - Jabatan Fungsional : Lektor Kepala
 - Pangkat/ Golongan : Pembina / IV A
 - Program Studi/ Fakultas : Teknik Informatika / Teknologi Informasi & Industri
 - Perguruan Tinggi : Universitas Stikubank
 - Bidang Keahlian : Informatika
 - Alamat Kantor/ Telp/Fax/Email : Jl. Tri Lomba Juang No.1 Mugasari Semarang/024-8411668/
tuniv@unisbank.ac.id
 - Alamat Rumah/Telp./Email : Jl. Borobudur Raya V. No.23 RT.10/RW.11 Kel.Kembangarum
Kec.Semarang Barat Semarang 50148/ +62 896-9925-7113/
dewi_h@edu.unisbank.ac.id
6. Jumlah Anggota Pelaksana 6
 - 1) Nama Anggota 1 : Dr. Eri Zuliarso, M.Kom.
Bidang Keahlian : Ilmu Komputer
 - 2) Nama Anggota 2 : Agus Prasetyo Utomo, S.Kom., M.Kom., M.M.
Bidang Keahlian : Sistem Informasi
 - 3) Nama Anggota 3 : Felix Andreas Sutanto, S.Kom., M.Cs.
Bidang Keahlian : Teknik Informatika
 - 4) Nama Anggota 4 : Hari Murti, S.Kom., M.Cs.
Bidang Keahlian : Sistem Informasi
 - 5) Nama Anggota 5 : Reza Tanjung Setiawan
Bidang Keahlian : Teknik Informatika
 - 6) Nama Anggota 6 : Sekar Ayu Ningtyas
Bidang Keahlian : Sistem Informasi
7. Lokasi Penelitian : Kota Semarang
8. Jangka Waktu Penelitian : 20 April 2026 s.d 30 November 2026 (8 bulan)
9. Luaran yang dihasilkan : a. Jurnal Penelitian Sinta 4

Semarang, 10 Juli 2026

Mengetahui,

Dekan Fakultas Teknologi Informasi & Industri



STIKUBANK
DIGITAL YOUTH ENTREPRENEURIAL UNIVERSITY

FAKULTAS TEKNOLOGI INFORMASI DAN INDUSTRI

Dr. Drs. Eri Zuliarso, M.Kom.

NIK/NIDN.YS.2.93.01.092/0623116801

Ketua Tim Penelitian

Dewi Handayani Untari Ningsih R.S, M.Kom.

NIDN/ID_Sinta. 0616036902/ 6002493

Mengetahui,

Direktur (DPPMP)



UNIVERSITAS STIKUBANK
DIGITAL YOUTH ENTREPRENEURIAL UNIVERSITY

DIREKTORAT PENELITIAN, PENGABDIAN MASYARAKAT DAN KEMAHIRAN

Prof. Dr. Endang Tjahjaningsih, S.E., M.Kom

NIK/NIDN.Y.2.91.10.065/0622056601

KATA PENGANTAR

Puji syukur kami panjatkan kepada Allah SWT yang telah melimpahkan Rahmat, Hidayah dan Karunia-Nya, sehingga penelitian yang berjudul "**Analisis Perbandingan Model Machine Learning Dan Deep Learning Untuk Klasifikasi Tanaman Obat Berbasis Data Citra Dan Multimodal**" dapat diselesaikan dengan baik.

Penelitian ini bertujuan mengkaji efektivitas model komputasi dalam mengenali varietas tanaman obat secara akurat dengan mengintegrasikan data visual, atribut botani, dan konteks lingkungan. Diharapkan, hasil kajian ini dapat memberikan kontribusi ilmiah yang signifikan bagi perkembangan ilmu komputer, pelestarian biodiversitas, serta menjadi fondasi kuat untuk pengembangan sistem klasifikasi hayati berbasis AI di masa depan. Terima kasih kepada seluruh pihak yang telah mendukung terwujudnya karya ini..

Penelitian ini tidak akan terwujud tanpa bimbingan, dukungan, dan kerja sama dari berbagai pihak. Oleh karena itu, kami menyampaikan penghargaan dan terima kasih yang sebesar-besarnya kepada semua pihak yang telah berkontribusi. Melalui kesempatan ini, tim peneliti Unisbank menyampaikan ucapan terima kasih kepada:

1. **Dr. Endang Tjahjaningsih, S.E., M.Com.**, selaku Direktur Direktorat Penelitian, Pengabdian Masyarakat, dan Publikasi (DPPMP) Universitas Stikubank (Unisbank) Semarang.
2. **Dr. Drs. Eri Zuliarso, M.Kom.**, selaku Dekan Fakultas Teknologi Informasi dan Industri Universitas Stikubank (Unisbank) Semarang.
3. **Tim Penelitian, Rekan-rekan dosen** di lingkungan Fakultas Teknologi Informasi dan Industri, serta **mahasiswa** yang terlibat dalam penelitian ini.
4. Semua pihak yang telah membantu dalam menyelesaikan penelitian ini, yang tidak dapat kami sebutkan satu per satu.

Kami menyadari bahwa penelitian ini masih memiliki kekurangan. Oleh karena itu, kritik dan saran yang membangun sangat kami harapkan untuk menyempurnakan penelitian ini di masa mendatang. Semoga hasil penelitian ini dapat memberikan kontribusi yang bermanfaat bagi pengembangan teknologi dalam industri kreatif batik serta menjadi referensi yang berguna bagi penelitian selanjutnya.

Demikian, semoga karya ini dapat memberikan manfaat bagi kita semua dan menjadi inspirasi bagi pengembangan teknologi informasi, terutama di disiplin ilmu Kecerdasan Buatan, Data Science, Tata Kelola Teknologi Informasi, dan Rekayasa Perangkat Lunak di masa depan.

Semarang, Juli 2026

TIM Peneliti

DAFTAR ISI

Halaman Cover	i
Halaman Pengesahan	ii
Kata Pengantar	iii
Daftar Isi	iv
Daftar Gambar dan Tabel	
Ringkasan	vii

BAB I PENDAHULUAN

- 1.1 Latar Belakang
- 1.2 Identifikasi Masalah
- 1.3 Batasan Masalah
- 1.4 Proses Bisnis Penelitian

BAB II TINJAUAN PUSTAKA

- 2.1 Klasifikasi Tanaman Obat Indonesia.
- 2.2 Data Citra dalam Klasifikasi Tanaman
- 2.3 Multimodal Data pada Tanaman Obat
- 2.4 Deep learning untuk Deteksi Tanaman Obat
- 2.5 Machine Learning: RandomForest dan SVM
- 2.6 Convolutional Neural Network (CNN)
- 2.7 Feature Concatenation dalam Multimodal Learning
- 2.8 Adaptive Feature Fusion (*State-of-the-Art*)
- 2.9 State of the Art dan Research Gap
 - 2.9.1 State of the Art
 - 2.9.2 Research Gap
 - 2.9.3 Tabel Penguatan Referensi State of the Art
- 2.10 Roadmap Penelitian

BAB III TUJUAN DAN MANFAAT PENELITIAN

- 3.1 Tujuan Penelitian
- 3.2 Tujuan Umum
- 3.3 Tujuan Khusus
- 3.4 Manfaat Penelitian
 - 3.4.1 Manfaat Teoritis
 - 3.4.2 Manfaat Metodologis
 - 3.4.3 Manfaat Praktis
 - 3.4.4 Manfaat bagi Pengembangan Dataset Tanaman Obat Indonesia
 - 3.4.5 Manfaat Institusional
 - 3.4.6 Manfaat bagi Penelitian Lanjutan
- 3.5 Indikator Keberhasilan Tujuan dan Manfaat Penelitian

BAB IV METODE PENELITIAN

- 4.1 Desain Penelitian
- 4.2 Rumusan Eksperimen
- 4.3 Hipotesis Penelitian
- 4.4 Dataset dan Preprocessing Penelitian
 - 4.4.1 Sumber Data

- 4.4.2 Augmentasi
- 4.5 Pembagian Data (Data Splitting)
- 4.6 Ekstraksi Fitur Menggunakan CNN
 - 4.6.1 Konsep Transfer Learning
 - 4.6.2 Arsitektur CNN yang Digunakan
- 4.7 Reduksi Dimensi dengan PCA
- 4.8 Model Machine Learning
 - 4.8.1 Support Vector Machine (SVM)
 - 4.8.2 SVM dengan Kernel RBF
 - 4.8.3 Random Forest
 - 4.8.4 K-Nearest Neighbors (KNN)
- 4.9 Framework Perbandingan Model
 - 4.9.1 Matriks Perbandingan Model
 - 4.9.2 Variabel Penelitian
 - 4.9.2.1 Variabel Independen
 - 4.9.2.2 Variabel Dependen
 - 4.9.2.3 Variabel Kontrol
- 4.10 Alur eksperimen
- 4.11 Metrik Evaluasi
 - 4.11.1 Akurasi
 - 4.11.2 Precision
 - 4.11.3 Recall
- 4.12 Stratified Cross Validation
- 4.13 Kriteria Keberhasilan Model

BAB V HASIL DAN PEMBAHASAN

- 5.1 Analisis Perbandingan Model Machine learning Dan Deep learning - Klasifikasi Tanaman Obat
- 5.2 Desain Penelitian
 - 5.2.1 Arsitektur Pipeline
 - 5.2.2 Dataset
 - 5.2.3 Jenis Augmentasi Data
- 5.3 Akstraksi Fitur CNN
 - 5.3.1 Arsitektur CNN yang digunakan
 - 5.3.2 Proses Ekstraksi Fitur
 - 5.3.3 Visualisasi Feature Space (t-SNE)
- 5.4 Model Machine Learning
 - 5.4.1 Model yang Diuji
 - 5.4.2 Hasil Evaluasi Lengkap
- 5.5. Analisis dan Pembahasan
 - 5.5.1 Perbandingan CNN Backbone
 - 5.5.2 Analisis Confusion Matrix Model
 - 5.5.3 Perbandingan Model Machine Learning
 - 5.5.4 Faktor yang Mempengaruhi Performa

BAB 6 KESIMPULAN DAN SARAN

- 6.1 Kesimpulan
- 6.2 Saran
 - 6.2.1 Saran untuk Riset Berkelanjutan
 - 6.2.2 Rekomendasi Akhir

DAFTAR PUSTAKA

LAMPIRAN

DAFTAR GAMBAR DAN TABEL

Daftar Gambar

Gambar 1	:	Dataset 17 kelas Tanaman Berkhasiat Obat dengan 1507 citra beserta Informasi MetadataTerkait
Gambar 2	:	Perbandingan Model Klasifikasi
Gambar 3	:	Tahapan Proses Penelitian
Gambar 4	:	Road Map Penelitian Klasifikasi Tanaman Obat
Gambar 5	:	Dataset dari 17 kelas tanaman obat dengan 2.940 citra asli dan 5100 citra hasil Augmentasi
Gambar 6	:	Proses Augmentasi Citra
Gambar 7	:	Pipeline ekstraksi fitur
Gambar 8	:	Model VGG16 + Decision Tree
Gambar 9	:	Model VGG16 + Gradient Boosting
Gambar 10	:	Model VGG16 + KNN
Gambar 11	:	Model VGG16 + Random Forest
Gambar 12	:	Model VGG16 + SVM Linear
Gambar 13	:	Model VGG16 + SVM RBF

Daftar Tabel

Tabel 1	:	Penguatan referensi dan relevansi terhadap Penelitian
Tabel 2	:	Indikator Keberhasilan Riset
Tabel 3	:	Hipotesis Penelitian
Tabel 4	:	Teknik Augmentasi data citra yang digunakan
Tabel 5	:	Pembagian Data
Tabel 6	:	Transfer Learning
Tabel 7	:	Perbandingan Arsitektur CNN
Tabel 8	:	Parameter CNN dan perbandingan ketiga arsitektur CNN.
Tabel 9	:	Perbandingan Tiga Arsitektur CNN berdasarkan Output
Tabel 10	:	Parameter Model SVM
Tabel 11	:	Parameter Model Random Forest
Tabel 12	:	Parameter Model KNN
Tabel 13	:	Matrik perbandingan untuk Algoritm Machine Learning yang diuji berdasarkan CNN Backbone
Tabel 14	:	Tahapan eksperimen dari Penelitian yang dilakukan
Tabel 15	:	Hasil Pengujian Hipotesis
Tabel 16	:	Hasil Utama Perbandingan Model CNN dan Machine Learning
Tabel 17	:	Deskripsi Dataset
Tabel 18	:	Jenis Augmentasi Data
Tabel 19	:	Arsitektur CNN yang Digunakan
Tabel 20	:	Tahapan Proses Ekstraksi data
Tabel 21	:	Pengujian Machine Learning
Tabel 22	:	Perbandingan Rata-Rata Akurasi CNN Backbone

RINGKASAN

Penelitian ini menganalisis perbandingan performa model *Machine Learning* dan *Deep Learning* untuk klasifikasi tanaman obat Indonesia berbasis data citra. Dataset terdiri atas 17 kelas tanaman obat dengan total 2.940 citra asli yang ditingkatkan menjadi 5.100 citra melalui proses augmentasi. Metode yang digunakan menggabungkan pendekatan *transfer learning* dan klasifikasi *Machine Learning*. Tiga arsitektur CNN pre-trained, yaitu VGG16, ResNet50, dan MobileNetV2, digunakan sebagai ekstraktor fitur tanpa *top layer*. Fitur citra yang dihasilkan kemudian direduksi menggunakan *Principal Component Analysis* menjadi 128 komponen dan distandarisasi sebelum diklasifikasikan menggunakan SVM Linear, SVM RBF, Random Forest, dan K-Nearest Neighbors. Evaluasi dilakukan melalui skenario benchmarking terhadap 12 kombinasi model dengan metrik accuracy, precision, recall, dan F1-score. Hasil eksperimen menunjukkan bahwa kombinasi **ResNet50 + SVM Linear** menghasilkan performa terbaik dengan akurasi **99,31%** dan F1-score **0,9931**. Secara rata-rata, **ResNet50** menjadi backbone CNN paling efektif dengan akurasi **97,52%**, diikuti MobileNetV2 sebesar **96,60%** dan VGG16 sebesar **94,29%**. Pada sisi classifier, **SVM Linear** memperoleh rata-rata akurasi tertinggi sebesar **98,66%**, diikuti SVM RBF sebesar **98,43%**, Random Forest sebesar **96,44%**, dan KNN sebesar **91,01%**. Temuan ini menunjukkan bahwa kombinasi CNN sebagai ekstraktor fitur dan SVM sebagai classifier mampu menghasilkan baseline klasifikasi tanaman obat yang sangat kuat. Hasil ini dapat dijadikan baseline awal untuk pengembangan klasifikasi tanaman obat berbasis multimodal pada penelitian lanjutan, terutama melalui integrasi atribut tabular dan geospasial.

Kata kunci: *klasifikasi tanaman obat, CNN feature extraction, transfer learning, ResNet50, Support Vector Machine, benchmarking model*

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan AI melalui *Machine* dan *Deep Learning* mendorong klasifikasi otomatis objek biologis. Ini sangat relevan untuk identifikasi tanaman obat berbasis citra guna pelestarian biodiversitas (Hajam et al., 2024; Holzinger et al., 2023). Pendekatan komputasional ini menjadi solusi atas keterbatasan identifikasi manual yang subjektif, bergantung pada keahlian pakar, dan sulit diterapkan pada data skala besar.

Pemanfaatan teknologi AI, khususnya *Machine Learning* dan *Deep Learning*, meningkatkan signifikan pada klasifikasi berbasis citra tanaman obat (Gupta & Singh, 2024),(Mulugeta et al., 2024a) . Pendekatan *Deep Learning*, terutama CNN, efektif mengekstraksi fitur visual—seperti bentuk, warna, tekstur, dan morfologi—secara otomatis dengan performa lebih tinggi dari model klasik. Kemampuan CNN mempelajari representasi visual hierarkis menjadikannya arsitektur utama yang sangat efektif untuk pengenalan pola data citra (J. Wang et al., 2021)

Pendekatan unimodal berbasis citra (CNN) kurang mampu merepresentasikan kompleksitas tanaman obat karena kemiripan visual daun. Pendekatan ini belum mengintegrasikan data heterogen penting seperti atribut tabular dan geospasial tempat tumbuh (Alfred et al., 2025; Yin et al., 2025).


Pendekatan multimodal menjadi relevan karena mampu menggabungkan beberapa sumber data yang berbeda untuk membentuk representasi fitur yang lebih kaya (Stahlschmidt et al., 2022a). Dalam konteks klasifikasi tanaman obat, data citra dapat merepresentasikan karakteristik visual tanaman, data tabular dapat menjelaskan atribut botani seperti bentuk daun, warna daun, tekstur daun, ukuran daun, habitat, dan manfaat utama, sedangkan data geospasial dapat menjelaskan konteks lingkungan seperti latitude, longitude, elevasi, suhu, kelembaban, dan curah hujan (Azadnia et al., 2024; Mulugeta et al., 2024b; Puttinaovarat & Horkaew, 2021a; Stahlschmidt et al., 2022a). Proposal penelitian ini merancang dataset yang terdiri atas sekitar 1.200 lebih citra tanaman obat dari 15 kelas, dilengkapi dengan metadata yang mendukung informasi tentang citra yang ada dan fitur geospasial . Secara teoretis, integrasi sumber data tersebut dapat membantu model mengenali tanaman obat secara lebih komprehensif dibandingkan hanya menggunakan citra.


Kajian multimodal learning menunjukkan bahwa penggabungan berbagai modality dapat meningkatkan performa model karena setiap sumber data membawa informasi yang saling melengkapi. Gao et al. (2020) menjelaskan bahwa *multimodal data fusion* memungkinkan model menangkap hubungan antar sumber data yang tidak dapat diperoleh dari satu modality saja. Xu et

al. (2023) juga menegaskan bahwa *multimodal learning* berkembang sebagai pendekatan penting dalam pembelajaran mesin modern karena mampu menggabungkan informasi visual, tekstual, numerik, maupun kontekstual. Dalam proposal, integrasi multimodal melalui *feature concatenation* menunjukkan peningkatan akurasi dari 91,3% pada CNN menjadi 94,6%, peningkatan F1-score sebesar 5,2%, dan penurunan error rate sebesar 6,8%. Data awal ini menunjukkan bahwa multimodal learning memiliki potensi kuat untuk memperbaiki performa klasifikasi tanaman obat.

Secara global, model *Deep Learning* berbasis *Convolutional Neural Network* (CNN) mampu mencapai akurasi di atas 90% dalam klasifikasi citra tanaman (Huixian, 2020; Lu et al., 2021). Namun, sebagian besar penelitian masih menggunakan pendekatan unimodal, yaitu hanya berbasis citra, sehingga belum mampu merepresentasikan kompleksitas data tanaman obat yang bersifat heterogeny (Lipkova et al., 2022; Patil & Kumar, 2022).

Dalam konteks penelitian ini, dataset yang digunakan terdiri lebih dari 1.500 citra tanaman obat dari 17 kelas, dilengkapi dengan 5 atribut data tabular serta informasi geospasial (gambar 1). Studi awal menunjukkan bahwa model *Machine Learning* seperti *Random Forest* dan *Support Vector Machine* menghasilkan akurasi masing-masing sebesar 84–85% dan 82–83% (Nhu et al., 2020; Pacheco et al., 2021), sedangkan model CNN mampu mencapai lebih dari 91% (Alzubaidi et al., 2021a). Ketika dilakukan integrasi data multimodal menggunakan *feature concatenation* (Vieira et al., 2020a), akurasi meningkat hingga sekitar 94–95%, dengan peningkatan F1-score sebesar $\pm 5\%$ dan penurunan error sebesar $\pm 6\text{--}7\%$.






Gambar 1. Dataset 17 kelas Tanaman Berkhasiat Obat dengan 1507 citra beserta Informasi Metadata Terkait.

Selain persoalan integrasi data, penelitian klasifikasi tanaman obat juga masih memerlukan *benchmarking* yang lebih sistematis antara model *Machine Learning* dan *Deep Learning* (Malik et al., 2022a; Mulugeta et al., 2024c; Puttinaovarat & Horkaew, 2021b). *Benchmarking* dalam konteks penelitian ini dipahami sebagai proses evaluasi komparatif yang dilakukan dengan dataset, skenario eksperimen, dan metrik evaluasi yang sama untuk mengetahui performa setiap model secara adil. Tanpa *benchmarking*, klaim bahwa suatu model lebih unggul hanya akan menjadi pernyataan performatif yang lemah secara metodologis. Penelitian dilakukan untuk menunjukkan model perbandingan antara *Random Forest*, *Support Vector Machine*, dan CNN, sedangkan evaluasi dilakukan menggunakan akurasi, F1-score, dan error rate .

Random Forest relevan digunakan karena memiliki kemampuan menangani data non-linear dan cukup stabil terhadap risiko *overfitting*. (Genuer & Poggi, 2020c) menjelaskan bahwa *Random Forest* merupakan metode *ensemble learning* yang kuat untuk klasifikasi dan regresi. *Support Vector Machine* (SVM) relevan karena efektif dalam ruang fitur berdimensi tinggi dan banyak digunakan dalam berbagai kasus klasifikasi, sebagaimana dijelaskan oleh (Shmilovici, 2023) dan (Pisner & Schnyer, 2020a). Sementara itu, CNN relevan sebagai model *Deep Learning* untuk ekstraksi fitur citra secara otomatis. Perbandingan ketiga model tersebut penting karena masing-masing memiliki karakteristik berbeda: Random Forest dan SVM lebih kuat pada data tabular atau fitur hasil ekstraksi, sedangkan CNN lebih unggul pada pengolahan citra (gambar 2).

Perbandingan Model Klasifikasi: Random Forest, SVM, dan CNN

Ilustrasi singkat untuk memperjelas karakteristik dan relevansi tiap model



Gambar 2. Perbandingan Model Klasifikasi

Penelitian ini sangat layak karena didukung dataset memadai, infrastruktur komputasi, dan kompetensi tim di bidang *data science*. Fokus riset tetap pada rumpun *Computer Science* melalui metode komputasi data multimodal untuk dasar ilmiah pengembangan *adaptive multimodal fusion* lanjutan.

1.2 Identifikasi Masalah

Masalah utama penelitian ini adalah keterbatasan klasifikasi tanaman obat akibat ketergantungan pada data citra tunggal dan metode integrasi multimodal yang statis. Selain itu, minimnya *benchmarking* sistematis memerlukan analisis perbandingan terkontrol antara *Random Forest*, *SVM*, dan *CNN*.

1.3 Batasan Masalah

Penelitian ini dibatasi pada klasifikasi tanaman obat berbasis data citra dan multimodal. Data multimodal yang digunakan mencakup data citra tanaman, atribut tabular, dan data geospasial. Penelitian tidak membahas analisis senyawa kimia, uji farmakologis, uji klinis, atau validasi khasiat medis tanaman obat.

Model yang dibandingkan dibatasi pada *Random Forest*, *Support Vector Machine*, dan *Convolutional Neural Network*. *Random Forest* dan *SVM* digunakan sebagai representasi model

Machine Learning klasik, sedangkan CNN digunakan sebagai representasi model *Deep Learning* berbasis citra. Metode integrasi multimodal yang digunakan pada tahap ini adalah *feature concatenation* sebagai baseline fusion.

Evaluasi model dibatasi pada metrik performa klasifikasi, seperti *accuracy*, *precision*, *recall*, *F1-score*, *error rate*, dan *confusion matrix*. Dataset penelitian terdiri atas 17 kelas tanaman obat dengan total 5.100 citra setelah augmentasi, disertai rencana pengayaan atribut tabular dan geospasial untuk skenario multimodal.. Fokus penelitian tetap berada pada aspek komputasional, yaitu pengolahan data, ekstraksi fitur, pemodelan klasifikasi, integrasi multimodal, dan *benchmarking* performa model.

1.4 Proses Bisnis Penelitian

Proses bisnis penelitian ini menggambarkan alur kerja klasifikasi tanaman obat mulai dari pengumpulan data sampai analisis hasil model. Tahap awal dimulai dari pengumpulan data tanaman obat. Data yang digunakan terdiri atas data citra, data tabular, dan data geospasial. Dataset dalam bentuk citra mencakup 17 kelas tanaman obat, seperti biji kembang Kantil, bunga Tapak Dara, bunga Telang, daun Insulin, daun Jambu, daun Kelor, daun Kemangi, daun Kenikir, daun Korokeling, daun Mimba, daun Pepaya, daun Salam, daun Sirih, daun Uni Jalar, Kejih Beling, Rumput Mutiara, dan Sirih Cina (tabel 1). Data tabular mencakup atribut tanaman seperti jenis tanaman, nama latin, manfaat utama ,gambar dan kadungan dalam metadata citra, digunakan sebagai objek klasifikasi citra. Setiap kelas direpresentasikan oleh citra tanaman dan dilengkapi informasi pendukung berupa nama latin, komposisi atau kandungan utama, serta manfaat utama tanaman. Informasi ini berfungsi sebagai atribut tabular pendukung dalam pengayaan dataset multimodal.

Tabel 1. Dataset Tanaman Obat dalam bentuk 17 kelas citra Metadata

No.	Nama Tanaman Obat	Nama Latin	Gambar	Komposisi/Kandungan Utama	Manfaat Utama
1	Biji Kembang Kantil	<i>Magnolia champaca</i>		Alkaloid, flavonoid, saponin, tanin, minyak atsiri	Membantu relaksasi, antioksidan, antiradang, dan mendukung kesehatan pernapasan secara tradisional

2	Bunga Tapak Dara	<i>Catharanthus roseus</i>		Alkaloid indol, vincristine, vinblastine, flavonoid, tanin	Secara tradisional digunakan untuk membantu pengelolaan gula darah; beberapa senyawanya dikenal dalam riset antikanker
3	Bunga Telang	<i>Clitoria ternatea</i>		Antosianin, flavonoid, polifenol, ternatin, saponin	Antioksidan, pewarna alami, mendukung kesehatan mata, dan membantu relaksasi
4	Daun Insulin	<i>Tithonia diversifolia</i>		Flavonoid, seskuiterpen lakton, alkaloid, tanin, saponin	Secara tradisional digunakan untuk membantu pengelolaan kadar gula darah dan antiradang
5	Daun Jambu	<i>Psidium guajava</i>		Flavonoid, quercetin, tanin, saponin, minyak atsiri	Membantu mengatasi diare, antioksidan, antimikroba, dan mendukung kesehatan pencernaan
6	Daun Kelor	<i>Moringa oleifera</i>		Flavonoid, vitamin C, vitamin A, kalsium, kalium, protein, isothiocyanate	Meningkatkan nutrisi, antioksidan, mendukung imunitas, dan membantu menjaga metabolisme tubuh
7	Daun Kemangi	<i>Ocimum basilicum</i> / <i>Ocimum tenuiflorum</i>		Eugenol, linalool, flavonoid, tanin, minyak atsiri	Antibakteri, antioksidan, membantu kesehatan pencernaan, dan mengurangi bau badan secara tradisional
8	Daun Kenikir	<i>Cosmos caudatus</i>		Flavonoid, polifenol, saponin, tanin, vitamin C	Antioksidan, membantu meningkatkan nafsu makan, mendukung kesehatan pencernaan, dan antiradang

9	Daun Korokeling/Kari	<i>Murraya koenigii</i>		Alkaloid karbazol, flavonoid, minyak atsiri, fenolik	Mendukung kesehatan pencernaan, antioksidan, antimikroba, dan digunakan sebagai tanaman aromatik
10	Daun Mimba	<i>Azadirachta indica</i>		Azadirachtin, nimbin, flavonoid, tanin, limonoid	Antimikroba, antiradang, membantu kesehatan kulit, dan digunakan sebagai pestisida nabati
11	Daun Pepaya Jepang	<i>Cnidioscolus aconitifolius</i>		Flavonoid, saponin, tanin, protein, mineral, vitamin	Sumber nutrisi, membantu menjaga daya tahan tubuh, dan mendukung kesehatan pencernaan
12	Daun Salam	<i>Syzygium polyanthum</i>		Flavonoid, tanin, minyak atsiri, eugenol, saponin	Membantu mengelola gula darah dan kolesterol secara tradisional, antioksidan, serta mendukung pencernaan
13	Daun Sirih	<i>Piper betle</i> L.		Eugenol, chavicol, kavikol, tanin, minyak atsiri, flavonoid	Antiseptik alami, antimikroba, membantu kesehatan mulut, dan perawatan luka ringan secara tradisional
14	Daun Ubi Jalar	<i>Ipomoea batatas</i>		Flavonoid, polifenol, beta-karoten, vitamin C, serat	Antioksidan, mendukung kesehatan mata, pencernaan, dan sumber nutrisi
15	Kejih Beling	<i>Strobilanthes crispata</i>		Flavonoid, kalium, silikat, tanin, saponin	Secara tradisional digunakan untuk membantu kesehatan saluran kemih dan mendukung peluruhan batu ginjal

16	Rumput Mutiara	<i>Oldenlandia corymbosa</i>		Flavonoid, iridoid, alkaloid, saponin, tanin	Antiradang, antipiretik, antioksidan, dan digunakan secara tradisional untuk membantu pemulihan tubuh
17	Sirih Cina	<i>Peperomia pellucida</i>		Flavonoid, alkaloid, tanin, saponin, steroid, minyak atsiri	Antiradang, membantu meredakan nyeri sendi ringan secara tradisional, antioksidan, dan mendukung kesehatan kulit

Tahap validasi dan *preprocessing* mencakup pembersihan data menyeluruh, standardisasi citra 224×224 piksel untuk CNN, serta augmentasi. Augmentasi bertujuan mencegah *overfitting* dan meningkatkan jumlah data lebih dari 1.500 menjadi lebih dari 5.000 citra potensial..

Tahap ketiga adalah ekstraksi fitur. Pada data citra, ekstraksi fitur dilakukan menggunakan CNN karena model ini mampu mempelajari fitur visual secara otomatis. Pada data tabular dan geospasial, fitur dibentuk melalui proses encoding, normalisasi, dan transformasi numerik. Hasil dari tahap ini adalah representasi fitur citra dan fitur non-citra yang siap digunakan sebagai input dalam proses pelatihan model.

Tahap keempat adalah pengembangan model klasifikasi (Random Forest, SVM, dan CNN) dengan skenario konsisten. Pembagian data latih, validasi, dan uji dilakukan berhati-hati untuk memastikan perbandingan adil dan mencegah bias.

Tahap kelima mengintegrasikan fitur citra, tabular, dan geospasial menggunakan *feature concatenation*. Pendekatan ini menjadi *baseline* untuk mengukur peningkatan performa model multimodal dibandingkan pendekatan unimodal.

Tahap keenam adalah *benchmarking* dan evaluasi model. Setiap model diuji menggunakan *metrik accuracy, precision, recall, F1-score, error rate*, dan *confusion matrix*. Evaluasi dilakukan untuk membandingkan performa *Random Forest*, SVM, CNN, dan model multimodal. Hasil evaluasi kemudian dianalisis untuk menentukan model yang paling efektif, mengidentifikasi kelemahan masing-masing pendekatan, dan menilai kontribusi data multimodal terhadap performa klasifikasi.

Tahap terakhir menganalisis hasil *benchmarking* (CNN, Random Forest, SVM) dan efektivitas integrasi multimodal. Evaluasi keterbatasan *feature concatenation* statis ini akan menjadi dasar pengembangan *adaptive feature fusion* pada penelitian lanjutan.

Urutan kegiatan penelitian ditunjukkan di gambar 3 dibawah ini:



Gambar 3. Tahapan Proses Penelitian

BAB III

TINJAUAN PUSTAKA

2.1 Klasifikasi Tanaman Obat Indonesia

Klasifikasi tanaman obat merupakan bagian penting dalam pemanfaatan sumber daya hayati untuk pengobatan tradisional dan modern. Pendekatan konvensional berbasis identifikasi manual memiliki keterbatasan dalam akurasi dan skalabilitas. Oleh karena itu, pendekatan berbasis *Artificial Intelligence* mulai banyak digunakan untuk meningkatkan efisiensi dan akurasi klasifikasi (Saleem et al., 2021; D. Wang et al., 2022).

Penelitian terbaru menunjukkan bahwa model berbasis *Deep Learning* mampu mencapai akurasi di atas 90% dalam klasifikasi tanaman berbasis citra. Namun, sebagian besar penelitian masih terbatas pada pendekatan unimodal dan belum memanfaatkan data multimodal secara optimal.

2.2 Data Citra dalam Klasifikasi Tanaman

Data citra menjadi komponen utama dalam klasifikasi tanaman karena memuat informasi visual seperti bentuk, tekstur, dan warna daun. Pendekatan tradisional menggunakan fitur manual seperti GLCM dan histogram warna, namun memiliki keterbatasan dalam menangkap kompleksitas pola (N. Ahmad et al., 2021; Kumar et al., 2020).

Seiring perkembangan teknologi, *Deep Learning* menggantikan pendekatan tersebut melalui *automatic feature extraction* menggunakan CNN yang terbukti lebih unggul dalam berbagai aplikasi *computer vision* (Basha et al., 2020; Yousfi et al., 2020).

2.3 Multimodal Data pada Tanaman Obat

Multimodal learning mengintegrasikan berbagai jenis data seperti citra, tabular, dan geospasial untuk menghasilkan representasi yang lebih kaya. Integrasi data multimodal dapat meningkatkan performa model secara signifikan karena mampu menangkap hubungan antar sumber data (Xu et al., 2023a). Namun, sebagian besar pendekatan masih menggunakan metode sederhana seperti *feature concatenation*, yang belum optimal dalam memodelkan interaksi antar modality.

2.4 Deep Learning untuk Deteksi Tanaman Obat

CNN merupakan metode utama dalam klasifikasi citra tanaman karena kemampuannya dalam mengekstraksi fitur secara hierarkis. Arsitektur seperti ResNet (Shafiq & Gu, 2022a) dan MobileNet (Dong et al., 2022; Rybczak & Kozakiewicz, 2024a) telah banyak digunakan untuk meningkatkan efisiensi dan akurasi model.

Studi terdahulu menunjukkan bahwa CNN mampu mencapai akurasi hingga 99% dalam klasifikasi penyakit tanaman, yang menunjukkan potensi besar penerapan *Deep Learning* dalam bidang pertanian dan tanaman obat (Chen et al., 2020; Fan et al., 2022).

2.5 Machine Learning: Random Forest dan SVM

Metode *Machine Learning* klasik tetap relevan dalam analisis data, terutama untuk data tabular.

- **Random Forest** (Genuer & Poggi, 2020a; Salman et al., 2024) merupakan metode *ensemble learning* yang efektif dalam mengurangi overfitting dan menangani data non-linear.
- **Support Vector Machine (SVM)** (Bansal et al., 2022a; Pisner & Schnyer, 2020b) (memiliki kemampuan klasifikasi yang baik pada data berdimensi tinggi).

Meskipun demikian, kedua metode ini memiliki keterbatasan dalam menangani data citra secara langsung tanpa ekstraksi fitur tambahan.

2.6 Convolutional Neural Network (CNN)

CNN merupakan arsitektur *Deep Learning* yang dirancang untuk pengolahan citra dan telah menjadi standar dalam berbagai aplikasi klasifikasi. CNN mampu mengekstraksi fitur secara otomatis dan menghasilkan performa yang lebih baik dibandingkan metode tradisional (Ikrar Musyaffa et al., 2024a; Malik et al., 2022b).

Namun, CNN memiliki keterbatasan dalam mengintegrasikan data non-citra, sehingga perlu dikombinasikan dengan pendekatan multimodal.

2.7 Feature Concatenation dalam Multimodal Learning

Feature concatenation adalah metode sederhana dalam menggabungkan fitur dari berbagai sumber data. Metode ini banyak digunakan sebagai baseline karena kemudahannya (Kurniawan, 2025; Putra et al., 2024a).

Namun, metode ini memiliki kelemahan:

- Tidak adaptif
- Tidak mempertimbangkan kontribusi masing-masing modality
- Kurang optimal dalam menangkap interaksi kompleks

2.8 Adaptive Feature Fusion (*State-of-the-Art*)

Pendekatan terbaru dalam *multimodal learning* adalah **adaptive feature fusion**, yang menggunakan mekanisme seperti attention untuk menggabungkan data secara dinamis (Gao et al., 2020; J. Wang et al., 2022a). *Gated multimodal fusion* mampu meningkatkan performa klasifikasi dibandingkan metode statis. Pendekatan ini memungkinkan model untuk menentukan bobot kontribusi masing-masing modality secara adaptif. Namun, penerapan metode ini dalam klasifikasi tanaman obat, khususnya berbasis dataset Indonesia, masih sangat terbatas.

2.9 State of the Art dan Research Gap

2.9.1 State of the Art

Perkembangan terkini dalam klasifikasi tanaman berbasis kecerdasan buatan menunjukkan bahwa pendekatan *Deep Learning*, khususnya *Convolutional Neural Network* atau CNN, menjadi metode dominan dalam pengolahan citra tanaman. CNN banyak digunakan karena mampu melakukan ekstraksi fitur visual secara otomatis melalui lapisan konvolusi, pooling, dan klasifikasi, sehingga tidak terlalu bergantung pada perancangan fitur manual seperti warna, tekstur, atau bentuk (Saleem et al., 2020; Tugrul et al., 2022). (Ashwinkumar et al., 2022) menjelaskan bahwa CNN telah banyak diterapkan dalam klasifikasi citra daun tanaman karena kemampuannya mengenali pola visual secara hierarkis. (Alzubaidi et al., 2021b) juga menegaskan bahwa CNN merupakan salah satu

arsitektur utama dalam *Deep Learning* yang efektif untuk pengenalan pola citra. (Liu et al., 2021; Sun et al., 2020). Dalam konteks tanaman obat, (Malik et al., 2022c; Muneer & Fati, 2020; Naeem et al., 2021) menunjukkan bahwa *Deep Learning* semakin banyak digunakan untuk klasifikasi dan pengenalan spesies tanaman obat.

Penelitian terbaru juga menunjukkan bahwa pendekatan *transfer learning* dan arsitektur CNN modern, seperti ResNet, MobileNet, EfficientNet, dan variasinya, banyak digunakan untuk meningkatkan akurasi klasifikasi tanaman (T. Ahmad et al., 2022; Hassan et al., 2021; Utami et al., 2025). (Shafiq & Gu, 2022b) membahas kekuatan *deep residual learning* dalam meningkatkan representasi fitur citra, sedangkan (Rybczak & Kozakiewicz, 2024b) menunjukkan bahwa model MobileNet, EfficientNet, dan Inception banyak digunakan karena efisiensi dan performanya dalam klasifikasi citra. Pada konteks tanaman obat Indonesia, (Ikrar Musyaffa et al., 2024b) melalui IndoHerb menunjukkan relevansi *transfer learning* dan *Deep Learning* untuk pengenalan tanaman obat Indonesia. (Putra et al., 2024b) juga memperkuat konteks lokal melalui klasifikasi daun herbal menggunakan *EfficientNetV2B0* (Govindaraj et al., 2025; Sonita et al., 2025). Referensi-referensi ini penting karena menunjukkan bahwa riset klasifikasi tanaman obat sudah bergerak dari fitur manual menuju model *Deep Learning* berbasis citra.

Meskipun CNN menunjukkan performa tinggi dalam klasifikasi citra, pendekatan berbasis citra tunggal masih memiliki keterbatasan. Tanaman obat tidak hanya dibedakan oleh karakteristik visual, tetapi juga oleh atribut botani, habitat, manfaat utama, serta kondisi lingkungan tempat tumbuh (Ikrar Musyaffa et al., 2024c). Dua tanaman dapat memiliki kemiripan warna, bentuk daun, atau tekstur, tetapi berbeda dari sisi habitat, ketinggian lokasi, kelembaban, atau karakteristik tabular lain. Oleh karena itu, *multimodal learning* menjadi pendekatan yang semakin relevan. *Multimodal data fusion* memungkinkan sistem pembelajaran mesin menggabungkan berbagai jenis data untuk memperoleh representasi yang lebih lengkap (Bayoudh et al., 2022a; Kline et al., 2022; Stahlschmidt et al., 2022b). (Bayoudh et al., 2022b; Jiao et al., 2024a; Nakach et al., 2024) juga menegaskan bahwa *multimodal learning* berkembang sebagai arah penting dalam AI modern karena mampu mengintegrasikan informasi visual, numerik, tekstual, dan kontekstual (Bayoudh et al., 2022c; Zhang et al., 2020a; Zhao et al., 2024a).

Dalam konteks penelitian ini, pendekatan multimodal digunakan untuk menggabungkan data citra tanaman obat, atribut tabular, dan informasi geospasial. Penelitian ini merancang dataset yang terdiri atas sekitar lebih dari 1.500 citra dari 17 kelas tanaman obat, 5 atribut tabular, dan fitur geospasial. Struktur data semacam ini membuat penelitian tidak berhenti pada klasifikasi citra, tetapi berkembang ke arah pemodelan data heterogen. (Vieira et al., 2020b), (Krones et al., 2025) menjelaskan bahwa integrasi multimodal dapat digunakan untuk menggabungkan informasi dari

berbagai sumber data dalam pemodelan *Machine Learning*, meskipun pada domain berbeda, juga menunjukkan bahwa integrasi data multimodal menjadi pendekatan penting dalam AI karena memungkinkan model menangkap hubungan antar sumber informasi yang tidak tampak pada satu modality saja (Xu et al., 2023b; Zhang et al., 2020b).

Pada tahap awal, *feature concatenation* menjadi *baseline* integrasi multimodal karena sederhana dan mampu menggabungkan berbagai fitur. Dalam penelitian ini *feature concatenation* (Nguyen et al., 2023; Zheng et al., 2020) merupakan metode sederhana untuk menggabungkan fitur dari berbagai sumber data dan banyak digunakan sebagai baseline karena kemudahannya. Namun, pendekatan ini memiliki kelemahan karena bersifat statis, tidak adaptif, dan belum mempertimbangkan kontribusi masing-masing modality. Dengan kata lain, citra, atribut tabular, dan geospasial diperlakukan sebagai gabungan fitur tanpa mekanisme pembobotan dinamis.

Arah terbaru dalam *multimodal learning* bergerak menuju *adaptive feature fusion*. Pendekatan ini menggunakan mekanisme seperti *attention*, *gated fusion*, atau pembobotan adaptif untuk menentukan kontribusi setiap sumber data terhadap keputusan model (Che et al., 2025; Zhao et al., 2024b). *Deep learning* untuk multimodal fusion terus berkembang untuk menangkap hubungan kompleks antar modality (Hong et al., 2021; Jiao et al., 2024b). (J. Wang et al., 2022b) melalui AM3Net menunjukkan bahwa pendekatan *adaptive mutual-learning-based multimodal data fusion* dapat digunakan untuk mempelajari hubungan antar sumber data secara lebih dinamis. Proposal penelitian juga menyatakan bahwa *adaptive feature fusion* menjadi arah lanjutan karena mampu menentukan bobot kontribusi masing-masing modality secara adaptif, sedangkan penerapannya dalam klasifikasi tanaman obat Indonesia masih terbatas.

Selain aspek metode, perkembangan *state of the art* juga menunjukkan pentingnya *benchmarking*. Dalam penelitian berbasis *Machine Learning* dan *Deep Learning*, benchmarking diperlukan untuk membandingkan performa model secara objektif pada dataset, skenario eksperimen, dan metrik evaluasi yang sama (Maseer et al., 2021). Random Forest dan Support Vector Machine masih relevan sebagai pembanding karena keduanya kuat pada data tabular atau fitur hasil ekstraksi. (Genuer & Poggi, 2020b) menjelaskan bahwa *Random Forest* merupakan metode *ensemble learning* yang efektif untuk klasifikasi dan regresi. (Pisner & Schnyer, 2020c) menjelaskan bahwa SVM efektif untuk klasifikasi pada ruang fitur berdimensi tinggi, sedangkan (Bansal et al., 2022b) menunjukkan bahwa SVM masih banyak digunakan dalam berbagai perbandingan algoritma *Machine Learning*. Dengan demikian, perbandingan antara Random Forest, SVM, dan CNN menjadi penting untuk menunjukkan posisi relatif model klasik dan model *Deep Learning* (Sheykhmousa et al., 2020) pada klasifikasi tanaman obat berbasis citra dan multimodal.

Berdasarkan uraian tersebut, *state of the art* penelitian ini berada pada irisan **Computer Vision, Machine Learning, Deep Learning, Data Science, dan Multimodal Learning**. Posisi ini sesuai dengan kompetensi Ketua Peneliti Dewi Handayani Untari Ningsih pada bidang Teknologi Informasi/Informatika. Penelitian ini tidak berfokus pada pengujian kandungan kimia, khasiat farmakologis, atau uji klinis tanaman obat, melainkan pada pengembangan proses komputasional untuk klasifikasi tanaman obat melalui benchmarking model dan integrasi data multimodal.

2.9.2 Research Gap

Berdasarkan perkembangan *state of the art* tersebut, terdapat beberapa celah penelitian yang menjadi dasar pelaksanaan penelitian ini.

Pertama, Riset klasifikasi tanaman didominasi pendekatan citra unimodal yang belum mampu merepresentasikan kompleksitas tanaman obat. Tanpa mengintegrasikan atribut tabular dan geospasial, informasi penting dari karakteristik botani serta lingkungan menjadi tidak optimal.

Kedua, integrasi data citra, tabular, dan geospasial pada klasifikasi tanaman obat Indonesia masih terbatas. dan minimnya mengintegrasikan data citra, tabular, dan geospasial. Studi ini mengisi celah tersebut dengan merancang dataset multimodal yang menggabungkan visualisasi tanaman, atribut botani, serta fitur spasial.

Ketiga, metode *feature concatenation* yang umum digunakan dalam multimodal fusion masih bersifat statis. Teknik ini belum mampu menentukan kontribusi masing-masing sumber data secara adaptif. Penelitian awal secara eksplisit menyebutkan kelemahan *feature concatenation*, yaitu tidak adaptif, tidak mempertimbangkan kontribusi tiap modality, dan kurang optimal dalam menangkap interaksi kompleks antar sumber data . Kelemahan ini menjadi dasar penting untuk mengembangkan metode *adaptive feature fusion* pada penelitian lanjutan.

Keempat, *Benchmarking* model *Machine Learning* dan *Deep Learning* pada data multimodal tanaman obat Indonesia masih sangat terbatas. Studi komparatif sistematis antara CNN, *Random Forest*, dan SVM sangat diperlukan untuk menentukan model yang paling tepat bagi data citra, tabular, geospasial, maupun gabungannya.

Kelima, masih terbatas dataset multimodal tanaman obat Indonesia yang terstruktur dan siap digunakan untuk riset AI. Dataset lokal menjadi penting karena tanaman obat Indonesia memiliki karakteristik visual, nama lokal, atribut botani, dan konteks lingkungan yang tidak selalu terwakili dalam dataset global. Indonesia plant Herb yang dikembangkan oleh (Pushpanathan et al., 2021; Putri et al., 2021; Rahayu et al., 2020; Singh et al., 2024) sudah menunjukkan arah penting pengenalan tanaman obat Indonesia berbasis *Deep Learning*, tetapi peluang pengembangan dataset multimodal yang memasukkan tabular dan geospasial masih terbuka.

2.9.3 Tabel Penguatan Referensi State of the Art

Tabel 1. Penguatan referensi dan relevansi terhadap Penelitian

No	Fokus State of the Art	Referensi Penguat	Substansi Dukungan Referensi	Relevansi terhadap Penelitian
1	Dominasi CNN dalam klasifikasi citra tanaman	(Saleem et al., 2020); (Tugrul et al., 2022); (Ashwinkumar et al., 2022); (Alzubaidi et al., 2021c); (Lu et al., 2021); (Sun et al., 2020)	CNN banyak digunakan karena mampu melakukan ekstraksi fitur visual secara otomatis melalui proses konvolusi, pooling, dan klasifikasi. CNN dapat mengenali pola visual tanaman secara hierarkis, seperti bentuk, warna, tekstur, dan struktur daun.	Menguatkan dasar pemilihan CNN sebagai pendekatan utama dalam ekstraksi fitur citra tanaman obat.
2	Deep Learning untuk klasifikasi tanaman obat	(Malik et al., 2022b);(Muneer & Fati, 2020); (Naeem et al., 2021)	Deep Learning semakin banyak digunakan untuk klasifikasi dan pengenalan spesies tanaman obat karena mampu mempelajari fitur visual kompleks dari citra tanaman.	Mendukung konteks domain penelitian, yaitu klasifikasi tanaman obat berbasis citra.
3	Transfer learning dalam klasifikasi tanaman	T. Ahmad et al. (2022); Hassan et al. (2021); Utami et al. (2025)	Transfer learning memungkinkan pemanfaatan model CNN yang telah dilatih pada dataset besar untuk meningkatkan akurasi klasifikasi pada dataset yang lebih spesifik.	Menguatkan penggunaan CNN pre-trained seperti VGG16, ResNet50, dan MobileNetV2 dalam penelitian.
4	Arsitektur CNN modern: ResNet, MobileNet, EfficientNet, Inception	Shafiq & Gu (2022); Rybczak & Kozakiewicz (2024)	ResNet unggul karena residual connection, sedangkan MobileNet, EfficientNet, dan Inception banyak digunakan karena efisiensi dan performa tinggi dalam klasifikasi citra.	Menjadi dasar perbandingan backbone CNN dan menjelaskan mengapa arsitektur modern perlu diuji.
5	Klasifikasi tanaman obat Indonesia berbasis Deep Learning	Ikrar Musyaffa et al. (2024); Putra et al. (2024); Govindaraj et al. (2025); Sonita et al. (2025)	Penelitian lokal dan regional menunjukkan bahwa Deep Learning relevan untuk pengenalan tanaman obat/herbal, termasuk melalui pendekatan	Memperkuat kebaruan kontekstual penelitian pada tanaman obat Indonesia.


			transfer learning dan EfficientNet.	
6	Keterbatasan pendekatan citra tunggal atau unimodal	Ikrar Musyaffa et al. (2024)	Klasifikasi berbasis citra saja belum sepenuhnya merepresentasikan kompleksitas tanaman karena tanaman juga dipengaruhi atribut botani, habitat, dan kondisi lingkungan.	Menjadi dasar argumen bahwa penelitian perlu bergerak dari citra tunggal menuju multimodal learning.
7	Multimodal data fusion dalam AI modern	Bayoudh et al. (2022); Kline et al. (2022); Stahlschmidt et al. (2022)	Multimodal data fusion memungkinkan penggabungan berbagai sumber data untuk membentuk representasi yang lebih lengkap dan informatif.	Mendukung integrasi citra, atribut tabular, dan geospasial dalam klasifikasi tanaman obat.
8	Multimodal learning untuk integrasi informasi visual, numerik, tekstual, dan kontekstual	Bayoudh et al. (2022); Jiao et al. (2024); Nakach et al. (2024)	Multimodal learning berkembang sebagai arah penting dalam AI karena mampu mengintegrasikan informasi dari modality yang berbeda.	Menguatkan posisi penelitian pada irisan Computer Vision, Data Science, dan Multimodal Learning.
9	Integrasi multimodal dalam pemodelan Machine Learning	Vieira et al. (2020); Krones et al. (2025); Xu et al. (2023); Zhang et al. (2020)	Integrasi multimodal dapat menangkap hubungan antar sumber data yang tidak tampak apabila hanya menggunakan satu modality.	Mendukung rancangan dataset citra, tabular, dan geospasial sebagai data heterogen.
10	Feature concatenation sebagai baseline multimodal fusion	Nguyen et al. (2023); Zheng et al. (2020)	<i>Feature concatenation</i> merupakan metode sederhana untuk menggabungkan fitur dari berbagai sumber data dan umum digunakan sebagai baseline.	Menjadi dasar penggunaan feature concatenation sebagai tahap awal integrasi multimodal.
11	Kelemahan feature concatenation statis	Nguyen et al. (2023); Zheng et al. (2020); Bayoudh et al. (2022)	<i>Feature concatenation</i> belum mempertimbangkan kontribusi masing-masing modality secara adaptif dan belum mampu memberi bobot dinamis pada tiap sumber data.	Menjadi dasar research gap bahwa metode fusion statis perlu dikembangkan menuju <i>adaptive feature fusion</i> .
12	Adaptive feature fusion dalam multimodal learning	Che et al. (2025); Zhao et al. (2024); Hong et al. (2021);	Adaptive fusion menggunakan mekanisme attention,	Menguatkan arah lanjutan penelitian menuju <i>adaptive</i>

		Jiao et al. (2024); J. Wang et al. (2022)	gated fusion, atau pembobotan adaptif untuk menentukan kontribusi setiap modality. AM3Net menunjukkan bahwa <i>adaptive mutual-learning</i> dapat mempelajari hubungan antar sumber data secara dinamis.	<i>feature fusion</i> pada klasifikasi tanaman obat multimodal.
13	Benchmarking model Machine Learning dan Deep Learning	Maseer et al. (2021); Bansal et al. (2022); Sheykhmousa et al. (2020)	Benchmarking diperlukan untuk membandingkan model secara objektif dengan dataset, skenario eksperimen, dan metrik evaluasi yang sama.	Mendukung desain penelitian yang membandingkan CNN, Random Forest, SVM, dan model multimodal secara sistematis.
14	Random Forest sebagai model pembanding	Genuer & Poggi (2020)	Random Forest merupakan metode ensemble learning yang efektif untuk klasifikasi dan regresi serta cukup kuat dalam menangani data non-linear.	Mendukung penggunaan Random Forest sebagai baseline Machine Learning untuk data tabular atau fitur hasil ekstraksi.
15	SVM untuk fitur berdimensi tinggi	Pisner & Schnyer (2020); Bansal et al. (2022)	SVM efektif pada ruang fitur berdimensi tinggi dan banyak digunakan dalam berbagai studi perbandingan algoritma Machine Learning.	Mendukung penggunaan SVM sebagai pembanding utama terhadap Random Forest dan CNN.
16	Posisi penelitian pada bidang Teknologi Informasi/Informatika	Alzubaidi et al. (2021); Xu et al. (2023); Jiao et al. (2024); Maseer et al. (2021)	Penelitian berada pada domain komputasional, yaitu Computer Vision, Machine Learning, Deep Learning, Data Science, dan Multimodal Learning.	Menegaskan kesesuaian penelitian dengan kompetensi Ketua Peneliti Dewi Handayani Untari Ningsih pada bidang Teknologi Informasi/Informatika, bukan farmasi atau uji klinis.

2.10 Roadmap Penelitian

Roadmap penelitian dibagi menjadi:

- **Tahun 1:** Dataset multimodal dan benchmarking ML vs DL
- **Tahun 2:** Pengembangan adaptive feature fusion
- **Tahun 3:** Explainable AI dan optimasi model



Gambar 4. Road Map Penelitian Klasifikasi Tanaman Obat

BAB III

TUJUAN DAN MANFAAT PENELITIAN

3.1 Tujuan Penelitian

Penelitian ini diarahkan untuk melakukan analisis perbandingan model *Machine Learning* dan *Deep Learning* dalam klasifikasi tanaman obat berbasis data citra dan multimodal. Fokus utama penelitian bukan sekadar memperoleh nilai akurasi tertinggi, tetapi menyusun *benchmarking* yang terukur terhadap performa *Random Forest*, *Support Vector Machine*, dan *Convolutional Neural Network* pada skenario data citra serta integrasi data multimodal. Penelitian bertujuan melakukan analisis komparatif atau *benchmarking* terhadap model *Machine Learning* dan *Deep Learning* sebagai dasar pengembangan metode *adaptive multimodal fusion*.

Secara umum, tujuan penelitian ini adalah menghasilkan dasar evaluatif yang kuat untuk menentukan model klasifikasi tanaman obat yang paling sesuai berdasarkan karakteristik data citra, data tabular, dan data geospasial. Penelitian ini sekaligus menjadi landasan awal bagi pengembangan metode integrasi multimodal yang lebih adaptif pada tahap penelitian berikutnya.

3.2 Tujuan Umum

Tujuan umum penelitian ini adalah:

Menganalisis dan membandingkan performa model *Random Forest*, *Support Vector Machine*, dan *Convolutional Neural Network* dalam klasifikasi tanaman obat berbasis data citra dan multimodal untuk menghasilkan model baseline dan kerangka evaluasi yang dapat digunakan sebagai dasar pengembangan metode *adaptive feature fusion*. Dimana inti riset bukan hanya “membandingkan model”, tetapi membangun **baseline ilmiah**. Tanpa baseline yang kuat, pengembangan metode adaptif pada tahap berikutnya akan lemah karena tidak memiliki titik pembandingan yang jelas.

3.3 Tujuan Khusus

Secara khusus, penelitian ini memiliki tujuan sebagai berikut.

1. Menyusun dataset multimodal tanaman obat yang terstruktur

Penelitian ini bertujuan menyusun dataset tanaman obat yang terdiri atas data citra, data tabular, dan data geospasial. Dataset dalam proposal dirancang menggunakan lebih dari 1.500 citra tanaman obat dari 17 kelas. Penyusunan dataset ini penting karena klasifikasi tanaman obat tidak cukup hanya mengandalkan citra, melainkan perlu memperhatikan atribut pendukung seperti karakteristik tanaman dan konteks lingkungan.

2. Menganalisis performa model Machine Learning klasik

Penelitian ini bertujuan menguji performa model *Random Forest* dan *Support Vector Machine* sebagai representasi pendekatan *Machine Learning* klasik. Kedua model tersebut relevan karena dapat digunakan pada data tabular atau fitur hasil ekstraksi. Analisis dilakukan untuk mengetahui sejauh mana model klasik mampu melakukan klasifikasi tanaman obat, terutama pada skenario data tabular, geospasial, atau fitur hasil ekstraksi dari citra.

3. Menganalisis performa model Deep Learning berbasis citra

Penelitian ini bertujuan menguji performa *Convolutional Neural Network* sebagai representasi model *Deep Learning* berbasis citra. CNN dipilih karena memiliki kemampuan melakukan ekstraksi fitur citra secara otomatis. Penelitian menunjukkan bahwa CNN memperoleh akurasi lebih tinggi dibandingkan *Random Forest* dan SVM pada studi awal, yaitu 91,3%, sedangkan *Random Forest* 84,7% dan SVM 82,5% .

4. Mengevaluasi pengaruh integrasi data multimodal terhadap performa klasifikasi

Penelitian ini bertujuan mengevaluasi apakah integrasi data citra, tabular, dan geospasial mampu meningkatkan performa klasifikasi dibandingkan pendekatan berbasis citra saja. Proposal menyebutkan bahwa integrasi multimodal menggunakan *feature concatenation* mampu meningkatkan akurasi menjadi 94,6%, meningkatkan F1-score sebesar 5,2%, serta menurunkan error rate sebesar 6,8% . Tujuan ini penting karena menjadi dasar pembuktian bahwa multimodal learning memberikan kontribusi nyata terhadap peningkatan performa model.

5. Menyusun benchmarking model klasifikasi tanaman obat

Penelitian ini bertujuan menyusun *benchmarking* model klasifikasi tanaman obat berdasarkan skenario eksperimen yang setara. Model yang dibandingkan meliputi *Random Forest*, *Support Vector Machine*, CNN, dan model multimodal berbasis *feature concatenation*. Evaluasi dilakukan menggunakan metrik *accuracy*, *precision*, *recall*, *F1-score*, *error rate*, dan *confusion matrix*. Tahapan evaluasi berupa *accuracy*, *precision*, *recall*, *F1-score*, *confusion matrix*, serta analisis komparatif ML vs DL vs multimodal .

6. Mengidentifikasi keterbatasan feature concatenation sebagai baseline fusion

Penelitian ini bertujuan mengidentifikasi keterbatasan *feature concatenation* sebagai metode integrasi multimodal tahap awal. Pendekatan ini penting sebagai baseline, tetapi masih bersifat statis dan belum mampu mengoptimalkan kontribusi setiap modality secara dinamis. Proposal menegaskan bahwa *fusion* statis belum mampu mengoptimalkan kontribusi tiap modality dan kebaruan penelitian terletak pada penyediaan *benchmarking* komprehensif berbasis data multimodal sebagai landasan pengembangan *adaptive feature fusion* .

7. Menyediakan dasar ilmiah untuk pengembangan *adaptive feature fusion*

Penelitian ini bertujuan menghasilkan dasar empiris untuk pengembangan metode *adaptive feature fusion* pada penelitian lanjutan. Hasil *benchmarking* akan menjadi acuan untuk mengetahui kelemahan pendekatan saat ini dan peluang pengembangan model yang mampu memberi bobot kontribusi berbeda terhadap citra, data tabular, dan data geospasial.

3.4 Manfaat Penelitian

Manfaat penelitian ini dibagi menjadi manfaat teoretis, manfaat metodologis, manfaat praktis, manfaat institusional, dan manfaat bagi pengembangan penelitian lanjutan.

3.4.1 Manfaat Teoretis

Secara teoretis, penelitian ini memberikan kontribusi pada pengembangan kajian *Data Science*, *Computer Vision*, *Machine Learning*, *Deep Learning*, dan *Multimodal Learning*. Penelitian ini memperkuat pemahaman bahwa klasifikasi tanaman obat tidak hanya dapat dilakukan melalui data citra, tetapi juga dapat diperluas melalui integrasi data tabular dan geospasial.

Penelitian ini juga memperkaya kajian tentang perbandingan model *Machine Learning* klasik dan *Deep Learning* dalam konteks klasifikasi tanaman obat. *Random Forest* dan *SVM* mewakili pendekatan pembelajaran mesin klasik, sedangkan *CNN* mewakili pendekatan *Deep Learning* berbasis citra. Dengan membandingkan ketiga model tersebut, penelitian ini memberikan gambaran yang lebih objektif mengenai karakteristik, keunggulan, dan keterbatasan masing-masing model.

Manfaat teoretis lain adalah tersedianya dasar konseptual untuk memahami keterbatasan *feature concatenation* sebagai metode *fusion* statis. Hasil penelitian dapat menjelaskan mengapa integrasi multimodal perlu dikembangkan lebih lanjut menuju pendekatan yang lebih adaptif.

3.4.2 Manfaat Metodologis

Secara metodologis, penelitian ini memberikan manfaat berupa rancangan alur eksperimen yang dapat digunakan sebagai acuan dalam penelitian klasifikasi berbasis data multimodal. Alur tersebut mencakup pengumpulan data, validasi dataset, preprocessing, ekstraksi fitur, pengembangan model, integrasi multimodal, training, tuning, evaluasi, dan benchmarking.

Manfaat metodologis yang paling penting adalah tersusunnya skenario *benchmarking* yang lebih adil antara model *Machine Learning* dan *Deep Learning*. Perbandingan model tidak dilakukan secara sembarangan, tetapi menggunakan dataset, skenario eksperimen, dan metrik evaluasi yang konsisten. Dengan begitu, hasil perbandingan lebih dapat dipertanggungjawabkan secara ilmiah.

Penelitian ini juga memberikan manfaat dalam penyusunan baseline model. Baseline ini dapat digunakan sebagai pembandingan untuk penelitian lanjutan, terutama ketika dikembangkan metode *adaptive feature fusion*, *attention-based fusion*, atau pendekatan *Explainable AI*.

3.4.3 Manfaat Praktis

Secara praktis, penelitian ini bermanfaat untuk mendukung proses identifikasi dan klasifikasi tanaman obat secara lebih sistematis berbasis kecerdasan buatan. Dataset multimodal yang disusun dapat menjadi dasar awal bagi pengembangan aplikasi atau sistem pendukung identifikasi tanaman obat.

Penelitian ini juga dapat membantu menghasilkan model klasifikasi yang lebih terukur karena performa model dievaluasi melalui beberapa metrik, bukan hanya akurasi. Penggunaan *precision*, *recall*, *F1-score*, *error rate*, dan *confusion matrix* memberikan gambaran lebih rinci mengenai kemampuan model dalam mengenali setiap kelas tanaman obat.

Manfaat praktis berikutnya adalah tersedianya informasi tentang model yang paling sesuai untuk jenis data tertentu. Random Forest dan SVM dapat lebih relevan pada data tabular atau fitur hasil ekstraksi, sedangkan CNN lebih relevan pada pengolahan citra. Dengan adanya *benchmarking*, pemilihan model tidak lagi berdasarkan asumsi, tetapi berdasarkan hasil evaluasi empiris.

3.4.4 Manfaat bagi Pengembangan Dataset Tanaman Obat Indonesia

Penelitian ini bermanfaat dalam penyusunan dataset tanaman obat Indonesia yang lebih terstruktur. Dataset tidak hanya berisi citra, tetapi juga atribut tabular dan informasi geospasial. Ini penting karena banyak dataset tanaman masih berfokus pada citra, sedangkan karakteristik tanaman obat sebenarnya lebih kompleks.

Dengan adanya dataset multimodal, penelitian selanjutnya dapat mengembangkan model yang lebih kuat dan lebih kontekstual. Dataset tersebut juga dapat digunakan sebagai dasar pengembangan repositori digital tanaman obat, sistem klasifikasi otomatis, atau bahan ajar berbasis data pada bidang kecerdasan buatan dan pengolahan citra.

3.4.5 Manfaat Institusional

Bagi institusi, penelitian ini mendukung penguatan riset pada bidang Teknologi Informasi/Informatika, khususnya *Artificial Intelligence*, *Data Science*, *Computer Vision*, *Machine Learning*, *Deep Learning*, dan *Multimodal Learning*. Proposal juga menegaskan bahwa penelitian ini berada pada bidang Data Science, Machine Learning dan Deep Learning, Computer Vision, serta Multimodal Learning .

Penelitian ini juga mendukung peningkatan luaran akademik institusi melalui penyusunan dataset, model baseline, hasil benchmarking, dan publikasi ilmiah. Dalam proposal, luaran yang ditargetkan meliputi dataset multimodal valid minimal 95%, model ML dan DL baseline dengan akurasi minimal 85%, model fusion dengan peningkatan minimal 3%, serta artikel pada jurnal SINTA 3 atau SINTA 4 .

3.4.6 Manfaat bagi Penelitian Lanjutan

Penelitian ini memiliki manfaat strategis sebagai fondasi untuk penelitian lanjutan. Hasil *benchmarking* dapat digunakan untuk menentukan kelemahan model baseline dan merancang metode integrasi yang lebih adaptif. Secara langsung, hasil penelitian ini dapat menjadi pijakan untuk pengembangan *adaptive feature fusion*, yaitu metode yang mampu menentukan kontribusi masing-masing modality secara dinamis.

Manfaat lanjutan lainnya adalah terbukanya peluang pengembangan *Explainable AI* untuk menjelaskan faktor atau fitur apa yang paling berpengaruh dalam klasifikasi tanaman obat. Hal ini sesuai dengan roadmap penelitian yang menempatkan tahun pertama pada dataset multimodal dan benchmarking ML vs DL, tahun kedua pada pengembangan *adaptive feature fusion*, dan tahun ketiga pada *Explainable AI* serta optimasi model .

3.5 Indikator Keberhasilan Tujuan dan Manfaat Penelitian

Agar tujuan penelitian tidak berhenti sebagai narasi, diperlukan indikator keberhasilan yang terukur. Indikator tersebut disusun sebagai berikut (ditunjukkan di tabel 2).

Tabel 2. Indikator Keberhasilan Riset

Tujuan Penelitian	Indikator Keberhasilan	Luaran yang Diharapkan
Menyusun dataset multimodal tanaman obat	Dataset citra, tabular, dan geospasial tersusun dan tervalidasi	Dataset multimodal terstruktur
Menguji model Machine Learning	Random Forest dan SVM berhasil dilatih dan dievaluasi	Nilai performa RF dan SVM
Menguji model Deep Learning	CNN berhasil dilatih dan divalidasi	Nilai performa CNN
Mengevaluasi integrasi multimodal	Model multimodal menunjukkan perubahan performa terukur	Hasil evaluasi feature concatenation
Menyusun benchmarking	Semua model dibandingkan dengan metrik yang sama	Tabel benchmarking ML vs DL vs multimodal
Mengidentifikasi keterbatasan fusion statis	Kelemahan feature concatenation terpetakan	Rekomendasi adaptive fusion
Menyiapkan publikasi ilmiah	Artikel disusun berdasarkan hasil eksperimen	Artikel ilmiah SINTA


BAB IV

METODE PENELITIAN


4.1 Desain Penelitian

Penelitian ini menggunakan pendekatan **eksperimental kuantitatif** dengan tujuan membandingkan performa beberapa kombinasi model *Deep Learning* dan *Machine Learning* dalam klasifikasi citra tanaman obat Indonesia. Desain penelitian diarahkan untuk mengetahui kombinasi arsitektur CNN dan model klasifikasi Machine Learning yang menghasilkan performa terbaik pada dataset tanaman obat. Berdasarkan dokumen metode, penelitian ini menggunakan dataset **17 kelas tanaman obat Indonesia** dengan total **2.940 citra original** dan meningkat menjadi **5.100 citra setelah augmentasi** (gambar 5). Gambar 5 menunjukkan dataset citra original dan citra hasil Augmentasi.

➔ Dataset Original



➔ Dataset Hasil Augmentasi



Gambar 5. Dataset dari 17 kelas tanaman obat dengan 2.940 citra asli dan 5100 citra hasil Augmentasi

Pendekatan utama penelitian adalah **CNN feature extraction + Machine Learning classification**. Artinya, model CNN tidak digunakan sebagai *classifier end-to-end* secara penuh, melainkan sebagai **ekstraktor fitur citra**. Fitur yang dihasilkan dari CNN kemudian direduksi dimensinya menggunakan **Principal Component Analysis (PCA)** dan diklasifikasikan menggunakan model *Machine Learning*. Pipeline penelitian terdiri atas tiga tahap utama, yaitu augmentasi dataset, ekstraksi fitur menggunakan CNN pre-trained, serta reduksi dimensi dan klasifikasi menggunakan model *Machine Learning*.

Arsitektur CNN yang digunakan adalah **VGG16, ResNet50, dan MobileNetV2**. Ketiga arsitektur ini dipilih karena memiliki karakteristik yang berbeda. VGG16 merepresentasikan arsitektur CNN klasik dengan struktur konvolusi bertingkat, ResNet50 merepresentasikan arsitektur residual network dengan mekanisme *skip connection*, sedangkan MobileNetV2 merepresentasikan arsitektur ringan yang efisien untuk potensi implementasi pada perangkat terbatas. Model Machine Learning yang digunakan adalah **SVM Linear, SVM RBF, Random Forest, dan K-Nearest Neighbors (KNN)**.

Dengan desain tersebut, penelitian ini tidak hanya menguji satu model, tetapi membandingkan **12 kombinasi model**, yaitu kombinasi antara tiga CNN backbone dan empat model Machine Learning. Kombinasi tersebut meliputi VGG16+SVM Linear, VGG16+SVM RBF, VGG16+Random Forest, VGG16+KNN, ResNet50+SVM Linear, ResNet50+SVM RBF, ResNet50+Random Forest, ResNet50+KNN, MobileNetV2+SVM Linear, MobileNetV2+SVM RBF, MobileNetV2+Random Forest, dan MobileNetV2+KNN.

4.2 Rumusan Eksperimen

Rumusan eksperimen dalam penelitian ini diarahkan pada perbandingan performa model. Berdasarkan dokumen metode, penelitian ini menjawab tiga pertanyaan utama. Pertama, bagaimana performa ekstraksi fitur menggunakan beberapa arsitektur CNN, yaitu VGG16, ResNet50, dan MobileNetV2, dalam menghasilkan fitur citra tanaman obat. Kedua, model Machine Learning mana yang memberikan akurasi tertinggi dalam klasifikasi tanaman obat berdasarkan fitur hasil ekstraksi CNN. Ketiga, bagaimana perbandingan performa antar kombinasi CNN backbone dan model Machine Learning.

Rumusan tersebut menunjukkan bahwa fokus penelitian bukan lagi sekadar membandingkan *Machine Learning* dan *Deep Learning* secara umum, tetapi lebih spesifik pada **kombinasi CNN sebagai feature extractor dan Machine Learning sebagai classifier**. Ini penting karena judul penelitian harus dibaca sebagai perbandingan model berbasis data citra dengan pendekatan hybrid, bukan murni CNN *end-to-end* versus *Machine Learning* biasa.

Pendekatan **eksperimental kuantitatif** untuk membandingkan kinerja *Machine Learning* dan *Deep Learning* dalam klasifikasi tanaman obat berbasis data citra dan multimodal. Metode dirancang secara bertahap mulai dari pengolahan data hingga evaluasi model.

1. Tahapan Penelitian

Tahap 1: Pengumpulan dan Integrasi Data

- Dataset: ± 1.500 citra (17 kelas), data tabular (4 atribut).
- **Output:** Dataset multimodal terstruktur
- **Indikator capaian:** $\geq 95\%$ data valid dan siap olah

Tahap 2: Preprocessing Data

- Citra: resizing, normalisasi
- Tabular: normalisasi Min-Max

$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

- Missing value handling
- **Output:** Data bersih dan terstandarisasi
- **Indikator:** Tidak ada missing value, distribusi data seimbang

Tahap 3: Ekstraksi Fitur

a. CNN (Deep Learning)

Ekstraksi fitur citra menggunakan CNN:

$$f_{img} = CNN(x_{img})$$

b. Tabular & Geospasial

Encoding dan normalisasi menghasilkan:

$$f_{tab}$$

- **Output:** Representasi fitur multimodal
- **Indikator:** Dimensi fitur optimal dan stabil

Tahap 4: Pengembangan Model

a. Random Forest

$$\hat{y} = \frac{1}{N} \sum_{i=1}^N T_i(x)$$

b. Support Vector Machine

$$f(x) = w^T x + b$$

c. CNN Classifier

$$y = \text{softmax}(W \cdot f_{img} + b)$$

- **Output:** Model ML dan DL
- **Indikator:** Model terlatih tanpa overfitting

Tahap 5: Multimodal Fusion (Baseline)

Menggunakan *feature concatenation*:

$$f_{fusion} = [f_{img}; f_{tab}]$$

- **Output:** Model multimodal
- **Indikator:** Integrasi data berhasil

Tahap 6: Evaluasi Model

Menggunakan metrik:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$
$$Precision = \frac{TP}{TP + FP}, Recall = \frac{TP}{TP + FN}$$

Output: Nilai performa model

Indikator: Akurasi $\geq 90\%$ (CNN), peningkatan $\geq 3\%$ (multimodal)

5.3 Hipotesis Penelitian

Hipotesis penelitian disusun untuk memberikan dugaan awal yang dapat diuji melalui eksperimen. Hipotesis ini didasarkan pada karakteristik arsitektur CNN, karakteristik model *Machine Learning*, dan rancangan pipeline penelitian. Berdasarkan dokumen metode, hipotesis penelitian terdiri atas tiga hipotesis utama, yaitu H1, H2, dan H3 .

H1: ResNet50 menghasilkan fitur yang lebih diskriminatif dibandingkan VGG16 dan MobileNetV2 karena kedalaman arsitektur dan mekanisme residual connection.

Hipotesis pertama menyatakan bahwa **ResNet50 menghasilkan fitur yang lebih diskriminatif** dibandingkan VGG16 dan MobileNetV2. Secara metodologis, hipotesis ini didasarkan pada karakteristik ResNet50 yang memiliki **50 layer** dan menggunakan mekanisme **residual atau skip connection**. Mekanisme ini memungkinkan aliran gradien berjalan lebih baik pada jaringan yang lebih dalam, sehingga model dapat mempelajari representasi visual yang lebih kompleks. Dalam dokumen metode, ResNet50 dijelaskan memiliki output fitur awal sebesar **$2048 \times 7 \times 7$ atau 100.352 fitur** sebelum proses reduksi dimensi .

Hipotesis ini relevan karena klasifikasi tanaman obat membutuhkan fitur visual yang mampu membedakan variasi bentuk daun, tekstur, warna, pola permukaan, dan ciri morfologis lainnya. Fitur yang lebih diskriminatif berarti fitur tersebut mampu memisahkan antar kelas tanaman secara lebih jelas dalam ruang fitur. Pada konteks ini, ResNet50 diperkirakan lebih unggul karena arsitekturnya lebih dalam dibandingkan VGG16 dan memiliki residual connection yang membantu stabilitas pembelajaran.

Hasil penelitian mendukung hipotesis ini. Dokumen hasil menunjukkan bahwa rata-rata akurasi berdasarkan CNN backbone adalah **ResNet50 sebesar 97,52%**, lebih tinggi dibandingkan **MobileNetV2 sebesar 96,60%** dan **VGG16 sebesar 94,29%**. Kombinasi terbaik juga diperoleh oleh **ResNet50 + SVM Linear** dengan akurasi **99,31%** dan F1-score **0,9931**. Dengan demikian, H1 dapat diterima karena ResNet50 terbukti menghasilkan fitur paling diskriminatif dalam eksperimen ini.

H2: SVM memberikan performa klasifikasi yang lebih baik dibandingkan Random Forest dan KNN pada fitur berdimensi tinggi dari CNN.

Hipotesis kedua menyatakan bahwa **SVM memberikan performa klasifikasi yang lebih baik dibandingkan Random Forest dan KNN** pada fitur hasil ekstraksi CNN. Hipotesis ini didasarkan pada karakteristik SVM yang efektif bekerja pada ruang fitur berdimensi tinggi. Dalam dokumen metode, SVM dijelaskan sebagai algoritma klasifikasi yang mencari **hyperplane optimal dengan margin maksimum** untuk memisahkan kelas. Penelitian ini menguji dua jenis SVM, yaitu **SVM Linear** dan **SVM RBF**.

Fitur hasil ekstraksi CNN pada awalnya memiliki dimensi sangat tinggi, yaitu VGG16 sebesar 25.088 fitur, ResNet50 sebesar 100.352 fitur, dan MobileNetV2 sebesar 62.720 fitur. Fitur tersebut kemudian direduksi menggunakan PCA menjadi **128 komponen** agar lebih efisien dan mengurangi risiko *curse of dimensionality*. Meskipun sudah direduksi, fitur hasil CNN tetap merupakan representasi tingkat tinggi yang kaya informasi visual. SVM cocok digunakan pada kondisi seperti ini karena mampu membentuk batas keputusan yang efektif pada ruang fitur hasil ekstraksi.

Hasil penelitian mendukung hipotesis kedua. Rata-rata akurasi model Machine Learning menunjukkan bahwa **SVM Linear memperoleh akurasi tertinggi sebesar 98,66%**, diikuti oleh **SVM RBF sebesar 98,43%**, **Random Forest sebesar 96,44%**, dan **KNN sebesar 91,01%**. Hasil ini menunjukkan bahwa SVM, khususnya SVM Linear, lebih stabil dan unggul dibandingkan Random Forest dan KNN pada fitur CNN. Dengan demikian, H2 dapat diterima.

H3: Kombinasi CNN+ML dapat mencapai akurasi klasifikasi di atas 95% untuk 17 kelas tanaman obat.

Hipotesis ketiga menyatakan bahwa **kombinasi CNN+ML dapat mencapai akurasi klasifikasi di atas 95%** untuk 17 kelas tanaman obat. Hipotesis ini didasarkan pada dugaan bahwa CNN mampu menghasilkan representasi fitur citra yang kuat, sementara model Machine Learning mampu melakukan klasifikasi secara efektif berdasarkan fitur tersebut. Kombinasi ini memanfaatkan keunggulan dua pendekatan: CNN sebagai *feature extractor* dan Machine Learning sebagai *classifier*.

Dataset penelitian terdiri atas **17 kelas tanaman obat Indonesia** dengan target **300 citra per kelas** setelah augmentasi, sehingga total citra menjadi **5.100**. Kelas tanaman obat yang digunakan antara lain biji kembang kantil, bunga tapak dara, bunga telang, daun insulin, daun jambu, daun kelor,

daun kemangi, daun kenikir, daun korokeling/kari, daun mimba, daun pepaya Jepang, daun salam, daun sirih, daun ubi jalar, kejibeling, rumput mutiara, dan sirih china .

Hasil penelitian menunjukkan bahwa sebagian besar kombinasi CNN+ML mampu mencapai akurasi di atas 95%. Kombinasi terbaik adalah **ResNet50 + SVM Linear** dengan akurasi **99,31%**, diikuti **ResNet50 + SVM RBF** sebesar **98,82%**, **MobileNetV2 + SVM RBF** sebesar **98,73%**, **MobileNetV2 + SVM Linear** sebesar **98,53%**, dan **VGG16 + SVM Linear** sebesar **98,14%** . Bahkan Random Forest juga menunjukkan performa baik, seperti ResNet50+Random Forest sebesar 97,06%, VGG16+Random Forest sebesar 96,47%, dan MobileNetV2+Random Forest sebesar 95,78% .

Tabel 2 berikut ini menunjukkan hipotesis penelitian yang terdiri dari H1, H2, dan H3, terkait keunggulan fitur ResNet50, performa SVM, dan capaian akurasi kombinasi CNN+ML di atas 95% untuk 17 kelas tanaman obat .

Tabel 3. Hipotesis Penelitian

Kode	Hipotesis Penelitian	Dasar Pemikiran	Indikator Pengujian	Hasil Eksperimen	Keputusan
H1	ResNet50 menghasilkan fitur yang lebih diskriminatif dibandingkan VGG16 dan MobileNetV2 karena kedalaman arsitektur dan mekanisme residual connection.	ResNet50 memiliki arsitektur lebih dalam dan menggunakan residual/skip connection sehingga diperkirakan mampu menghasilkan representasi fitur citra yang lebih kuat.	Rata-rata akurasi berdasarkan CNN backbone dan performa kombinasi terbaik tiap backbone.	ResNet50 memperoleh rata-rata akurasi tertinggi, yaitu 97,52%, dibandingkan MobileNetV2 96,60% dan VGG16 94,29%. Kombinasi terbaik juga diperoleh oleh ResNet50 + SVM Linear dengan akurasi 99,31%.	Diterima
H2	SVM memberikan performa klasifikasi yang lebih baik dibandingkan <i>Random Forest</i> dan KNN pada fitur berdimensi tinggi dari CNN.	SVM efektif bekerja pada ruang fitur berdimensi tinggi sehingga diperkirakan cocok untuk fitur hasil ekstraksi CNN yang telah direduksi menggunakan PCA.	Rata-rata akurasi tiap model Machine Learning pada fitur CNN.	SVM Linear memperoleh rata-rata akurasi tertinggi, yaitu 98,66%, disusul SVM RBF 98,43%, <i>Random Forest</i> 96,44%, dan KNN 91,01%.	Diterima
H3	Kombinasi CNN+ML dapat mencapai akurasi klasifikasi di	CNN berperan sebagai ekstraktor fitur citra, sedangkan model	Akurasi testing pada 12 kombinasi CNN	Kombinasi terbaik ResNet50 + SVM Linear mencapai akurasi 99,31% dan	Diterima terbatas

	atas 95% untuk 17 kelas tanaman obat.	ML berperan sebagai classifier. Kombinasi keduanya diperkirakan mampu menghasilkan akurasi tinggi.	backbone dan model ML.	F1-score 0,9931. Sebagian besar kombinasi CNN+SVM dan CNN+Random Forest mencapai akurasi di atas 95%, tetapi kombinasi KNN tidak seluruhnya memenuhi ambang tersebut; misalnya VGG16+KNN hanya 84,80%.	
--	---------------------------------------	--	------------------------	--	--

Berdasarkan hasil pengujian, H1 diterima karena ResNet50 terbukti menghasilkan fitur paling diskriminatif dibandingkan VGG16 dan MobileNetV2. H2 juga diterima karena SVM, khususnya SVM Linear, memberikan performa klasifikasi terbaik pada fitur hasil ekstraksi CNN. H3 diterima secara terbatas karena kombinasi CNN+ML mampu mencapai akurasi sangat tinggi, terutama pada kombinasi CNN dengan SVM dan *Random Forest*, tetapi tidak semua kombinasi memenuhi ambang akurasi di atas 95%, khususnya model berbasis KNN.

Kombinasi berbasis KNN menghasilkan performa lebih rendah, terutama VGG16 + KNN yang hanya mencapai 84,80%. Artinya, H3 diterima secara terbatas, bukan diterima mutlak. Sebagian besar kombinasi CNN+ML, terutama kombinasi CNN dengan SVM dan *Random Forest*, mampu mencapai akurasi di atas 95%, sedangkan kombinasi dengan KNN tidak selalu memenuhi ambang tersebut.

4.4 Dataset dan Preprocessing Penelitian

4.4.1 Sumber Data

Dataset yang digunakan dalam penelitian ini merupakan koleksi citra tanaman obat tradisional Indonesia yang dikumpulkan dari folder D:\Dewi_Agent. Dataset terdiri dari 17 kelas tanaman obat dengan total 2.940 citra original. Dataset yang digunakan dalam penelitian ini merupakan koleksi citra tanaman obat tradisional Indonesia yang dikumpulkan dari folder kerja penelitian.

Informasi Dataset:

- Lokasi: D:\Dewi_Agent
- Format: JPG, JPEG, PNG
- Resolusi: Bervariasi (akan di-resize ke 224x224)

- Jumlah Kelas: 17

Total Citra: 2.940 (original)

Dataset original terdiri atas **2.940 citra** dengan format JPG, JPEG, dan PNG. Resolusi citra bervariasi sehingga seluruh citra distandarkan menjadi **224 × 224 piksel** agar sesuai dengan kebutuhan input arsitektur CNN pre-trained .

Jumlah kelas tanaman obat yang digunakan adalah **17 kelas**. Setelah proses augmentasi, setiap kelas ditargetkan memiliki **300 citra**, sehingga total dataset menjadi **5.100 citra**. Strategi ini dilakukan untuk mengurangi ketidakseimbangan kelas dan meningkatkan kemampuan generalisasi model. Augmentasi dilakukan menggunakan teknik geometrik, fotometrik, filter, noise, dan color transformation.

4.4.2 Augmentasi

Teknik augmentasi yang digunakan meliputi flip horizontal, flip vertical, rotasi 90/180/270 derajat, center crop, brightness up/down, contrast up/down, sharpness up/down, Gaussian blur, sharpen, Gaussian noise, color shift, dan gamma correction . Augmentasi ini berfungsi memperkaya variasi data agar model tidak hanya menghafal citra original, tetapi mampu mengenali pola tanaman dalam berbagai kondisi visual. Untuk mengatasi ketidakseimbangan jumlah data antar kelas dan meningkatkan generalisasi model, dilakukan augmentasi data dengan target 300 citra per kelas. Total citra setelah augmentasi adalah 5.100.

Tabel 4 Teknik Augmentasi data citra yang digunakan.


No.	Kategori Augmentasi	Teknik yang Digunakan	Penjelasan Parameter
1	Geometrik	Flip Horizontal	Membalik citra dari kiri ke kanan pada sumbu X.
2	Geometrik	Flip Vertical	Membalik citra dari atas ke bawah pada sumbu Y.
3	Geometrik	Rotasi	Memutar citra sebesar 90°, 180°, atau 270°.
4	Geometrik	Center Crop	Memotong bagian tengah citra sebesar 80%, kemudian menyesuaikan kembali ukuran citra.
5	Fotometrik	Brightness Up/Down	Meningkatkan atau menurunkan tingkat kecerahan citra sebesar ±30%.
6	Fotometrik	Contrast Up/Down	Meningkatkan atau menurunkan kontras citra sebesar ±40%.
7	Fotometrik	Sharpness Up/Down	Meningkatkan ketajaman citra hingga 2× atau menurunkannya menjadi 0,5×.
8	Filter	Gaussian Blur	Memberikan efek blur pada citra dengan radius 2 piksel.

9	Filter	Sharpen	Menajamkan citra menggunakan filter penajaman standar.
10	Noise	Gaussian Noise	Menambahkan noise acak dengan nilai mean = 0 dan standar deviasi = 25.
11	Warna	Color Shift	Mengubah komposisi warna dengan penyesuaian R +10%, G - 10%, dan B +5%.
12	Warna	Gamma Correction	Mengatur intensitas pencahayaan citra dengan nilai gamma acak antara 0,7 sampai 1,3.

$$Target_Augmentasi = Target_Per_Kelas - Jumlah_Original$$

Jumlah gambar yang perlu ditambahkan per kelas

Augmentasi data dilakukan untuk meningkatkan variasi citra, mengurangi risiko overfitting, dan membantu model mengenali pola tanaman obat dalam berbagai kondisi visual. Teknik augmentasi yang digunakan mencakup transformasi geometrik, penyesuaian fotometrik, filter, penambahan noise, dan perubahan warna. Gambaran proses augmentasi citra ditunjukkan di gambar 6.



Gambar 6. Proses Augmentasi Citra

4.5 Pembagian Data (*Data Splitting*)

Pembagian data dilakukan menggunakan strategi **stratified split** untuk menjaga distribusi kelas tetap seimbang pada setiap subset data. Dalam dokumen metode, dataset dibagi menjadi tiga bagian, yaitu **training 70%**, **validation 10%**, dan **testing 20%**. Dengan total 5.100 citra, pembagian ini menghasilkan **3.570 data training**, **510 data validation**, dan **1.020 data testing**.

Tabel 5. Pembagian Data

No.	Bagian Data	Persentase	Jumlah Sampel	Tujuan Penggunaan
1	Training	70%	3.570 citra	Digunakan untuk melatih model dan melakukan ekstraksi fitur.
2	Validation	10%	510 citra	Digunakan untuk tuning hyperparameter dan validasi sementara model.
3	Testing	20%	1.020 citra	Digunakan untuk mengevaluasi performa akhir model.
	Total	100%	5.100 citra	Keseluruhan dataset setelah augmentasi.

$X_{train}, X_{val}, X_{test} = \text{train_test_split}(X, y, \text{test_size}=0.2, \text{stratify}=y)$
Stratified split untuk menjaga proporsi kelas

Data training digunakan untuk melatih model dan mengekstraksi fitur. Data validation digunakan untuk tuning hyperparameter, sedangkan data testing digunakan untuk evaluasi performa akhir. Strategi stratified split penting karena dataset memiliki banyak kelas, sehingga distribusi tiap kelas harus dijaga agar tidak terjadi bias evaluasi.

4.6 Ekstraksi Fitur Menggunakan CNN

Ekstraksi fitur dilakukan menggunakan pendekatan **transfer learning**. Model CNN pre-trained yang telah dilatih pada dataset besar ImageNet digunakan tanpa top layer. Dengan pendekatan ini, CNN berfungsi sebagai ekstraktor fitur, bukan sebagai classifier akhir. Transfer learning dipilih karena dapat mengurangi waktu komputasi, memanfaatkan fitur visual yang sudah dipelajari dari dataset besar, dan cocok untuk dataset yang relatif terbatas.

Pendekatan *transfer learning* dengan memanfaatkan tiga arsitektur CNN pre-trained, yaitu VGG16, ResNet50, dan MobileNetV2. Model CNN tersebut digunakan tanpa *top layer* sehingga berfungsi sebagai ekstraktor fitur, bukan sebagai classifier akhir. Citra tanaman obat berukuran 224×224×3 diproses melalui CNN pre-trained untuk menghasilkan representasi fitur visual. Fitur tersebut kemudian diringkas menggunakan *Global Average Pooling*, direduksi dimensinya menjadi 128 komponen menggunakan PCA, distandarisasi dengan *StandardScaler*, dan diklasifikasikan menggunakan model *Machine Learning*.

VGG16 digunakan sebagai baseline karena memiliki arsitektur yang stabil dan banyak digunakan dalam klasifikasi citra. ResNet50 digunakan karena memiliki mekanisme residual connection yang memungkinkan model menghasilkan fitur lebih diskriminatif. MobileNetV2 digunakan karena memiliki arsitektur ringan dan efisien sehingga relevan untuk pengembangan sistem klasifikasi pada perangkat dengan sumber daya terbatas. Ketiga arsitektur ini dibandingkan untuk mengetahui model CNN mana yang paling efektif dalam menghasilkan fitur citra tanaman obat.

4.6.1 Konsep Transfer learning

Transfer learning merupakan pendekatan yang memanfaatkan model *Convolutional Neural Network* atau CNN yang sebelumnya telah dilatih pada dataset besar, seperti ImageNet, untuk digunakan kembali pada tugas klasifikasi yang lebih spesifik. Dalam penelitian ini, *transfer learning* digunakan untuk membantu proses ekstraksi fitur citra tanaman obat.

Pendekatan ini dipilih karena model CNN pre-trained telah memiliki kemampuan awal dalam mengenali pola visual umum, seperti bentuk, warna, tekstur, tepi objek, dan struktur citra. Dengan demikian, model tidak perlu dilatih dari awal, tetapi cukup digunakan sebagai ekstraktor fitur untuk mengenali karakteristik citra tanaman obat.

Keuntungan penggunaan *transfer learning* dalam penelitian ini adalah sebagai berikut (tabel 6).

Tabel 6. Transfer Learning

No.	Keuntungan Transfer Learning	Penjelasan
1	Mengurangi waktu komputasi	Model tidak perlu dilatih dari awal karena sudah menggunakan bobot hasil pelatihan pada dataset besar.
2	Menghasilkan fitur yang lebih umum dan kuat	CNN pre-trained telah mempelajari pola visual dasar yang dapat digunakan kembali pada citra tanaman obat.
3	Cocok untuk dataset terbatas	Pendekatan ini efektif digunakan ketika jumlah data penelitian tidak sebesar dataset pelatihan model asli.
4	Meningkatkan efisiensi eksperimen	Peneliti dapat membandingkan beberapa arsitektur CNN tanpa harus melakukan pelatihan penuh dari awal.

Pipeline *transfer learning* yang digunakan dalam penelitian ini adalah sebagai berikut:

Input citra 224×224×3 → CNN pre-trained tanpa top layer → Global Average Pooling → PCA 128 dimensi → StandardScaler → Machine Learning Classifier (ditunjukkan di gambar 4)

Melalui alur tersebut, citra tanaman obat terlebih dahulu distandarkan ukurannya menjadi 224×224 piksel dengan tiga kanal warna. Citra kemudian diproses menggunakan model CNN pre-trained tanpa lapisan klasifikasi akhir. Fitur yang dihasilkan oleh CNN selanjutnya diringkas menggunakan *Global Average Pooling*, direduksi dimensinya menggunakan PCA menjadi 128 komponen, distandarisasi menggunakan *StandardScaler*, lalu diklasifikasikan menggunakan model *Machine Learning*.

4.6.2 Arsitektur CNN yang Digunakan

Penelitian ini menggunakan tiga arsitektur CNN pre-trained, yaitu **VGG16**, **ResNet50**, dan **MobileNetV2**. Ketiga arsitektur ini dipilih karena memiliki karakteristik yang berbeda, sehingga dapat digunakan untuk membandingkan efektivitas ekstraksi fitur citra tanaman obat.

a. VGG16

VGG16 merupakan arsitektur CNN yang dikembangkan oleh Visual Geometry Group, University of Oxford. Arsitektur ini terdiri atas 16 layer, yaitu 13 layer konvolusi dan 3 layer *fully connected*. VGG16 menggunakan filter berukuran 3×3 dengan stride 1 dan *max pooling* berukuran 2×2.

Dalam penelitian ini, VGG16 digunakan sebagai ekstraktor fitur dengan mengambil output sebelum lapisan *fully connected*. Output fitur yang dihasilkan berukuran **512 × 7 × 7**, sehingga menghasilkan **25.088 fitur**. VGG16 dipilih karena arsitekturnya sederhana, stabil, dan banyak digunakan sebagai baseline dalam penelitian klasifikasi citra.

b. ResNet50

ResNet50 merupakan arsitektur CNN berbasis *Residual Network* yang dikembangkan oleh Microsoft. Arsitektur ini memiliki 50 layer dan dilengkapi mekanisme **residual connection** atau **skip connection**. Mekanisme ini memungkinkan informasi dan gradien mengalir lebih baik pada jaringan yang dalam, sehingga membantu mengurangi masalah degradasi performa pada model CNN yang memiliki banyak layer.

Dalam penelitian ini, ResNet50 digunakan sebagai ekstraktor fitur dengan output sebelum lapisan klasifikasi akhir. Fitur yang dihasilkan berukuran **2048 × 7 × 7**, sehingga menghasilkan **100.352 fitur**. ResNet50 dipilih karena memiliki kemampuan yang kuat dalam menghasilkan representasi fitur visual yang lebih diskriminatif.

c. MobileNetV2

MobileNetV2 merupakan arsitektur CNN ringan yang dikembangkan oleh Google. Arsitektur ini dirancang agar efisien dari sisi komputasi, sehingga cocok digunakan pada perangkat dengan sumber daya terbatas seperti perangkat mobile, edge device, atau sistem berbasis IoT.

MobileNetV2 menggunakan konsep **inverted residuals** dan **linear bottlenecks** untuk menjaga efisiensi model tanpa mengorbankan performa secara signifikan. Dalam penelitian ini, MobileNetV2 menghasilkan output fitur berukuran **1280 × 7 × 7**, sehingga menghasilkan **62.720 fitur**. Arsitektur ini digunakan untuk melihat sejauh mana model ringan dapat bersaing dengan arsitektur yang lebih besar seperti VGG16 dan ResNet50. Perbandingan arsitektur CNN ditunjukkan di tabel 7 berikut ini:

Tabel 7. Perbandingan Arsitektur CNN


No.	Arsitektur CNN	Karakteristik Utama	Output Fitur Awal	Kelebihan	Peran dalam Penelitian
1	VGG16	CNN klasik dengan 16 layer dan filter 3×3	25.088 fitur	Stabil, sederhana, dan sering digunakan sebagai baseline	Pembanding dasar untuk ekstraksi fitur citra
2	ResNet50	CNN 50 layer dengan residual/skip connection	100.352 fitur	Mampu menghasilkan fitur visual yang lebih diskriminatif	Kandidat utama ekstraktor fitur dengan performa tinggi
3	MobileNetv2	CNN ringan dengan inverted residuals dan linear bottlenecks	62.720 fitur	Efisien dan cocok untuk perangkat mobile atau edge device	Pembanding model ringan untuk efisiensi komputasi

Perbandingan Parameter Arsitektur CNN

Berikut ini (tabel 8) parameter dari arsitektur CNN dalam bentuk ringkasan perbandingan ketiga arsitektur berdasarkan spesifikasinya.

Tabel 8. Parameter CNN dan perbandingan ketiga arsitektur CNN.

Parameter	VGG16	ResNet50	MobileNetV2
Jumlah Layer	16	50	53
Total Parameter	138M	25.6M	3.4M
Ukuran Input	$224 \times 224 \times 3$	$224 \times 224 \times 3$	$224 \times 224 \times 3$
Output Fitur	$512 \times 7 \times 7$	$2048 \times 7 \times 7$	$1280 \times 7 \times 7$
Dimensi Asli	25.088	100.352	62.720
Dimensi (Setelah PCA)	128	128	128
Skip Connection	Tidak	Ya (Residual)	Ya (Inverted)
Pre-trained	ImageNet	ImageNet	ImageNet



Gambar 7. Pipeline ekstraksi fitur

Tiga arsitektur CNN digunakan dalam penelitian ini. **VGG16** memiliki 16 layer dan menghasilkan dimensi fitur asli sebesar 25.088. **ResNet50** memiliki 50 layer dengan residual connection dan menghasilkan dimensi fitur asli sebesar 100.352. **MobileNetV2** merupakan arsitektur ringan berbasis inverted residual dan linear bottleneck yang menghasilkan dimensi fitur asli sebesar 62.720. Seluruh fitur kemudian direduksi menjadi **128 komponen PCA**.

1. VGG16

VGG16 adalah arsitektur CNN klasik yang dikembangkan oleh *Visual Geometry Group*, University of Oxford. Model ini terdiri atas **16 layer**, yaitu 13 layer konvolusi dan 3 layer *fully connected*. Dalam penelitian ini, VGG16 tidak digunakan sebagai classifier akhir, tetapi sebagai **ekstraktor fitur citra**.

Cara kerjanya:

Citra tanaman obat berukuran **224×224×3** dimasukkan ke dalam jaringan VGG16. Layer konvolusi kemudian membaca pola visual dasar seperti tepi, warna, tekstur, bentuk daun, dan pola permukaan tanaman. Semakin dalam layer yang dilalui, fitur yang ditangkap semakin kompleks. Output fitur yang digunakan adalah output sebelum layer *fully connected*, yaitu sebesar **512×7×7**, sehingga menghasilkan **25.088 fitur awal**.

Dalam konteks penelitian ini, VGG16 berperan sebagai **baseline arsitektur CNN**. Artinya, VGG16 digunakan sebagai pembandingan dasar untuk melihat apakah arsitektur yang lebih baru seperti ResNet50 dan MobileNetV2 dapat menghasilkan fitur yang lebih baik. Keunggulan VGG16 adalah arsitekturnya sederhana, stabil, dan mudah dipahami. Kelemahannya, jumlah parameternya besar dan tidak memiliki mekanisme *skip connection*, sehingga fitur yang dihasilkan cenderung kurang fleksibel dibandingkan ResNet50.

Secara sederhana:

Aspek	Penjelasan
Fungsi	Ekstraktor fitur citra tanaman obat
Jumlah layer	16 layer
Ciri utama	Arsitektur klasik dengan filter konvolusi 3×3
Output fitur awal	25.088 fitur
Kelebihan	Stabil, sederhana, cocok sebagai baseline
Keterbatasan	Parameter besar dan tidak memiliki residual connection

2. ResNet50

ResNet50 adalah arsitektur CNN berbasis *Residual Network* yang dikembangkan oleh Microsoft. Model ini memiliki **50 layer** dan dilengkapi dengan mekanisme **residual connection** atau **skip connection**. Mekanisme ini menjadi pembeda utama ResNet50 dibandingkan VGG16.

Pada CNN yang sangat dalam, informasi dapat melemah ketika melewati banyak layer. ResNet50 mengatasi masalah tersebut dengan *skip connection*, yaitu jalur pintas yang memungkinkan informasi dari layer sebelumnya diteruskan ke layer berikutnya. Dengan cara ini, aliran gradien menjadi lebih stabil dan model dapat belajar representasi visual yang lebih kompleks.

Dalam penelitian ini, citra tanaman obat diproses melalui ResNet50 tanpa top layer. Output fitur yang dihasilkan sebelum layer klasifikasi adalah **2048×7×7**, sehingga menghasilkan **100.352 fitur awal**. Dimensi fitur ini jauh lebih besar dibandingkan VGG16 dan MobileNetV2. Hal ini menunjukkan bahwa ResNet50 menghasilkan representasi visual yang lebih kaya.

eksperimen juga mendukung penggunaan ResNet50. Dokumen hasil penelitian menunjukkan bahwa ResNet50 menjadi backbone dengan rata-rata akurasi tertinggi, yaitu **97,52%**, dibandingkan MobileNetV2 sebesar **96,60%** dan VGG16 sebesar **94,29%**. Kombinasi terbaik adalah **ResNet50 + SVM Linear** dengan akurasi **99,31%** dan F1-score **0,9931**.

Secara sederhana:

Aspek	Penjelasan
Fungsi	Ekstraktor fitur utama dengan representasi visual kuat
Jumlah layer	50 layer
Ciri utama	Memiliki residual/skip connection
Output fitur awal	100.352 fitur
Kelebihan	Menghasilkan fitur paling diskriminatif
Keterbatasan	Dimensi fitur besar sehingga perlu reduksi PCA

3. MobileNetV2

MobileNetV2 adalah arsitektur CNN ringan yang dikembangkan oleh Google. Model ini dirancang agar efisien dari sisi ukuran model dan komputasi. Berbeda dari VGG16 dan ResNet50 yang relatif lebih besar, MobileNetV2 cocok untuk skenario implementasi pada perangkat dengan sumber daya terbatas, seperti perangkat mobile, edge device, atau sistem IoT.

MobileNetV2 menggunakan konsep **inverted residual** dan **linear bottleneck**. Inverted residual membantu model mempertahankan informasi penting meskipun arsitekturnya ringan, sedangkan linear bottleneck membantu mengurangi hilangnya informasi selama proses transformasi fitur. Dalam penelitian ini, MobileNetV2 digunakan sebagai pembanding untuk melihat apakah arsitektur ringan tetap mampu menghasilkan performa tinggi dalam klasifikasi tanaman obat.

Output fitur awal MobileNetV2 adalah **1280×7×7**, sehingga menghasilkan **62.720 fitur awal**. Dimensi ini lebih besar daripada VGG16, tetapi lebih kecil daripada ResNet50. Hasil penelitian menunjukkan bahwa MobileNetV2 tetap kompetitif, dengan rata-rata akurasi **96,60%**. Bahkan kombinasi MobileNetV2 + SVM RBF mencapai akurasi **98,73%**, dan MobileNetV2 + SVM Linear mencapai **98,53%**.

Perbandingan tiga arsitektur VGG16, ResNet50, MobilenetV2 ditunjukkan di tabel 9.

Secara sederhana:

Aspek	Penjelasan
Fungsi	Ekstraktor fitur ringan dan efisien
Karakteristik	Lightweight CNN
Ciri utama	Inverted residual dan linear bottleneck
Output fitur awal	62.720 fitur
Kelebihan	Efisien, cocok untuk perangkat mobile/edge
Keterbatasan	Fitur tidak sekaya ResNet50, tetapi tetap kompetitif

Tabel 9. Perbandingan Tiga Arsitektur CNN berdasarkan Output

Arsitektur	Karakter Utama	Output Fitur Awal	Peran dalam Penelitian	Catatan Hasil
VGG16	CNN klasik 16 layer	25.088	Baseline ekstraksi fitur	Stabil, tetapi rata-rata performa paling rendah dibanding dua backbone lain
ResNet50	CNN 50 layer dengan residual connection	100.352	Ekstraktor fitur utama	Menghasilkan fitur paling diskriminatif dan performa terbaik
MobileNetV2	CNN ringan berbasis inverted residual	62.720	Ekstraktor fitur efisien	Ringan, tetapi tetap kompetitif untuk klasifikasi

4.7 Reduksi Dimensi dengan PCA

Principal Component Analysis (PCA) digunakan untuk mereduksi dimensi fitur CNN dari dimensi asli (25.088 - 100.352) menjadi 128 komponen.

PCA membantu:

1. Mengurangi computational cost untuk training ML
2. Mengurangi curse of dimensionality
3. Menghilangkan noise pada fitur
4. Mempertahankan informasi penting (>85% explained variance)

Fitur CNN memiliki dimensi yang sangat tinggi. Jika langsung digunakan untuk klasifikasi Machine Learning, dimensi tersebut dapat meningkatkan beban komputasi, memperbesar risiko *curse of dimensionality*, dan memasukkan noise ke dalam proses pembelajaran. Oleh karena itu, penelitian ini menggunakan **Principal Component Analysis (PCA)** untuk mereduksi fitur menjadi **128 komponen**.

Reduksi dimensi dengan PCA:

$$X_{pca} = PCA(n_components=128).fit_transform(X_original)$$

Proporsi variansi yang dijelaskan oleh komponen PCA:

$$Explained_Variance_Ratio = \text{sum}(\lambda_i) / \text{sum}(\lambda_{all})$$

PCA digunakan untuk mempertahankan informasi penting dari fitur CNN dengan dimensi yang lebih efisien. Dalam dokumen metode, PCA dijelaskan membantu mengurangi biaya komputasi, mengurangi *curse of dimensionality*, menghilangkan noise, dan mempertahankan informasi penting dengan target **explained variance lebih dari 85%** .

Berdasarkan dokumen hasil, PCA menghasilkan explained variance sebesar **91,85% pada VGG16, 86,52% pada ResNet50**, dan sekitar **85% pada MobileNetV2** . Ini menunjukkan bahwa reduksi ke 128 komponen masih mempertahankan proporsi informasi yang memadai untuk proses klasifikasi.

4.8 Model Machine Learning

Model Machine Learning yang digunakan dalam penelitian ini terdiri atas **SVM Linear, SVM RBF, Random Forest, dan KNN**.

4.8.1 Support Vector Machine (SVM)

Support Vector Machine (SVM) merupakan algoritma pembelajaran mesin yang digunakan untuk mengklasifikasikan data ke dalam kelas tertentu. SVM bekerja dengan mencari garis atau bidang pemisah terbaik, yang disebut **hyperplane**, di antara kelas-kelas data.

Hyperplane dipilih berdasarkan jarak pemisah terbesar terhadap data terdekat dari masing-masing kelas. Jarak tersebut disebut **margin**, sedangkan data yang berada paling dekat dengan hyperplane disebut **support vector**. Semakin besar margin yang terbentuk, semakin baik kemampuan model dalam membedakan kelas.

Dalam penelitian ini digunakan dua jenis kernel SVM, yaitu **kernel linear** dan **kernel Radial Basis Function (RBF)**.

1. SVM dengan Kernel Linear

Kernel linear digunakan ketika pola pemisahan antar kelas cenderung berbentuk garis lurus atau dapat dipisahkan secara linear. Fungsi keputusan SVM linear dirumuskan sebagai:

$$f(x) = \text{sign}(w^T x + b)$$

Keterangan:

- x adalah data masukan;
- w adalah bobot model;
- b adalah nilai bias;
- sign menentukan kelas hasil prediksi.

Model akan menghitung posisi data terhadap hyperplane. Nilai hasil perhitungan tersebut kemudian digunakan untuk menentukan kelas data.

2. SVM dengan Kernel RBF

Kernel RBF digunakan ketika hubungan atau batas antar kelas tidak dapat dipisahkan menggunakan garis lurus. Kernel ini memetakan data ke ruang berdimensi lebih tinggi sehingga pola yang kompleks dapat dipisahkan dengan lebih baik.

Fungsi kernel RBF dirumuskan sebagai:

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Keterangan:

- x dan x' adalah dua data yang dibandingkan;
- $\|x - x'\|^2$ menunjukkan jarak kuadrat antara kedua data;
- γ mengatur seberapa jauh pengaruh setiap data;
- $\exp$ merupakan fungsi eksponensial.

Nilai gamma yang besar membuat pengaruh setiap data menjadi lebih sempit sehingga batas klasifikasi lebih kompleks. Sebaliknya, nilai gamma yang kecil menghasilkan batas klasifikasi yang lebih halus. Parameter model SVM diberikan di tabel 10.

Tabel 10. Parameter Model SVM

Parameter	SVM Linear	SVM RBF	Penjelasan
Kernel	linear	rbf	Menentukan bentuk fungsi pemisah antar kelas
C atau regularisasi	1,0	10,0	Mengatur keseimbangan antara margin yang besar dan kesalahan klasifikasi
Gamma	Tidak digunakan	scale	Mengatur luas pengaruh setiap data pada kernel RBF
Probability	True	True	Mengaktifkan keluaran probabilitas prediksi

Parameter **C** mengendalikan tingkat toleransi model terhadap kesalahan klasifikasi. Nilai **C** yang kecil memberikan toleransi lebih besar terhadap kesalahan dan menghasilkan margin yang lebih lebar. Nilai **C** yang besar membuat model lebih ketat dalam mengklasifikasikan data, tetapi dapat meningkatkan risiko overfitting.

Pengaturan `gamma='scale'` berarti nilai gamma dihitung secara otomatis berdasarkan jumlah fitur dan variasi data. Sementara itu, `probability=True` digunakan agar model dapat menghasilkan probabilitas untuk setiap kelas, bukan hanya label hasil prediksi.

Secara umum, SVM linear digunakan sebagai model yang lebih sederhana dan mudah diinterpretasikan, sedangkan SVM RBF digunakan untuk menangani pola data yang lebih kompleks dan tidak linear. Kedua model kemudian dibandingkan berdasarkan hasil evaluasi untuk menentukan konfigurasi yang memberikan kinerja klasifikasi terbaik.

5.8.2 Random Forest

Random Forest merupakan algoritma pembelajaran mesin berbasis **ensemble learning** yang menggabungkan banyak pohon keputusan atau *decision tree* untuk menghasilkan prediksi yang lebih stabil dan akurat.

Setiap pohon dilatih menggunakan sampel data dan sebagian fitur yang dipilih secara acak. Setelah seluruh pohon menghasilkan prediksi, *Random Forest* menentukan hasil akhir melalui mekanisme **majority voting**, yaitu memilih kelas yang paling banyak diprediksi oleh seluruh pohon. Secara sederhana, satu pohon keputusan dapat menghasilkan prediksi yang kurang stabil. Random Forest mengurangi kelemahan tersebut dengan menggabungkan banyak pohon sehingga keputusan akhir tidak bergantung pada satu model saja.

Mekanisme Prediksi Random Forest

Prediksi Random Forest untuk masalah klasifikasi dirumuskan sebagai:

$$\hat{y} = \text{mode}(h_1(x), h_2(x), \dots, h_T(x))$$

Keterangan:

- $\hat{y}$ adalah hasil prediksi akhir;
- x adalah data masukan;
- $h_1(x), h_2(x), \dots, h_T(x)$ adalah hasil prediksi dari setiap pohon keputusan;
- T adalah jumlah pohon;
- mode menunjukkan kelas yang paling sering dipilih.

Sebagai contoh, apabila dari 200 pohon terdapat 130 pohon yang memprediksi kelas A dan 70 pohon memprediksi kelas B, hasil akhir yang dipilih adalah kelas A.

Kelebihan Random Forest

Random Forest memiliki beberapa kelebihan berikut.

1) Lebih tahan terhadap overfitting

Penggabungan banyak pohon membantu mengurangi ketergantungan model terhadap pola tertentu pada data latih.

2) Mampu menangani hubungan non-linear

Random Forest dapat mempelajari pola data yang kompleks tanpa mengharuskan hubungan antarvariabel berbentuk linear.

3) Menyediakan nilai kepentingan fitur

Model dapat menunjukkan fitur yang memberikan kontribusi paling besar terhadap hasil klasifikasi.

4) Mendukung pemrosesan paralel

Setiap pohon dapat dilatih secara terpisah sehingga proses komputasi dapat dijalankan secara bersamaan menggunakan beberapa inti prosesor.

Parameter model Random Forest diberikan di tabel 11.

Tabel 11. Parameter Model Random Forest

Parameter	Nilai	Penjelasan
n_estimators	200	Jumlah pohon keputusan yang dibangun dalam model
max_depth	None	Kedalaman pohon tidak dibatasi dan berkembang sampai memenuhi kriteria penghentian
min_samples_split	2	Jumlah minimum sampel yang diperlukan untuk membagi satu simpul
random_state	42	Menjaga agar proses acak menghasilkan keluaran yang konsisten ketika eksperimen diulang
n_jobs	-1	Menggunakan seluruh inti prosesor yang tersedia untuk mempercepat proses pelatihan

Penjelasan Parameter

- Parameter n_estimators=200 menunjukkan bahwa model menggunakan 200 pohon keputusan. Jumlah pohon yang lebih banyak umumnya menghasilkan prediksi yang lebih stabil, tetapi membutuhkan waktu komputasi yang lebih besar.
- Parameter max_depth=None berarti kedalaman setiap pohon tidak dibatasi secara langsung. Pohon akan terus berkembang sampai seluruh daun cukup murni atau jumlah sampel tidak lagi memenuhi syarat untuk dibagi. Pengaturan ini dapat membantu model menangkap pola yang kompleks, tetapi juga perlu dikendalikan agar tidak meningkatkan risiko overfitting.
- Parameter min_samples_split=2 berarti suatu simpul dapat dibagi apabila memiliki sedikitnya dua sampel. Nilai ini merupakan pengaturan standar yang memungkinkan pohon tumbuh cukup rinci.
- Parameter random_state=42 digunakan untuk memastikan proses pengambilan sampel acak dan pemilihan fitur menghasilkan keluaran yang sama ketika eksperimen dijalankan kembali. Pengaturan ini penting untuk menjaga reproduktibilitas penelitian.
- Parameter n_jobs=-1 menginstruksikan sistem agar menggunakan seluruh inti prosesor yang tersedia. Pengaturan tersebut mempercepat pelatihan karena pembangunan beberapa pohon dapat dilakukan secara paralel.

Secara keseluruhan, Random Forest digunakan karena mampu menangani pola data yang kompleks, relatif tahan terhadap overfitting, serta menyediakan informasi mengenai kontribusi setiap fitur. Model ini kemudian dievaluasi menggunakan metrik klasifikasi untuk mengetahui kemampuan prediksinya dibandingkan dengan metode lainnya.

4.8.4 K-Nearest Neighbors (KNN)

K-Nearest Neighbors (KNN) merupakan algoritma pembelajaran mesin yang mengklasifikasikan data baru berdasarkan kemiripannya dengan sejumlah data terdekat. Algoritma ini termasuk metode **instance-based learning**, karena proses prediksi dilakukan dengan membandingkan langsung data baru terhadap data yang telah tersedia.

KNN tidak membentuk model matematis yang kompleks pada tahap pelatihan. Seluruh data latih disimpan, kemudian digunakan ketika terdapat data baru yang akan diprediksi. Oleh karena itu, KNN sering disebut sebagai metode **lazy learning**.

Mekanisme Kerja KNN

Proses klasifikasi KNN dilakukan melalui beberapa tahap berikut:

1. Menghitung jarak antara data baru dan seluruh data latih.
2. Memilih sejumlah K data dengan jarak paling dekat.
3. Mengidentifikasi kelas dari masing-masing tetangga terdekat.
4. Menentukan kelas akhir berdasarkan jumlah suara terbanyak atau bobot jarak.

Prediksi KNN dapat dirumuskan sebagai:

$$\hat{y} = \arg \max_c \sum_{i \in N_K(x)} I(y_i = c)$$

Keterangan:

- $\hat{y}$ adalah kelas hasil prediksi;
- c adalah kelas kandidat;
- $N_K(x)$ adalah kumpulan K tetangga terdekat dari data x ;
- y_i adalah kelas dari tetangga ke- i ;
- $I(y_i = c)$ bernilai 1 apabila kelas tetangga sama dengan kelas c , dan 0 apabila berbeda;
- $\arg \max$ memilih kelas dengan jumlah suara terbesar.

Pada konfigurasi berbobot jarak, tetangga yang posisinya lebih dekat memiliki pengaruh lebih besar dibandingkan tetangga yang jaraknya lebih jauh.

Apabila digunakan nilai $K = 5$, sistem akan memilih lima data yang paling dekat dengan data baru. Misalnya, tiga tetangga termasuk kelas A dan dua tetangga termasuk kelas B, maka data baru akan diprediksi sebagai kelas A.

Pada pengaturan *weights* = 'distance', keputusan tidak hanya mempertimbangkan jumlah tetangga. Jarak setiap tetangga juga diperhitungkan sehingga tetangga terdekat memberikan kontribusi suara yang lebih besar.

Kelebihan KNN

KNN memiliki beberapa kelebihan berikut:

1) **Sederhana dan mudah dipahami**

Proses klasifikasi didasarkan pada kedekatan data sehingga konsepnya relatif intuitif.

2) **Tidak memerlukan tahap pelatihan yang kompleks**

KNN hanya menyimpan data latih dan melakukan perhitungan ketika proses prediksi berlangsung.

3) **Tidak mengasumsikan distribusi data tertentu**

KNN termasuk metode nonparametrik sehingga tidak mengharuskan data mengikuti distribusi tertentu.

4) **Mampu menangani pola non-linear**

KNN dapat membentuk batas klasifikasi yang fleksibel berdasarkan persebaran data.

Keterbatasan KNN

KNN memiliki beberapa keterbatasan yang perlu diperhatikan:

1) Proses prediksi dapat menjadi lambat pada dataset berukuran besar karena jarak terhadap seluruh data latih perlu dihitung.

2) Hasil klasifikasi sangat dipengaruhi oleh pemilihan nilai K .

3) Algoritma sensitif terhadap perbedaan skala antarfitur.

4) Fitur yang tidak relevan dapat mengurangi ketepatan perhitungan jarak.

5) KNN membutuhkan ruang penyimpanan lebih besar karena seluruh data latih disimpan.

Normalisasi atau standardisasi data perlu dilakukan sebelum penerapan KNN agar fitur dengan rentang nilai besar tidak mendominasi perhitungan jarak. Parameter model KNN ditunjukkan di tabel 12.

Tabel 12. Parameter Model KNN

Parameter	Nilai	Penjelasan
n_neighbors	5	Jumlah tetangga terdekat yang digunakan untuk menentukan kelas
weights	distance	Tetangga yang lebih dekat memperoleh bobot lebih besar
metric	minkowski	Metode yang digunakan untuk menghitung jarak antar-data
n_jobs	-1	Menggunakan seluruh inti prosesor yang tersedia untuk mempercepat komputasi

Penjelasan Parameter

Parameter $n_neighbors=5$ berarti model menggunakan lima tetangga terdekat sebagai dasar penentuan kelas. Nilai K yang terlalu kecil dapat membuat model sensitif terhadap noise, sedangkan nilai K yang terlalu besar dapat menyebabkan batas antar-kelas menjadi terlalu umum.

Parameter $weights='distance'$ memberikan bobot lebih besar kepada tetangga yang jaraknya lebih dekat. Secara umum, bobot dapat dirumuskan sebagai:

$$w_i = \frac{1}{d_i}$$

Keterangan:

- w_i adalah bobot tetangga ke- i ;
- d_i adalah jarak antara data baru dan tetangga ke- i .

Semakin kecil jarak suatu tetangga, semakin besar pengaruhnya terhadap hasil prediksi.

Parameter `metric='minkowski'` menunjukkan bahwa jarak antar-data dihitung menggunakan metrik Minkowski.

Rumusnya adalah:

$$d(x, x') = \left(\sum_{j=1}^m |x_j - x'_j|^p \right)^{1/p}$$

Pada pengaturan standar dengan $p = 2$, metrik Minkowski setara dengan **Euclidean distance**.

Parameter `n_jobs=-1` digunakan agar proses pencarian tetangga dapat memanfaatkan seluruh inti prosesor yang tersedia.

Secara keseluruhan, KNN digunakan karena memiliki mekanisme klasifikasi yang sederhana dan mampu menangani pola data non-linear. Kinerjanya sangat bergantung pada pemilihan nilai K , metode pembobotan, metrik jarak, serta proses normalisasi fitur.

SVM Linear digunakan untuk menguji efektivitas hyperplane linear pada fitur hasil ekstraksi CNN. Parameter yang digunakan adalah **C = 1.0**. **SVM RBF** digunakan untuk menangani kemungkinan batas keputusan non-linear dengan parameter **C = 10.0** dan **gamma = scale**. Kedua varian SVM ini relevan karena fitur CNN yang telah direduksi PCA tetap berada dalam ruang fitur berdimensi tinggi.

Random Forest digunakan sebagai pembanding berbasis ensemble decision trees. Parameter yang digunakan adalah **n_estimators = 200**, **max_depth = None**, **min_samples_split = 2**, **random_state = 42**, dan **n_jobs = -1**. Random Forest relevan karena robust terhadap overfitting, mampu menangani data non-linear, dan dapat memberikan informasi feature importance .

KNN digunakan sebagai model berbasis kemiripan tetangga terdekat. Parameter yang digunakan adalah **n_neighbors = 5**, **weights = distance**, **metric = minkowski**, dan **n_jobs = -1**. KNN sederhana dan intuitif, tetapi memiliki kelemahan berupa komputasi prediksi yang lebih lambat pada dataset besar .

4.9 Framework Perbandingan Model

Framework perbandingan menggunakan matriks 3×4 , yaitu tiga CNN backbone dikombinasikan dengan empat model Machine Learning. Dengan demikian, terdapat 12 kombinasi yang diuji. CNN backbone berperan sebagai variabel independen pertama, sedangkan model Machine Learning berperan sebagai variabel independen kedua. Variabel dependen meliputi accuracy, F1-score macro, precision macro, recall macro, dan cross-validation score. Variabel **kontrol meliputi dimensi PCA sebesar 128 komponen, test size 20%, random state 42, dan image size 224×224**.

Alur eksperimen dilakukan dalam enam tahap sebagai berikut:

1. Augmentasi dataset hingga mencapai 300 citra per kelas.
2. Memuat CNN pre-trained tanpa top layer.
3. Ekstraksi fitur untuk seluruh dataset menggunakan setiap CNN.
4. Penerapan PCA untuk reduksi dimensi menjadi 128 komponen.
5. Training empat model Machine Learning pada setiap set fitur CNN.
6. Evaluasi dan perbandingan 12 kombinasi model .

Framework perbandingan digunakan untuk mengevaluasi kinerja beberapa kombinasi model ekstraksi fitur berbasis CNN dan algoritma machine learning. Setiap CNN digunakan sebagai pengestraksi fitur, sedangkan model machine learning digunakan untuk melakukan klasifikasi. Penelitian ini membandingkan tiga arsitektur CNN, yaitu **VGG16**, **ResNet50**, dan **MobileNetV2**, dengan empat algoritma klasifikasi, yaitu **SVM Linear**, **SVM RBF**, **Random Forest**, dan **K-Nearest Neighbors**. Kombinasi tersebut menghasilkan 12 model yang diuji menggunakan prosedur eksperimen yang sama.

4.9.1 Matriks Perbandingan Model

Matriks perbandingan disusun untuk memastikan bahwa setiap CNN diuji dengan seluruh algoritma machine learning yang ditunjukkan di tabel 13.

Tabel 13. Matrik perbandingan untuk Algoritm Machine Learning yang diuji berdasarkan CNN Backbone

CNN Backbone	SVM Linear	SVM RBF	Random Forest	KNN
VGG16	VGG16 + SVM Linear	VGG16 + SVM RBF	VGG16 + Random Forest	VGG16 + KNN
ResNet50	ResNet50 + SVM Linear	ResNet50 + SVM RBF	ResNet50 + Random Forest	ResNet50 + KNN
MobileNetV2	MobileNetV2 + SVM Linear	MobileNetV2 + SVM RBF	MobileNetV2 + Random Forest	MobileNetV2 + KNN

Dengan rancangan tersebut, jumlah kombinasi model dapat dihitung sebagai:

$$3 \text{ CNN} \times 4 \text{ model machine learning} = 12 \text{ kombinasi}$$

Setiap kombinasi menggunakan fitur yang dihasilkan oleh CNN tertentu. Sebagai contoh, model **VGG16 + SVM Linear** menggunakan VGG16 untuk mengekstraksi fitur citra, kemudian fitur tersebut diklasifikasikan menggunakan SVM dengan kernel linear.

4.9.2 Variabel Penelitian

Variabel penelitian dibagi menjadi tiga kelompok, yaitu variabel independen, variabel dependen, dan variabel kontrol.

4.9.2.1 Variabel Independen

Variabel independen merupakan komponen yang sengaja diubah untuk mengetahui pengaruhnya terhadap kinerja model.

Kelompok	Variabel yang diuji
CNN backbone	VGG16, ResNet50, dan MobileNetV2
Model machine learning	SVM Linear, SVM RBF, Random Forest, dan KNN

CNN backbone berfungsi sebagai pengekstraksi fitur citra. Perbedaan arsitektur CNN dapat menghasilkan representasi fitur yang berbeda. Model machine learning kemudian menggunakan fitur tersebut untuk menentukan kelas citra.

4.9.2.2 Variabel Dependen

Variabel dependen merupakan hasil yang diukur untuk menilai kinerja setiap kombinasi model.

Metrik	Fungsi
Akurasi	Mengukur proporsi seluruh prediksi yang benar
Precision macro	Mengukur ketepatan prediksi pada seluruh kelas
Recall macro	Mengukur kemampuan model mengenali seluruh kelas
F1-score macro	Mengukur keseimbangan antara precision dan recall
Cross-validation score	Mengukur kestabilan model pada beberapa pembagian data

Penggunaan macro average memastikan bahwa setiap kelas memiliki bobot penilaian yang sama, termasuk kelas dengan jumlah data yang lebih sedikit.

4.9.2.3 Variabel Kontrol

Variabel kontrol dibuat tetap agar perbandingan antarmodel berlangsung secara adil.

Variabel kontrol	Nilai
Dimensi hasil PCA	128 komponen
Proporsi data uji	20%
Proporsi data latih	80%
Random state	42
Ukuran citra	224 × 224 piksel
Jumlah citra per kelas setelah augmentasi	300 citra

Dimensi PCA ditetapkan sebanyak 128 komponen untuk menyamakan jumlah fitur yang digunakan oleh seluruh model machine learning. Ukuran citra, proporsi data, dan random state juga dibuat sama agar perbedaan hasil lebih mencerminkan pengaruh kombinasi CNN dan model klasifikasi.

4.10 Alur Eksperimen

Eksperimen dilakukan melalui enam tahap utama, mulai dari penyiapan dataset hingga evaluasi seluruh kombinasi model yang ditunjukkan di tabel 14.

Tabel 14. Tahapan eksperimen dari Penelitian yang dilakukan

Tahap	Deskripsi
Tahap 1	Melakukan augmentasi data hingga setiap kelas memiliki 300 citra, dengan total 5.100 citra
Tahap 2	Memuat model CNN pre-trained VGG16, ResNet50, dan MobileNetV2 tanpa lapisan klasifikasi akhir
Tahap 3	Mengekstraksi fitur seluruh citra menggunakan masing-masing CNN
Tahap 4	Mereduksi dimensi fitur menggunakan PCA menjadi 128 komponen
Tahap 5	Melatih empat model machine learning pada setiap set fitur CNN
Tahap 6	Mengevaluasi dan membandingkan seluruh 12 kombinasi model

Tahap 1: Augmentasi Dataset

Augmentasi dilakukan untuk menambah variasi data latih dan menyetarakan jumlah citra pada setiap kelas. Setelah augmentasi, setiap kelas memiliki 300 citra sehingga total dataset menjadi 5.100 citra. Augmentasi dapat mencakup rotasi, pergeseran, pembalikan, perubahan skala, atau transformasi lain yang tidak mengubah identitas objek utama.

Tahap 2: Memuat CNN Pre-trained

Tiga arsitektur CNN, yaitu VGG16, ResNet50, dan MobileNetV2, digunakan sebagai model pre-trained. Lapisan klasifikasi akhir atau *top layer* dihilangkan karena CNN hanya digunakan untuk mengekstraksi fitur.

Bobot awal model berasal dari proses pelatihan pada dataset besar sehingga CNN telah memiliki kemampuan mengenali pola visual dasar, seperti tepi, bentuk, warna, dan tekstur.

Tahap 3: Ekstraksi Fitur

Setiap citra diproses menggunakan masing-masing CNN untuk menghasilkan representasi fitur. Dengan demikian, diperoleh tiga set fitur yang berbeda:

- fitur VGG16;
- fitur ResNet50;
- fitur MobileNetV2.

Set fitur tersebut kemudian digunakan sebagai masukan bagi model machine learning.

Tahap 4: Reduksi Dimensi Menggunakan PCA

Fitur yang dihasilkan CNN umumnya memiliki dimensi tinggi. Principal Component Analysis digunakan untuk mereduksi dimensi fitur menjadi 128 komponen utama.

Reduksi dimensi bertujuan untuk:

- mengurangi beban komputasi;
- menghilangkan sebagian informasi yang redundan;
- mempercepat pelatihan model;
- menyamakan dimensi fitur dari seluruh CNN.

PCA harus dipelajari hanya menggunakan data latih, kemudian transformasi yang sama diterapkan pada data validasi dan data uji untuk mencegah kebocoran data.

Tahap 5: Pelatihan Model Machine Learning

Setiap set fitur CNN digunakan untuk melatih empat model machine learning, yaitu:

1. SVM Linear;
2. SVM RBF;
3. Random Forest;
4. KNN.

Tahap ini menghasilkan 12 kombinasi model. Seluruh model dilatih menggunakan data dan prosedur evaluasi yang sama agar hasilnya dapat dibandingkan secara objektif.

Tahap 6: Evaluasi dan Perbandingan Model

Setiap kombinasi dievaluasi menggunakan akurasi, precision macro, recall macro, F1-score macro, dan cross-validation score.

Model terbaik tidak hanya ditentukan berdasarkan akurasi tertinggi. Penilaian juga mempertimbangkan:

- keseimbangan precision dan recall;
- kestabilan hasil cross-validation;
- konsistensi kinerja antar-kelas;
- waktu komputasi;
- kompleksitas model.

Secara keseluruhan, framework ini dirancang untuk menjawab dua pertanyaan utama. Pertama, arsitektur CNN mana yang menghasilkan fitur paling informatif. Kedua, algoritma machine learning mana yang paling sesuai untuk mengklasifikasikan fitur tersebut. Kombinasi dengan kinerja paling tinggi dan stabil dipilih sebagai model terbaik

4.11 Metrik Evaluasi

Evaluasi performa model dilakukan menggunakan beberapa metrik, yaitu **accuracy**, **precision**, **recall**, **F1-score**, dan **cross-validation score**. Accuracy digunakan untuk mengukur proporsi prediksi benar terhadap total data. Precision digunakan untuk mengukur proporsi prediksi positif yang benar. Recall digunakan untuk mengukur proporsi data aktual positif yang berhasil dikenali model. F1-score digunakan sebagai harmonic mean antara precision dan recall .

Kinerja setiap model klasifikasi dievaluasi menggunakan empat metrik utama, yaitu **akurasi**, **precision**, **recall**, dan **F1-score**. Selain itu, digunakan **5-fold stratified cross-validation** untuk menilai kestabilan model pada beberapa pembagian data.

Sebelum memahami setiap metrik, terdapat empat istilah dasar dalam evaluasi klasifikasi:

- **True Positive (TP)**: data positif yang diprediksi positif dengan benar.
- **True Negative (TN)**: data negatif yang diprediksi negatif dengan benar.
- **False Positive (FP)**: data negatif yang salah diprediksi sebagai positif.
- **False Negative (FN)**: data positif yang salah diprediksi sebagai negatif.

4.11.1 Akurasi

Akurasi menunjukkan proporsi seluruh prediksi yang benar dibandingkan dengan jumlah keseluruhan data.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

Nilai akurasi yang tinggi menunjukkan bahwa sebagian besar data berhasil diklasifikasikan dengan benar. Namun, akurasi perlu digunakan secara hati-hati apabila jumlah data pada setiap kelas tidak seimbang.

Sebagai contoh, apabila model menghasilkan 90 prediksi benar dari 100 data, nilai akurasinya adalah 90%.

4.11.2 Precision

Precision menunjukkan seberapa banyak prediksi positif yang benar-benar termasuk kelas positif.

$$\text{Precision} = \frac{TP}{TP + FP}$$

Precision penting ketika kesalahan berupa **false positive** perlu diminimalkan. Semakin tinggi precision, semakin sedikit data negatif yang salah diklasifikasikan sebagai positif.

Sebagai contoh, apabila model memberikan 50 prediksi positif dan hanya 40 di antaranya benar, nilai precision adalah:

$$\frac{40}{50} = 0,80$$

Artinya, 80% prediksi positif yang dihasilkan model merupakan prediksi yang benar.

Pada klasifikasi multikelas, precision dihitung untuk setiap kelas, kemudian dirata-ratakan menggunakan metode **macro average**:

$$\text{Precision}_{macro} = \frac{1}{C} \sum_{c=1}^C \text{Precision}_c$$

Keterangan C menunjukkan jumlah kelas.

4.11.3 Recall

Recall atau sensitivity menunjukkan kemampuan model dalam menemukan seluruh data yang sebenarnya termasuk kelas positif.

$$\text{Recall} = \frac{TP}{TP + FN}$$

Recall penting ketika kesalahan berupa **false negative** perlu diminimalkan. Semakin tinggi recall, semakin banyak data positif yang berhasil dikenali oleh model.

Sebagai contoh, apabila terdapat 50 data positif dan model berhasil mengenali 45 di antaranya, nilai recall adalah:

$$\frac{45}{50} = 0,90$$

Artinya, model berhasil mengenali 90% dari seluruh data positif.

Pada klasifikasi multikelas, recall dihitung untuk setiap kelas, kemudian dirata-ratakan menggunakan **macro average**:

$$\text{Recall}_{macro} = \frac{1}{C} \sum_{c=1}^C \text{Recall}_c$$

4.11.4 F1-Score

F1-score merupakan rata-rata harmonik antara precision dan recall. Metrik ini digunakan untuk menilai keseimbangan antara kemampuan model dalam menghasilkan prediksi positif yang tepat dan menemukan seluruh data positif.

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-score akan tinggi apabila precision dan recall sama-sama tinggi. Metrik ini lebih informatif daripada akurasi ketika distribusi jumlah data antar-kelas tidak seimbang.

Sebagai contoh, apabila precision sebesar 0,80 dan recall sebesar 0,90, maka:

$$F1 = 2 \times \frac{0,80 \times 0,90}{0,80 + 0,90} = 0,847$$

Nilai F1-score tersebut menunjukkan bahwa model memiliki keseimbangan kinerja yang cukup baik antara precision dan recall.

Pada klasifikasi multikelas, F1-score dapat dihitung untuk setiap kelas dan kemudian dirata-ratakan menggunakan **macro average**.

5.12 Stratified Cross-Validation

Cross-validation digunakan untuk mengevaluasi kestabilan dan kemampuan generalisasi model. Dalam penelitian ini digunakan **5-fold stratified cross-validation** pada data pelatihan.

Data pelatihan dibagi menjadi lima bagian atau *fold* dengan proporsi kelas yang tetap seimbang pada setiap bagian. Proses evaluasi dilakukan sebanyak lima kali. Pada setiap proses, empat bagian digunakan untuk melatih model dan satu bagian digunakan untuk validasi.

Ilustrasi pembagiannya adalah sebagai berikut:

Iterasi	Data pelatihan	Data validasi
1	Fold 2, 3, 4, dan 5	Fold 1
2	Fold 1, 3, 4, dan 5	Fold 2
3	Fold 1, 2, 4, dan 5	Fold 3
4	Fold 1, 2, 3, dan 5	Fold 4
5	Fold 1, 2, 3, dan 4	Fold 5

Nilai akhir cross-validation diperoleh dengan menghitung rata-rata skor dari seluruh fold:

$$CV_{\text{score}} = \frac{score_1 + score_2 + score_3 + score_4 + score_5}{5}$$

Apabila metrik yang digunakan adalah akurasi, rumusnya menjadi:

$$CV_{\text{accuracy}} = \frac{acc_1 + acc_2 + acc_3 + acc_4 + acc_5}{5}$$

Selain nilai rata-rata, simpangan baku juga sebaiknya dilaporkan untuk menunjukkan kestabilan model:

$$SD = \sqrt{\frac{\sum_{i=1}^5 (score_i - \bar{score})^2}{5 - 1}}$$

Nilai rata-rata yang tinggi menunjukkan kinerja model yang baik, sedangkan simpangan baku yang kecil menunjukkan bahwa kinerja model relatif konsisten pada berbagai pembagian data.

Secara keseluruhan, akurasi memberikan gambaran umum mengenai jumlah prediksi yang benar, precision menilai ketepatan prediksi positif, recall mengukur kemampuan menemukan data positif, dan F1-score menilai keseimbangan antara precision dan recall. Cross-validation digunakan untuk memastikan bahwa hasil evaluasi tidak bergantung pada satu pembagian data saja

Seluruh metrik dihitung menggunakan rata-rata **macro**, sehingga setiap kelas mendapat bobot yang sama. Ini penting karena klasifikasi tanaman obat melibatkan banyak kelas dan potensi ketidakseimbangan data. Penggunaan macro average membantu menghindari bias terhadap kelas mayoritas.

Selain itu, dilakukan **5-Fold Stratified Cross-Validation** pada data training untuk menguji robustness model. Cross-validation membagi data training menjadi lima bagian, menggunakan empat bagian untuk training dan satu bagian untuk validasi secara bergantian. Model dianggap lebih stabil apabila standar deviasi cross-validation rendah.

5.11 Kriteria Keberhasilan Model

Model dianggap berhasil apabila memenuhi beberapa kriteria. Pertama, akurasi data testing minimal **90%**. Kedua, F1-score minimal **0,90**. Ketiga, selisih akurasi training dan testing tidak lebih dari **10%**, sehingga model tidak menunjukkan gejala overfitting yang berlebihan. Keempat, standar deviasi cross-validation tidak lebih dari **5%**, sehingga model dapat dianggap stabil .

Model terbaik ditentukan melalui F1-score tertinggi pada data pengujian. Jika nilainya setara, pemilihan mempertimbangkan akurasi dan stabilitas *cross-validation* demi keseimbangan *precision* dan *recall* yang optimal.

4.12 Pengujian Hipotesis Berdasarkan Hasil Eksperimen

Berdasarkan hasil penelitian, pengujian hipotesis dapat dirangkum sebagai berikut (tabel 15).

Tabel 15 Hasil pengujian Hipotesis

Hipotesis	Pernyataan	Dasar Evaluasi	Status
H1	ResNet50 menghasilkan fitur lebih diskriminatif dibandingkan VGG16 dan MobileNetV2	Rata-rata akurasi ResNet50 97,52%, tertinggi dibanding MobileNetV2 96,60% dan VGG16 94,29%	Diterima
H2	SVM memberikan performa lebih baik dibandingkan Random Forest dan KNN	SVM Linear 98,66% dan SVM RBF 98,43%, lebih tinggi dari RF 96,44% dan KNN 91,01%	Diterima
H3	Kombinasi CNN+ML dapat mencapai akurasi di atas 95%	Kombinasi terbaik 99,31%; sebagian besar kombinasi SVM/RF >95%, tetapi KNN tidak semuanya >95%	Diterima terbatas

H1 dan H2 diterima kuat. H3 diterima terbatas karena hanya kombinasi CNN dengan SVM dan Random Forest yang melampaui akurasi 95%, sedangkan performa CNN dengan KNN lebih rendah dan tidak mencapai ambang batas tersebut.

Deskripsi kerja Tim Peneliti

Tahapan	Penanggung Jawab	Tugas
Data Collection	Ketua	Pengumpulan & validasi dataset
Preprocessing	Anggota 1	Cleaning & normalisasi data
Feature Extraction	Anggota 2	CNN & feature engineering
Modeling	Ketua & Anggota 2	Random Forest, SVM, KNN
Evaluasi	Anggota 3	Analisis performa
Penulisan	Semua	Publikasi ilmiah

Luaran dan Target Capaian

Tahap	Luaran	Indikator
Data	Dataset multimodal	Valid $\geq 95\%$
Model	ML & DL baseline	Akurasi $\geq 85\%$
Multimodal	Model fusion	Peningkatan $\geq 3\%$
Publikasi	Jurnal SINTA 4 atau SINTA 3	1 artikel

BAB V

HASIL DAN PEMBAHASAN

Penelitian ini menganalisis perbandingan performa berbagai model *Machine Learning* (ML) dengan ekstraksi fitur CNN (*Convolutional Neural Network*) untuk klasifikasi 17 jenis tanaman obat Indonesia. Dataset terdiri dari 5.100 citra (setelah augmentasi) yang diekstraksi fiturnya menggunakan 3 arsitektur CNN pre-trained (VGG16, ResNet50, MobileNetV2) dan diklasifikasikan menggunakan 4 model *Machine Learning*.

5.1 Analisis Perbandingan Model Machine learning Dan Deep learning - Klasifikasi Tanaman Obat

Analisis perbandingan anatar model Machine learning dan Deep learning klasifikasi tanaman obat ditunjukkan di tabel 16.

Tabel 16 Hasil Utama Perbandingan Model CNN dan Machine Learning

Peringkat	Ekstraktor Fitur CNN	Model Machine Learning	Akurasi	F1-Score	Keterangan
1	ResNet50	SVM Linear	99,31%	0,9931	Model terbaik dengan performa paling tinggi.
2	ResNet50	SVM RBF	98,82%	0,9883	Performa sangat tinggi dan mendekati SVM Linear.
3	MobileNetV2	SVM RBF	98,73%	0,9873	Model ringan dengan performa sangat kompetitif.
4	MobileNetV2	SVM Linear	98,53%	0,9853	Performa tinggi dengan arsitektur CNN yang efisien.
5	VGG16	SVM Linear	98,14%	0,9815	VGG16 tetap kompetitif sebagai baseline CNN.
6	VGG16	SVM RBF	97,75%	0,9780	Performa baik dengan kernel non-linear.
7	ResNet50	Random Forest	97,06%	0,9706	Performa baik, tetapi masih di bawah SVM.
8	VGG16	Random Forest	96,47%	0,9645	Cukup stabil pada fitur hasil ekstraksi CNN.
9	MobileNetV2	Random Forest	95,78%	0,9576	Masih mencapai akurasi di atas 95%.
10	ResNet50	KNN	94,90%	0,9499	Performa cukup baik, tetapi belum mencapai 95%.
11	MobileNetV2	KNN	93,33%	0,9344	Performa menurun dibanding SVM dan Random Forest.
12	VGG16	KNN	84,80%	0,8489	Performa terendah di antara seluruh kombinasi.

Berdasarkan hasil pengujian, kombinasi **ResNet50 + SVM Linear** menghasilkan performa terbaik dengan akurasi **99,31%** dan F1-score **0,9931**. Hasil ini menunjukkan bahwa fitur yang diekstraksi menggunakan ResNet50 sangat efektif ketika diklasifikasikan menggunakan SVM Linear.

Secara umum, model berbasis **SVM** memberikan performa paling tinggi dibandingkan Random Forest dan KNN. SVM Linear dan SVM RBF menempati enam peringkat teratas pada semua arsitektur CNN, yaitu ResNet50, MobileNetV2, dan VGG16. Hal ini menunjukkan bahwa SVM sangat sesuai digunakan untuk mengklasifikasikan fitur hasil ekstraksi CNN.

Random Forest juga menunjukkan performa yang cukup baik, dengan akurasi berada pada rentang **95,78% sampai 97,06%**. Sementara itu, KNN menghasilkan performa paling rendah, terutama pada kombinasi **VGG16 + KNN** yang hanya mencapai akurasi **84,80%**.

Dengan demikian, hasil utama penelitian menunjukkan bahwa pendekatan **CNN sebagai ekstraktor fitur** dan **SVM sebagai classifier** merupakan kombinasi paling efektif untuk klasifikasi citra tanaman obat. Kombinasi terbaik yang direkomendasikan adalah **ResNet50 + SVM Linear**.

5.2. Desain Penelitian

5.2.1 Arsitektur Pipeline

Penelitian ini menggunakan pendekatan **transfer learning** untuk klasifikasi citra tanaman obat. Transfer learning digunakan dengan memanfaatkan model CNN yang sudah dilatih sebelumnya pada dataset besar, kemudian digunakan kembali untuk mengekstraksi fitur citra tanaman obat.

Secara umum, pipeline penelitian terdiri atas tiga tahap utama:

1. **Augmentasi dataset**

Tahap ini dilakukan untuk menambah variasi citra dan menyeimbangkan jumlah data pada setiap kelas tanaman obat.

2. **Ekstraksi fitur menggunakan CNN pre-trained**

Citra tanaman obat diproses menggunakan tiga arsitektur CNN, yaitu **VGG16**, **ResNet50**, dan **MobileNetV2**. Ketiga model tersebut digunakan sebagai ekstraktor fitur.

3. **Reduksi dimensi dan klasifikasi**

Fitur hasil ekstraksi CNN direduksi menggunakan **Principal Component Analysis (PCA)**, kemudian diklasifikasikan menggunakan model **Machine Learning**.

Dengan alur tersebut, CNN berperan sebagai **pengambil fitur citra**, sedangkan model Machine Learning berperan sebagai **classifier** untuk menentukan kelas tanaman obat.

5.2.2 Dataset

Dataset yang digunakan dalam penelitian ini merupakan kumpulan foto tanaman obat Indonesia. Dataset terdiri atas **17 jenis tanaman obat** dengan jumlah citra asli sebanyak **2.940 citra**.

Setelah dilakukan augmentasi, jumlah citra meningkat menjadi **5.100 citra**, dengan target sekitar **300 citra untuk setiap kelas (tabel 17)**.

Tabel 17. Deskripsi Dataset

No.	Aspek Dataset	Keterangan
1	Sumber Data	Folder dataset D:\Dewi_Agent berisi foto tanaman obat Indonesia
2	Jumlah Kelas	17 jenis tanaman obat
3	Total Citra Original	2.940 citra
4	Total Citra Setelah Augmentasi	5.100 citra
5	Target Jumlah Citra per Kelas	300 citra per kelas
6	Pembagian Data	80% data training dan 20% data testing

Dataset penelitian terdiri atas 17 kelas tanaman obat Indonesia. Jumlah citra asli sebanyak 2.940 citra, kemudian ditingkatkan menjadi 5.100 citra melalui proses augmentasi. Augmentasi dilakukan agar jumlah data setiap kelas lebih seimbang dan model memiliki kemampuan generalisasi yang lebih baik.

5.2.3 Jenis Augmentasi Data

Augmentasi data dilakukan untuk memperbanyak variasi citra tanaman obat. Proses ini penting karena model perlu mengenali tanaman dalam berbagai kondisi visual, seperti perbedaan posisi, arah, pencahayaan, ketajaman, dan warna.

Teknik augmentasi yang digunakan dikelompokkan menjadi empat kategori utama, yaitu **geometric**, **photometric**, **filter**, serta **noise dan color**. Jenis Augmentasi data diberikan di tabel 18.

Tabel 18 Jenis Augmentasi Data

No.	Kategori Augmentasi	Teknik yang Digunakan	Penjelasan
1	Geometric	Flip Horizontal	Membalik citra dari kiri ke kanan.
2	Geometric	Flip Vertical	Membalik citra dari atas ke bawah.
3	Geometric	Rotasi	Memutar citra sebesar 90°, 180°, atau 270°.
4	Geometric	Crop Center	Memotong bagian tengah citra, kemudian menyesuaikan kembali ukuran gambar.
5	Photometric	Brightness Up/Down	Meningkatkan atau menurunkan tingkat kecerahan citra.
6	Photometric	Contrast Up/Down	Meningkatkan atau menurunkan kontras citra.
7	Photometric	Sharpness Up/Down	Meningkatkan atau menurunkan ketajaman citra.
8	Filter	Gaussian Blur	Memberikan efek blur pada citra.
9	Filter	Sharpen	Menajamkan citra menggunakan filter penajaman.

10	Noise & Color	Gaussian Noise	Menambahkan noise acak pada citra.
11	Noise & Color	Color Shift	Mengubah komposisi warna citra.
12	Noise & Color	Gamma Correction	Menyesuaikan intensitas pencahayaan citra.

Augmentasi data dilakukan untuk memperkaya variasi citra dan mengurangi risiko overfitting. Teknik augmentasi yang digunakan mencakup transformasi geometrik, seperti flip, rotasi, dan crop center; penyesuaian visual, seperti brightness, contrast, dan sharpness; penggunaan filter, seperti Gaussian blur dan sharpen; serta perubahan noise dan warna melalui Gaussian noise, color shift, dan gamma correction. Proses ini membantu model belajar dari variasi citra yang lebih beragam sehingga performa klasifikasi menjadi lebih stabil.

5.3. Ekstraksi Fitur CNN

5.3.1 Arsitektur CNN yang Digunakan

Pada penelitian ini, proses ekstraksi fitur dilakukan menggunakan tiga arsitektur CNN pre-trained, yaitu **VGG16**, **ResNet50**, dan **MobileNetV2**. Ketiga model tersebut digunakan tanpa lapisan klasifikasi akhir atau *top layer*, sehingga berfungsi sebagai **ekstraktor fitur citra**, bukan sebagai classifier utama. Setiap arsitektur menghasilkan dimensi fitur awal yang berbeda. Fitur tersebut kemudian direduksi menggunakan **Principal Component Analysis (PCA)** menjadi **128 komponen** agar lebih ringkas dan efisien untuk digunakan pada model Machine Learning (ditunjukkan di tabel 19).

Tabel 19 Arsitektur CNN yang Digunakan

No.	Model CNN	Karakteristik Arsitektur	Dimensi Fitur Awal	Dimensi Setelah PCA	Variance Explained
1	VGG16	Arsitektur CNN klasik dengan 16 layer, dikembangkan oleh Oxford	25.088 fitur atau $512 \times 7 \times 7$	128 komponen	91,85%
2	ResNet50	Arsitektur CNN 50 layer dengan residual connection, dikembangkan oleh Microsoft	100.352 fitur atau $2048 \times 7 \times 7$	128 komponen	86,52%
3	MobileNetV2	Arsitektur CNN ringan berbasis inverted residual, dikembangkan oleh Google	62.720 fitur atau $1280 \times 7 \times 7$	128 komponen	±85%

VGG16 digunakan sebagai baseline karena memiliki arsitektur klasik yang stabil. ResNet50 digunakan karena memiliki residual connection yang mampu menghasilkan fitur visual lebih kuat dan diskriminatif. MobileNetV2 digunakan sebagai model ringan yang efisien dari sisi komputasi. Ketiga arsitektur tersebut menghasilkan fitur berdimensi tinggi, sehingga diperlukan reduksi dimensi menggunakan PCA menjadi 128 komponen agar proses klasifikasi menjadi lebih efisien.

5.3.2 Proses Ekstraksi Fitur


Proses ekstraksi fitur dilakukan untuk mengubah citra tanaman obat menjadi representasi numerik yang dapat diproses oleh model Machine Learning. Tahapan ekstraksi fitur dalam penelitian ini adalah sebagai berikut (tabel 20).

Tabel 20. Tahapan Proses Ekstraksi data

No.	Tahapan	Penjelasan
1	Load model CNN pre-trained	Model VGG16, ResNet50, dan MobileNetV2 dimuat dengan bobot ImageNet dan tanpa top layer.
2	Input citra	Setiap citra tanaman obat dimasukkan ke model CNN dengan ukuran $224 \times 224 \times 3$.
3	Forward pass	Citra diproses melalui layer CNN untuk menghasilkan representasi fitur visual.
4	Global Average Pooling	Dimensi spasial feature map diringkas agar fitur lebih padat dan mudah diproses.
5	Reduksi dimensi PCA	Fitur berdimensi tinggi direduksi menjadi 128 komponen utama.
6	Standard Scaling	Fitur distandarisasi agar memiliki skala yang seragam sebelum digunakan untuk training model ML.
7	Output fitur	Hasil akhir berupa feature vector 128 dimensi yang siap digunakan untuk klasifikasi.

Proses ekstraksi fitur dimulai dengan memuat model CNN pre-trained, yaitu VGG16, ResNet50, dan MobileNetV2, menggunakan bobot ImageNet tanpa top layer. Setiap citra tanaman obat yang telah berukuran $224 \times 224 \times 3$ dimasukkan ke dalam model CNN untuk menghasilkan representasi fitur visual. Fitur yang diperoleh kemudian diringkas menggunakan Global Average Pooling dan direduksi menggunakan PCA menjadi 128 komponen. Setelah itu, fitur distandarisasi menggunakan StandardScaler sebelum digunakan sebagai input pada model Machine Learning. Tahapan ini menghasilkan feature vector yang lebih ringkas, efisien, dan siap digunakan untuk proses klasifikasi tanaman obat.

5.3.3 Visualisasi Feature Space (t-SNE)



Kelas Tanaman Obat:

-  Biji Kembang Kantil
-  Bunga Tapak Dara
-  Daun jambu Biji
-  Daun Kelor
-  Daun Kemangi
-  Daun Sambiloto
-  Daun Sirih

5.4. Model Machine Learning

5.4.1 Model yang Diuji

Pada penelitian ini, fitur citra yang telah diekstraksi menggunakan CNN kemudian diklasifikasikan menggunakan beberapa model **Machine Learning**. Model yang diuji terdiri atas **SVM Linear**, **SVM RBF**, **Random Forest**, dan **K-Nearest Neighbors (KNN)**.

Setiap model dipilih karena memiliki karakteristik yang berbeda. SVM digunakan untuk menguji kemampuan klasifikasi pada fitur berdimensi tinggi, *Random Forest* digunakan sebagai model *ensemble* berbasis pohon keputusan, sedangkan KNN digunakan sebagai model pembandingan berbasis kedekatan jarak antar data. Model pengujian machine learning ditunjukkan di tabel 21.

Tabel 21. Model Machine Learning yang Diuji

No.	Model Machine Learning	Deskripsi Singkat	Hyperparameter Utama
1	SVM Linear	Model Support Vector Machine dengan kernel linear. Cocok untuk fitur yang dapat dipisahkan secara linear.	C = 1.0
2	SVM RBF	Model Support Vector Machine dengan kernel RBF. Cocok untuk menangani pola data non-linear.	C = 10.0, gamma = scale
3	Random Forest	Model ensemble yang menggabungkan banyak decision tree untuk menghasilkan prediksi yang lebih stabil.	n_estimators = 200
4	KNN	Model klasifikasi berbasis kedekatan jarak dengan tetangga terdekat.	k = 5, weights = distance

Model Machine Learning digunakan sebagai classifier setelah proses ekstraksi fitur CNN. SVM Linear dan SVM RBF digunakan untuk menguji kemampuan Support Vector Machine pada fitur hasil ekstraksi CNN. Random Forest digunakan sebagai pembandingan berbasis ensemble decision tree, sedangkan KNN digunakan sebagai pembandingan berbasis kedekatan jarak antar data. Dengan membandingkan keempat model tersebut, penelitian dapat mengetahui classifier mana yang paling sesuai untuk fitur citra tanaman obat.

5.4.2 Hasil Evaluasi Lengkap

Hasil evaluasi menunjukkan bahwa kombinasi **ResNet50 + SVM Linear** memperoleh performa terbaik dengan akurasi **99,31%**, F1-score **0,9931**, precision **0,9932**, dan recall **0,9931**. Hasil ini menunjukkan bahwa fitur yang dihasilkan oleh ResNet50 sangat efektif ketika diklasifikasikan menggunakan SVM Linear (ditunjukkan di tabel 22).

Kombinasi CNN dengan model **SVM** memberikan performa paling tinggi. *Random Forest* masih menunjukkan hasil yang baik, sedangkan KNN memiliki performa paling rendah dibandingkan model lainnya.

Tabel 22. Hasil Evaluasi Model

Peringkat	CNN Backbone	Model ML	Akurasi	F1-Score	Precision	Recall	Keterangan
1	ResNet50	SVM Linear	99,31%	0,9931	0,9932	0,9931	Model terbaik secara keseluruhan.
2	ResNet50	SVM RBF	98,82%	0,9883	0,9888	0,9882	Performa sangat tinggi dan mendekati model terbaik.
3	MobileNetV2	SVM RBF	98,73%	0,9873	0,9877	0,9873	Model ringan dengan performa sangat baik.
4	MobileNetV2	SVM Linear	98,53%	0,9853	0,9856	0,9853	Efisien dan tetap menghasilkan akurasi tinggi.
5	VGG16	SVM Linear	98,14%	0,9815	0,9821	0,9814	VGG16 tetap kompetitif sebagai baseline.
6	VGG16	SVM RBF	97,75%	0,9780	0,9801	0,9775	Performa baik dengan kernel RBF.
7	ResNet50	Random Forest	97,06%	0,9706	0,9718	0,9706	Random Forest cukup baik pada fitur ResNet50.
8	VGG16	Random Forest	96,47%	0,9645	0,9655	0,9647	Performa stabil pada fitur VGG16.
9	MobileNetV2	Random Forest	95,78%	0,9576	0,9587	0,9578	Masih mencapai performa di atas 95%.
10	ResNet50	KNN	94,90%	0,9499	0,9542	0,9490	Cukup baik, tetapi di bawah SVM dan Random Forest.
11	MobileNetV2	KNN	93,33%	0,9344	0,9410	0,9333	Performa menurun pada model KNN.
12	VGG16	KNN	84,80%	0,8489	0,8836	0,8480	Performa paling rendah di antara seluruh kombinasi.

Hasil Evaluasi

Berdasarkan hasil evaluasi, kombinasi **ResNet50 + SVM Linear** menjadi model terbaik karena menghasilkan nilai akurasi, F1-score, precision, dan recall tertinggi. Hal ini menunjukkan bahwa ResNet50 mampu menghasilkan fitur citra yang diskriminatif, sedangkan SVM Linear mampu mengklasifikasikan fitur tersebut secara efektif.

Model SVM secara umum menunjukkan performa terbaik. Enam peringkat teratas ditempati oleh kombinasi CNN dengan **SVM Linear** dan **SVM RBF**. Hal ini menunjukkan bahwa SVM sangat cocok digunakan untuk mengklasifikasikan fitur hasil ekstraksi CNN.

Random Forest juga memberikan hasil yang cukup baik dengan akurasi di atas **95%** pada semua backbone CNN. Namun, performanya masih berada di bawah SVM. Sementara itu, KNN menunjukkan performa paling rendah, terutama pada kombinasi **VGG16 + KNN** dengan akurasi **84,80%**.

Dengan demikian, hasil penelitian menunjukkan bahwa pendekatan **CNN sebagai ekstraktor fitur** dan **SVM sebagai classifier** merupakan kombinasi paling efektif untuk klasifikasi citra tanaman obat.

Model yang paling direkomendasikan adalah **ResNet50 + SVM Linear**.

5.5. Analisis dan Pembahasan

5.5.1 Perbandingan CNN Backbone

Pada penelitian ini, tiga arsitektur CNN digunakan sebagai ekstraktor fitur, yaitu **ResNet50**, **MobileNetV2**, dan **VGG16**. Ketiga model tersebut dibandingkan untuk mengetahui backbone CNN mana yang mampu menghasilkan fitur citra tanaman obat paling baik (ditunjukkan di tabel 22).

Berdasarkan hasil pengujian, rata-rata akurasi untuk setiap CNN backbone adalah sebagai berikut.

Tabel 22. Perbandingan Rata-Rata Akurasi CNN Backbone

No.	CNN Backbone	Rata-Rata Akurasi	Keterangan
1	ResNet50	97,52%	Akurasi tertinggi dan menghasilkan fitur paling diskriminatif.
2	MobileNetV2	96,60%	Performa sangat baik meskipun arsitekturnya lebih ringan.
3	VGG16	94,29%	Masih kompetitif, tetapi berada di bawah ResNet50 dan MobileNetV2.

Hasil tersebut menunjukkan bahwa **ResNet50 menjadi CNN backbone terbaik** dalam penelitian ini. Keunggulan ResNet50 dipengaruhi oleh kedalaman arsitektur dan adanya **residual connection**, sehingga model mampu menghasilkan fitur visual yang lebih kuat. MobileNetV2 juga menunjukkan performa tinggi meskipun dirancang sebagai model ringan. Sementara itu, VGG16 tetap dapat digunakan sebagai baseline, tetapi performanya sedikit lebih rendah dibandingkan arsitektur yang lebih baru.

5.5.2 Analisis Confusion Matrix Model

Confusion matrix digunakan untuk melihat **seberapa tepat model mengklasifikasikan setiap kelas tanaman obat**. Baris pada matriks menunjukkan **kelas sebenarnya** atau *true label*, sedangkan kolom menunjukkan **kelas hasil prediksi model** atau *predicted label*.

Nilai pada diagonal utama menunjukkan jumlah data yang berhasil diklasifikasikan dengan benar. Semakin besar nilai pada diagonal utama, semakin baik performa model. Sebaliknya, nilai di luar diagonal menunjukkan kesalahan klasifikasi, yaitu citra tanaman yang diprediksi sebagai kelas lain.

Pada lampiran terdapat dua jenis matriks:

Jenis Matriks	Fungsi
Confusion Matrix Counts	Menampilkan jumlah data asli yang benar atau salah diklasifikasikan.
Normalized Confusion Matrix	Menampilkan proporsi keberhasilan klasifikasi dalam bentuk nilai 0 sampai 1. Nilai mendekati 1 berarti performa sangat baik.

Penjelasan Per Model

1) VGG16 + Decision Tree (gambar 7)

Model **VGG16 + Decision Tree** menunjukkan performa yang cukup baik, tetapi masih terdapat beberapa kesalahan klasifikasi antar kelas. Pada normalized confusion matrix, beberapa kelas memiliki nilai diagonal yang masih rendah, misalnya sekitar **0,67–0,75** pada kelas tertentu. Hal ini menunjukkan bahwa Decision Tree belum sepenuhnya mampu memanfaatkan fitur hasil ekstraksi VGG16 secara optimal.

Kesalahan prediksi lebih banyak terlihat pada kelas-kelas yang memiliki kemiripan visual, seperti daun-daunan yang memiliki bentuk, warna, atau tekstur serupa. Dengan demikian, Decision Tree dapat digunakan sebagai pembanding, tetapi belum menjadi model paling kuat untuk fitur VGG16.

2) VGG16 + Gradient Boosting (gambar 8)

Model **VGG16 + Gradient Boosting** menunjukkan performa yang lebih baik dibandingkan Decision Tree. Nilai diagonal pada normalized confusion matrix terlihat lebih dominan dan banyak kelas memiliki nilai di atas **0,90**. Artinya, sebagian besar kelas tanaman obat berhasil diklasifikasikan dengan benar.

Gradient Boosting mampu meningkatkan performa karena bekerja secara ensemble, yaitu membangun beberapa model secara bertahap untuk memperbaiki kesalahan model sebelumnya. Pada fitur VGG16, pendekatan ini lebih stabil daripada Decision Tree tunggal.

3) **VGG16 + KNN** (gambar 9)

Model **VGG16 + KNN** menunjukkan performa paling lemah dibandingkan model lainnya. Pada normalized confusion matrix terlihat beberapa nilai diagonal yang rendah, misalnya kelas tertentu hanya mencapai sekitar **0,42**, **0,58**, atau **0,68**. Ini menunjukkan bahwa KNN mengalami kesulitan membedakan beberapa kelas tanaman obat.

Kelemahan ini wajar karena KNN sangat bergantung pada kedekatan jarak antar fitur. Jika fitur hasil ekstraksi VGG16 dari beberapa kelas saling berdekatan, maka KNN mudah salah mengelompokkan citra ke kelas yang mirip. Dengan demikian, KNN kurang optimal digunakan pada fitur VGG16 dibandingkan SVM, Random Forest, atau Gradient Boosting.

4) **VGG16 + Random Forest** (gambar 10)

Model **VGG16 + Random Forest** menunjukkan performa yang sangat baik. Pada normalized confusion matrix, sebagian besar nilai diagonal berada pada rentang tinggi, banyak yang mencapai **0,95–1,00**. Ini berarti Random Forest mampu mengklasifikasikan sebagian besar kelas tanaman obat dengan benar.

Random Forest lebih baik daripada Decision Tree karena menggunakan banyak pohon keputusan dan melakukan proses voting. Hal ini membuat model lebih stabil, lebih tahan terhadap overfitting, dan lebih mampu menangani variasi fitur hasil ekstraksi VGG16.

5) **VGG16 + SVM Linear** (gambar 11)

Model **VGG16 + SVM Linear** menunjukkan performa sangat kuat. Banyak kelas memiliki nilai diagonal mendekati atau sama dengan **1,00**, yang berarti hampir seluruh citra pada kelas tersebut berhasil diprediksi dengan benar.

SVM Linear efektif karena fitur hasil ekstraksi CNN cenderung sudah memiliki representasi yang cukup baik. Ketika fitur antar kelas sudah relatif terpisah, kernel linear dapat membentuk batas keputusan yang kuat dan efisien. Pada model ini, kesalahan klasifikasi terlihat sangat sedikit.

6) **VGG16 + SVM RBF** (gambar 12)

Model **VGG16 + SVM RBF** juga menunjukkan performa sangat baik dan relatif sebanding dengan SVM Linear. Nilai diagonal pada normalized confusion matrix terlihat tinggi pada hampir semua kelas. Kernel RBF membantu model menangani kemungkinan pola non-linear pada fitur hasil ekstraksi VGG16.

Namun, jika dibandingkan dengan SVM Linear, SVM RBF belum tentu selalu lebih unggul. Jika fitur CNN sudah cukup terpisah secara linear, SVM Linear dapat bekerja lebih sederhana dan tetap sangat akurat.

Interpretasi Utama

Dari seluruh confusion matrix VGG16 yang ditampilkan, dapat disimpulkan bahwa:

Model	Interpretasi
SVM Linear	Sangat kuat dan stabil; kesalahan klasifikasi sangat sedikit.
SVM RBF	Sangat baik, mampu menangani pola non-linear.
Random Forest	Performa tinggi dan stabil karena berbasis ensemble.
Gradient Boosting	Lebih baik daripada Decision Tree, cukup kuat sebagai ensemble model.
Decision Tree	Cukup baik, tetapi masih banyak kesalahan pada kelas yang mirip.
KNN	Paling lemah karena sensitif terhadap kedekatan fitur antar kelas.

Berdasarkan confusion matrix untuk fitur hasil ekstraksi VGG16, model SVM Linear dan SVM RBF menunjukkan performa paling baik karena sebagian besar nilai diagonal mendekati 1,00 pada normalized confusion matrix. Hal ini menunjukkan bahwa kedua model mampu membedakan sebagian besar kelas tanaman obat dengan tingkat kesalahan yang rendah. Random Forest dan Gradient Boosting juga menunjukkan performa yang baik, terutama karena keduanya merupakan model ensemble yang mampu meningkatkan stabilitas klasifikasi.

Sebaliknya, KNN menunjukkan performa paling rendah dibandingkan model lainnya. Beberapa kelas memiliki nilai diagonal yang lebih rendah, sehingga menunjukkan adanya kesalahan klasifikasi yang cukup besar. Hal ini mengindikasikan bahwa KNN kurang optimal untuk fitur hasil ekstraksi VGG16, terutama ketika beberapa kelas memiliki kedekatan fitur visual. Decision Tree juga menunjukkan performa yang lebih rendah dibandingkan model ensemble dan SVM karena model tunggal ini lebih rentan terhadap kesalahan pemisahan kelas.

Secara keseluruhan, analisis confusion matrix memperkuat temuan bahwa fitur CNN lebih efektif ketika diklasifikasikan menggunakan SVM atau model ensemble. Untuk fitur VGG16, model yang paling direkomendasikan adalah SVM Linear atau SVM RBF, sedangkan KNN kurang direkomendasikan karena menghasilkan lebih banyak kesalahan klasifikasi.

5.5.3 Perbandingan Model Machine Learning

Setelah fitur citra diekstraksi menggunakan CNN, proses klasifikasi dilakukan menggunakan beberapa model Machine Learning, yaitu **SVM Linear**, **SVM RBF**, **Random Forest**, dan **KNN**. Setiap model dibandingkan berdasarkan rata-rata akurasi dari seluruh CNN backbone.

Tabel Perbandingan Rata-Rata Akurasi Model Machine Learning

No.	Model Machine Learning	Rata-Rata Akurasi	Keterangan
1	SVM Linear	98,66%	Model terbaik dan paling konsisten pada fitur hasil ekstraksi CNN.
2	SVM RBF	98,43%	Performa sangat tinggi dan hampir setara dengan SVM Linear.
3	Random Forest	96,44%	Memberikan performa baik dengan akurasi di atas 95%.
4	KNN	91,01%	Performa paling rendah dibandingkan model lainnya.

SVM Linear menjadi model terbaik yang konsisten unggul pada fitur VGG16, ResNet50, dan MobileNetV2, disusul erat oleh SVM RBF. *Random Forest* tetap bersaing baik (akurasi 96,44%), sementara KNN kurang optimal dan mencatat performa terendah, terutama saat dipadukan dengan VGG16.

5.5.4 Faktor yang Mempengaruhi Performa

Performa model dipengaruhi oleh beberapa faktor utama, yaitu karakteristik CNN backbone, keberadaan residual connection, pemilihan model Machine Learning, dan proses augmentasi data.

Tabel Faktor yang Mempengaruhi Performa Model

No.	Faktor	Pengaruh terhadap Performa
1	Kedalaman CNN	Arsitektur CNN yang lebih dalam mampu menghasilkan fitur visual yang lebih kaya. ResNet50 menunjukkan performa terbaik dibandingkan MobileNetV2 dan VGG16.
2	Residual Connection	Mekanisme residual connection pada ResNet50 membantu aliran informasi dan gradien sehingga fitur yang dihasilkan lebih diskriminatif.
3	Model Machine Learning	SVM paling optimal untuk fitur hasil ekstraksi CNN karena mampu bekerja baik pada fitur berdimensi tinggi.
4	Augmentasi Data	Augmentasi membantu menambah variasi data, meningkatkan generalisasi model, dan mengurangi risiko overfitting.

Hasil analisis menunjukkan bahwa performa klasifikasi dipengaruhi oleh kualitas fitur yang dihasilkan oleh CNN backbone dan kemampuan model Machine Learning dalam mengklasifikasikan fitur tersebut. ResNet50 menghasilkan fitur paling diskriminatif karena memiliki arsitektur yang lebih dalam dan didukung oleh residual connection. Pada sisi classifier, SVM Linear memberikan performa terbaik karena efektif digunakan pada fitur berdimensi tinggi hasil ekstraksi CNN. Selain itu, augmentasi data juga berperan penting dalam meningkatkan variasi citra, membantu generalisasi model, dan mengurangi risiko overfitting. Dengan demikian, kombinasi CNN backbone yang kuat, classifier yang tepat, dan preprocessing data yang baik menjadi faktor utama dalam peningkatan performa klasifikasi tanaman obat.

BAB VI

KESIMPULAN DAN SARAN

6.1 Kesimpulan

Kombinasi CNN sebagai ekstraktor fitur dan *Machine Learning* sebagai *classifier* terbukti memberikan performa terbaik pada klasifikasi 17 kelas tanaman obat Indonesia. Dataset berisi 2.940 citra asli diaugmentasi menjadi 5.100 citra untuk menyeimbangkan data dan mencegah *overfitting*.

Pipeline penelitian menggunakan pendekatan transfer learning dengan tiga arsitektur CNN pre-trained, yaitu VGG16, ResNet50, dan MobileNetV2. Ketiga arsitektur tersebut digunakan tanpa top layer, sehingga berfungsi sebagai ekstraktor fitur citra. VGG16 menghasilkan fitur awal sebesar 25.088, ResNet50 menghasilkan 100.352 fitur awal, sedangkan MobileNetV2 menghasilkan 62.720 fitur awal. Seluruh fitur kemudian direduksi menggunakan Principal Component Analysis (PCA) menjadi 128 komponen agar lebih efisien untuk proses klasifikasi Machine Learning .

Hasil penelitian menunjukkan bahwa ResNet50 menghasilkan fitur paling diskriminatif dibandingkan VGG16 dan MobileNetV2. Rata-rata akurasi berdasarkan CNN backbone menunjukkan bahwa ResNet50 memperoleh hasil tertinggi, yaitu 97,52%, diikuti MobileNetV2 sebesar 96,60%, dan VGG16 sebesar 94,29%. Keunggulan ResNet50 dipengaruhi oleh kedalaman arsitektur dan mekanisme residual connection, yang membantu model menangkap pola visual citra tanaman secara lebih kuat .

Pada sisi classifier, SVM Linear menjadi model Machine Learning terbaik. Rata-rata akurasi per model menunjukkan bahwa SVM Linear mencapai 98,66%, disusul SVM RBF sebesar 98,43%, Random Forest sebesar 96,44%, dan KNN sebesar 91,01%. Hasil ini menunjukkan bahwa SVM sangat sesuai digunakan untuk mengklasifikasikan fitur hasil ekstraksi CNN, terutama karena fitur tersebut berada pada ruang representasi berdimensi tinggi .

Kombinasi model terbaik dalam penelitian ini adalah ResNet50 + SVM Linear, dengan akurasi 99,31% dan F1-score 0,9931. Hasil ini menunjukkan bahwa penggunaan ResNet50 sebagai ekstraktor fitur dan SVM Linear sebagai classifier merupakan konfigurasi paling optimal dalam eksperimen ini. Kombinasi lain yang juga memberikan performa tinggi adalah ResNet50 + SVM RBF, MobileNetV2 + SVM RBF, MobileNetV2 + SVM Linear, dan VGG16 + SVM Linear .

Penelitian membuktikan efektivitas *transfer learning*, reduksi fitur CNN berbasis PCA yang tetap informatif, serta tingginya performa kombinasi fitur CNN dengan pengklasifikasi SVM pada tanaman obat.

Pendekatan CNN sebagai ekstraktor fitur yang dikombinasikan dengan Machine Learning sebagai classifier efektif digunakan untuk klasifikasi citra tanaman obat Indonesia. Dataset yang digunakan terdiri atas 17 kelas tanaman obat, dengan jumlah awal 2.940 citra dan meningkat menjadi 5.100 citra setelah proses augmentasi.

Tiga arsitektur CNN pre-trained, yaitu VGG16, ResNet50, dan MobileNetV2, digunakan untuk mengekstraksi fitur citra. Fitur yang dihasilkan kemudian direduksi menggunakan PCA menjadi 128 komponen sebelum diklasifikasikan menggunakan SVM Linear, SVM RBF, Random Forest, dan KNN. Proses ini membuat fitur citra menjadi lebih ringkas, efisien, dan siap digunakan dalam proses klasifikasi.

ResNet50 menghasilkan fitur paling diskriminatif dibandingkan MobileNetV2 dan VGG16. Rata-rata akurasi ResNet50 mencapai 97,52%, lebih tinggi dibandingkan MobileNetV2 sebesar 96,60% dan VGG16 sebesar 94,29%. Hal ini menunjukkan bahwa mekanisme residual connection pada ResNet50 berperan penting dalam menghasilkan representasi fitur visual yang lebih kuat.

Pada sisi classifier, SVM Linear menjadi model Machine Learning terbaik dengan rata-rata akurasi 98,66%, diikuti SVM RBF sebesar 98,43%, Random Forest sebesar 96,44%, dan KNN sebesar 91,01%. Kombinasi terbaik diperoleh oleh ResNet50 + SVM Linear dengan akurasi 99,31% dan F1-score 0,9931.

Kombinasi ResNet50 dan SVM Linear merupakan konfigurasi paling optimal dalam klasifikasi citra tanaman obat. Hasil ini menjadi *baseline* kuat bagi riset lanjutan bertema *multimodal learning*, *adaptive fusion*, dan *Explainable AI*.

6.2 Saran

Pertama, kualitas dataset harus diperkuat dengan menambahkan citra original dari kondisi nyata—seperti variasi pencahayaan, sudut pandang, dan latar belakang—serta melakukan validasi taksonomi ilmiah bersama ahli botani. Selanjutnya, evaluasi model perlu diperluas menggunakan *confusion matrix* per kelas untuk menganalisis kekeliruan klasifikasi secara mendalam.

Selain itu, keandalan performa model harus diuji melalui skenario validasi yang lebih ketat seperti *k-fold cross-validation*. Guna menghindari *data leakage* yang memicu bias akurasi, proses augmentasi data wajib dilakukan setelah pembagian dataset. Terakhir, judul dan klaim penelitian harus disesuaikan secara jujur dengan eksperimen aktual; istilah "multimodal" tidak boleh diklaim sebagai hasil utama jika integrasi data tabular dan geospasial belum sepenuhnya diimplementasikan.

6.2.1 Saran untuk Riset Berkelanjutan

Untuk pengembangan riset berikutnya, arah penelitian dapat diperluas ke beberapa jalur.

Arah pengembangan riset berikutnya meliputi enam tahapan strategis:

- **Riset *Multimodal Learning***: Mengintegrasikan data citra dengan konteks tanaman berupa atribut tabular (bentuk, manfaat) dan data geospasial (elevasi, cuaca).
- ***Adaptive Feature Fusion***: Menerapkan mekanisme *attention* atau *gated fusion* agar model dapat memprioritaskan kontribusi setiap modalitas secara dinamis.
- ***Explainable AI (XAI)***: Menggunakan Grad-CAM, LIME, atau SHAP untuk transparansi ilmiah keputusan model.
- ***Deployment Model***: Menguji arsitektur ringan MobileNetV2 pada aplikasi *mobile*, web, atau perangkat *edge/IoT* di lapangan.
- **Repositori Digital Terbuka**: Membangun basis data tanaman obat Indonesia yang mencakup citra, metadata, dan atribut botani.
- **Komparasi Arsitektur Mutakhir**: Membandingkan model CNN klasik dengan arsitektur baru seperti EfficientNet, Vision Transformer, atau Swin Transformer

6.2.2 Rekomendasi Akhir

Berdasarkan seluruh hasil penelitian, model yang paling direkomendasikan untuk klasifikasi citra tanaman obat adalah: *ResNet50 + SVM Linear*. Model terbaik meraih akurasi 99,31% (F1-score 0,9931), dengan MobileNetV2 + SVM sebagai alternatif ringan yang efisien. Penelitian berbasis ekstraksi fitur CNN dan ML ini sangat kuat dijadikan *baseline* riset lanjutan bertema *multimodal learning*, *adaptive fusion*, dan *Explainable AI*.

DAFTAR PUSTAKA

- Ahmad, N., Asif, H. M. S., Saleem, G., Younus, M. U., Anwar, S., & Anjum, M. R. (2021). Leaf Image-Based Plant Disease Identification Using Color and Texture Features. *Wireless Personal Communications*, 121(2), 1139–1168. <https://doi.org/10.1007/s11277-021-09054-2>
- Ahmad, T., Khan, I., Irshad, A., Ahmad, S., T. Soliman, A., Abid Gardezi, A., Shafiq, M., & Choi, J.-G. (2022). EfficientNet-Based Robust Recognition of Peach Plant Diseases in Field Images. *Computers, Materials & Continua*, 71(1), 2073–2089. <https://doi.org/10.32604/cmc.2022.018961>
- Alfred, R., Leo, J., & Kaijage, S. F. (2025). Optimizing dataset diversity for a robust deep-learning model in rice blast disease identification to enhance crop health assessment across diverse conditions. *Smart Agricultural Technology*, 10, 100726. <https://doi.org/10.1016/j.atech.2024.100726>

- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M., & Farhan, L. (2021a). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*, 8(1), 53. <https://doi.org/10.1186/s40537-021-00444-8>
- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M., & Farhan, L. (2021b). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*, 8(1), 53. <https://doi.org/10.1186/s40537-021-00444-8>
- Alzubaidi, L., Zhang, J., Humaidi, A. J., Al-Dujaili, A., Duan, Y., Al-Shamma, O., Santamaría, J., Fadhel, M. A., Al-Amidie, M., & Farhan, L. (2021c). Review of deep learning: concepts, CNN architectures, challenges, applications, future directions. *Journal of Big Data*, 8(1). <https://doi.org/10.1186/s40537-021-00444-8>
- Ashwinkumar, S., Rajagopal, S., Manimaran, V., & Jegajothi, B. (2022). Automated plant leaf disease detection and classification using optimal MobileNet based convolutional neural networks. *Materials Today: Proceedings*, 51, 480–487. <https://doi.org/10.1016/j.matpr.2021.05.584>
- Azadnia, R., Noei-Khodabadi, F., Moloudzadeh, A., Jahanbakhshi, A., & Omid, M. (2024). Medicinal and poisonous plants classification from visual characteristics of leaves using computer vision and deep neural networks. *Ecological Informatics*, 82, 102683. <https://doi.org/10.1016/j.ecoinf.2024.102683>
- Bansal, M., Goyal, A., & Choudhary, A. (2022a). A comparative analysis of K-Nearest Neighbor, Genetic, Support Vector Machine, Decision Tree, and Long Short Term Memory algorithms in machine learning. *Decision Analytics Journal*, 3, 100071. <https://doi.org/10.1016/j.dajour.2022.100071>
- Bansal, M., Goyal, A., & Choudhary, A. (2022b). A comparative analysis of K-Nearest Neighbor, Genetic, Support Vector Machine, Decision Tree, and Long Short Term Memory algorithms in machine learning. *Decision Analytics Journal*, 3, 100071. <https://doi.org/10.1016/j.dajour.2022.100071>
- Basha, S. H. S., Dubey, S. R., Pulabaigari, V., & Mukherjee, S. (2020). Impact of fully connected layers on performance of convolutional neural networks for image classification. *Neurocomputing*, 378, 112–119. <https://doi.org/10.1016/j.neucom.2019.10.008>
- Bayoudh, K., Knani, R., Hamdaoui, F., & Mtibaa, A. (2022a). A survey on deep multimodal learning for computer vision: advances, trends, applications, and datasets. *The Visual Computer*, 38(8), 2939–2970. <https://doi.org/10.1007/s00371-021-02166-7>
- Bayoudh, K., Knani, R., Hamdaoui, F., & Mtibaa, A. (2022b). A survey on deep multimodal learning for computer vision: advances, trends, applications, and datasets. *The Visual Computer*, 38(8), 2939–2970. <https://doi.org/10.1007/s00371-021-02166-7>
- Bayoudh, K., Knani, R., Hamdaoui, F., & Mtibaa, A. (2022c). A survey on deep multimodal learning for computer vision: advances, trends, applications, and datasets. *The Visual Computer*, 38(8), 2939–2970. <https://doi.org/10.1007/s00371-021-02166-7>
- Che, J., Sun, M., Wang, Y., & Xu, Z. (2025). Fusion-driven multimodal learning for biomedical time series in surgical care. *Frontiers in Physiology*, 16. <https://doi.org/10.3389/fphys.2025.1605406>

- Chen, J., Chen, J., Zhang, D., Sun, Y., & Nanekharan, Y. A. (2020). Using deep transfer learning for image-based plant disease identification. *Computers and Electronics in Agriculture*, 173, 105393. <https://doi.org/10.1016/j.compag.2020.105393>
- Dong, X., Garratt, M. A., Anavatti, S. G., & Abbass, H. A. (2022). MobileXNet: An Efficient Convolutional Neural Network for Monocular Depth Estimation. *IEEE Transactions on Intelligent Transportation Systems*, 23(11), 20134–20147. <https://doi.org/10.1109/TITS.2022.3179365>
- Fan, X., Luo, P., Mu, Y., Zhou, R., Tjahjadi, T., & Ren, Y. (2022). Leaf image based plant disease identification using transfer learning and feature fusion. *Computers and Electronics in Agriculture*, 196, 106892. <https://doi.org/10.1016/j.compag.2022.106892>
- Gao, J., Li, P., Chen, Z., & Zhang, J. (2020). A Survey on Deep Learning for Multimodal Data Fusion. *Neural Computation*, 32(5), 829–864. https://doi.org/10.1162/neco_a_01273
- Genuer, R., & Poggi, J.-M. (2020a). *Random Forests* (pp. 33–55). https://doi.org/10.1007/978-3-030-56485-8_3
- Genuer, R., & Poggi, J.-M. (2020b). *Random Forests* (pp. 33–55). https://doi.org/10.1007/978-3-030-56485-8_3
- Genuer, R., & Poggi, J.-M. (2020c). *Random Forests with R*. Springer International Publishing. <https://doi.org/10.1007/978-3-030-56485-8>
- Govindaraj, P. K., Pathinettampadian, K., & Balasubramanian, K. (2025). A deep learning method for enhanced medicinal plant identification using EfficientNet models. 020022. <https://doi.org/10.1063/5.0262019>
- Gupta, M., & Singh, M. (2024). The Impact of Artificial Intelligence for Advancement in Entrepreneurial Education. *European Conference on Innovation and Entrepreneurship*, 19(1), 218–224. <https://doi.org/10.34190/ecie.19.1.2426>
- Hajam, M. A., Arif, T., Khanday, A. M. U. D., Wani, M. A., & Asim, M. (2024). AI-Driven Pattern Recognition in Medicinal Plants: A Comprehensive Review and Comparative Analysis. *Computers, Materials & Continua*, 81(2), 2077–2131. <https://doi.org/10.32604/cmc.2024.057136>
- Hassan, S. M., Maji, A. K., Jasiński, M., Leonowicz, Z., & Jasińska, E. (2021). Identification of Plant-Leaf Diseases Using CNN and Transfer-Learning Approach. *Electronics*, 10(12), 1388. <https://doi.org/10.3390/electronics10121388>
- Holzinger, A., Keiblinger, K., Holub, P., Zatloukal, K., & Müller, H. (2023). AI for life: Trends in artificial intelligence for biotechnology. *New Biotechnology*, 74, 16–24. <https://doi.org/10.1016/j.nbt.2023.02.001>
- Hong, D., Gao, L., Yokoya, N., Yao, J., Chanussot, J., Du, Q., & Zhang, B. (2021). More Diverse Means Better: Multimodal Deep Learning Meets Remote-Sensing Imagery Classification. *IEEE Transactions on Geoscience and Remote Sensing*, 59(5), 4340–4354. <https://doi.org/10.1109/TGRS.2020.3016820>
- Huixian, J. (2020). The Analysis of Plants Image Recognition Based on Deep Learning and Artificial Neural Network. *IEEE Access*, 8, 68828–68841. <https://doi.org/10.1109/ACCESS.2020.2986946>

- Ikrar Musyaffa, M. S., Yudistira, N., Rahman, M. A., Basori, A. H., Firdausiah Mansur, A. B., & Batoro, J. (2024a). IndoHerb: Indonesia medicinal plants recognition using transfer learning and deep learning. *Heliyon*, 10(23), e40606. <https://doi.org/10.1016/j.heliyon.2024.e40606>
- Ikrar Musyaffa, M. S., Yudistira, N., Rahman, M. A., Basori, A. H., Firdausiah Mansur, A. B., & Batoro, J. (2024b). IndoHerb: Indonesia medicinal plants recognition using transfer learning and deep learning. *Heliyon*, 10(23), e40606. <https://doi.org/10.1016/j.heliyon.2024.e40606>
- Ikrar Musyaffa, M. S., Yudistira, N., Rahman, M. A., Basori, A. H., Firdausiah Mansur, A. B., & Batoro, J. (2024c). IndoHerb: Indonesia medicinal plants recognition using transfer learning and deep learning. *Heliyon*, 10(23), e40606. <https://doi.org/10.1016/j.heliyon.2024.e40606>
- Jiao, T., Guo, C., Feng, X., Chen, Y., & Song, J. (2024a). A Comprehensive Survey on Deep Learning Multi-Modal Fusion: Methods, Technologies and Applications. *Computers, Materials & Continua*, 80(1), 1–35. <https://doi.org/10.32604/cmc.2024.053204>
- Jiao, T., Guo, C., Feng, X., Chen, Y., & Song, J. (2024b). A Comprehensive Survey on Deep Learning Multi-Modal Fusion: Methods, Technologies and Applications. *Computers, Materials & Continua*, 80(1), 1–35. <https://doi.org/10.32604/cmc.2024.053204>
- Kline, A., Wang, H., Li, Y., Dennis, S., Hutch, M., Xu, Z., Wang, F., Cheng, F., & Luo, Y. (2022). Multimodal machine learning in precision health: A scoping review. *Npj Digital Medicine*, 5(1), 171. <https://doi.org/10.1038/s41746-022-00712-8>
- Krones, F., Marikkar, U., Parsons, G., Szmul, A., & Mahdi, A. (2025). Review of multimodal machine learning approaches in healthcare. *Information Fusion*, 114, 102690. <https://doi.org/10.1016/j.inffus.2024.102690>
- Kumar, B., Dikshit, O., Gupta, A., & Singh, M. K. (2020). Feature extraction for hyperspectral image classification: a review. *International Journal of Remote Sensing*, 41(16), 6248–6287. <https://doi.org/10.1080/01431161.2020.1736732>
- Kurniawan, B. (2025). Multimodal Deep Learning and IoT Sensor Fusion for Real-Time Beef Freshness Detection. *Journal of Applied Data Sciences*, 6(4), 2921–2937. <https://doi.org/10.47738/jads.v6i4.977>
- Lipkova, J., Chen, R. J., Chen, B., Lu, M. Y., Barbieri, M., Shao, D., Vaidya, A. J., Chen, C., Zhuang, L., Williamson, D. F. K., Shaban, M., Chen, T. Y., & Mahmood, F. (2022). Artificial intelligence for multimodal data integration in oncology. *Cancer Cell*, 40(10), 1095–1110. <https://doi.org/10.1016/j.ccell.2022.09.012>
- Liu, Y., Pu, H., & Sun, D.-W. (2021). Efficient extraction of deep image features using convolutional neural network (CNN) for applications in detecting and analysing complex food matrices. *Trends in Food Science & Technology*, 113, 193–204. <https://doi.org/10.1016/j.tifs.2021.04.042>
- Lu, J., Tan, L., & Jiang, H. (2021). Review on Convolutional Neural Network (CNN) Applied to Plant Leaf Disease Classification. *Agriculture*, 11(8), 707. <https://doi.org/10.3390/agriculture11080707>
- Malik, O. A., Ismail, N., Hussein, B. R., & Yahya, U. (2022a). Automated Real-Time Identification of Medicinal Plants Species in Natural Environment Using Deep Learning Models—A Case Study from Borneo Region. *Plants*, 11(15), 1952. <https://doi.org/10.3390/plants11151952>

- Malik, O. A., Ismail, N., Hussein, B. R., & Yahya, U. (2022b). Automated Real-Time Identification of Medicinal Plants Species in Natural Environment Using Deep Learning Models—A Case Study from Borneo Region. *Plants*, 11(15), 1952. <https://doi.org/10.3390/plants11151952>
- Malik, O. A., Ismail, N., Hussein, B. R., & Yahya, U. (2022c). Automated Real-Time Identification of Medicinal Plants Species in Natural Environment Using Deep Learning Models—A Case Study from Borneo Region. *Plants*, 11(15), 1952. <https://doi.org/10.3390/plants11151952>
- Maseer, Z. K., Yusof, R., Bahaman, N., Mostafa, S. A., & Foozy, C. F. M. (2021). Benchmarking of Machine Learning for Anomaly Based Intrusion Detection Systems in the CICIDS2017 Dataset. *IEEE Access*, 9, 22351–22370. <https://doi.org/10.1109/ACCESS.2021.3056614>
- Mulugeta, A. K., Sharma, D. P., & Mesfin, A. H. (2024a). Deep learning for medicinal plant species classification and recognition: a systematic review. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1286088>
- Mulugeta, A. K., Sharma, D. P., & Mesfin, A. H. (2024b). Deep learning for medicinal plant species classification and recognition: a systematic review. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1286088>
- Mulugeta, A. K., Sharma, D. P., & Mesfin, A. H. (2024c). Deep learning for medicinal plant species classification and recognition: a systematic review. *Frontiers in Plant Science*, 14. <https://doi.org/10.3389/fpls.2023.1286088>
- Muneer, A., & Fati, S. M. (2020). Efficient and Automated Herbs Classification Approach Based on Shape and Texture Features using Deep Learning. *IEEE Access*, 8, 196747–196764. <https://doi.org/10.1109/ACCESS.2020.3034033>
- Naeem, S., Ali, A., Chesneau, C., Tahir, M. H., Jamal, F., Sherwani, R. A. K., & Ul Hassan, M. (2021). The Classification of Medicinal Plant Leaves Based on Multispectral and Texture Feature Using Machine Learning Approach. *Agronomy*, 11(2), 263. <https://doi.org/10.3390/agronomy11020263>
- Nakach, F.-Z., Idri, A., & Goceri, E. (2024). A comprehensive investigation of multimodal deep learning fusion strategies for breast cancer classification. *Artificial Intelligence Review*, 57(12), 327. <https://doi.org/10.1007/s10462-024-10984-z>
- Nguyen, L. D., Gao, R., Lin, D., & Lin, Z. (2023). Biomedical image classification based on a feature concatenation and ensemble of deep CNNs. *Journal of Ambient Intelligence and Humanized Computing*, 14(11), 15455–15467. <https://doi.org/10.1007/s12652-019-01276-4>
- Nhu, V.-H., Shirzadi, A., Shahabi, H., Singh, S. K., Al-Ansari, N., Clague, J. J., Jaafari, A., Chen, W., Miraki, S., Dou, J., Luu, C., Górski, K., Thai Pham, B., Nguyen, H. D., & Ahmad, B. Bin. (2020). Shallow Landslide Susceptibility Mapping: A Comparison between Logistic Model Tree, Logistic Regression, Naïve Bayes Tree, Artificial Neural Network, and Support Vector Machine Algorithms. *International Journal of Environmental Research and Public Health*, 17(8), 2749. <https://doi.org/10.3390/ijerph17082749>
- Pacheco, A. da P., Junior, J. A. da S., Ruiz-Armenteros, A. M., & Henriques, R. F. F. (2021). Assessment of k-Nearest Neighbor and Random Forest Classifiers for Mapping Forest Fire Areas in Central Portugal Using Landsat-8, Sentinel-2, and Terra Imagery. *Remote Sensing*, 13(7), 1345. <https://doi.org/10.3390/rs13071345>


- Patil, R. R., & Kumar, S. (2022). Rice-Fusion: A Multimodality Data Fusion Framework for Rice Disease Diagnosis. *IEEE Access*, 10, 5207–5222. <https://doi.org/10.1109/ACCESS.2022.3140815>
- Pisner, D. A., & Schnyer, D. M. (2020a). Support vector machine. In *Machine Learning* (pp. 101–121). Elsevier. <https://doi.org/10.1016/B978-0-12-815739-8.00006-7>
- Pisner, D. A., & Schnyer, D. M. (2020b). Support vector machine. In *Machine Learning* (pp. 101–121). Elsevier. <https://doi.org/10.1016/B978-0-12-815739-8.00006-7>
- Pisner, D. A., & Schnyer, D. M. (2020c). Support vector machine. In *Machine Learning* (pp. 101–121). Elsevier. <https://doi.org/10.1016/B978-0-12-815739-8.00006-7>
- Pushpanathan, K., Hanafi, M., Mashohor, S., & Fazlil Ilahi, W. F. (2021). Machine learning in medicinal plants recognition: a review. *Artificial Intelligence Review*, 54(1), 305–327. <https://doi.org/10.1007/s10462-020-09847-0>
- Putra, R. P. S., Aditya, C. S. K., & Wicaksono, G. W. (2024a). HERBAL LEAF CLASSIFICATION USING DEEP LEARNING MODEL EFFICIENTNETV2B0. *JITK (Jurnal Ilmu Pengetahuan Dan Teknologi Komputer)*, 9(2), 301–307. <https://doi.org/10.33480/jitk.v9i2.5119>
- Putra, R. P. S., Aditya, C. S. K., & Wicaksono, G. W. (2024b). HERBAL LEAF CLASSIFICATION USING DEEP LEARNING MODEL EFFICIENTNETV2B0. *JITK (Jurnal Ilmu Pengetahuan Dan Teknologi Komputer)*, 9(2), 301–307. <https://doi.org/10.33480/jitk.v9i2.5119>
- Putri, Y. A., Djamal, E. C., & Ilyas, R. (2021). Identification of Medicinal Plant Leaves Using Convolutional Neural Network. *Journal of Physics: Conference Series*, 1845(1), 012026. <https://doi.org/10.1088/1742-6596/1845/1/012026>
- Puttinaovarat, S., & Horkaew, P. (2021a). A geospatial database management system for the collection of medicinal plants. *Geospatial Health*, 16(2). <https://doi.org/10.4081/gh.2021.998>
- Puttinaovarat, S., & Horkaew, P. (2021b). A geospatial database management system for the collection of medicinal plants. *Geospatial Health*, 16(2). <https://doi.org/10.4081/gh.2021.998>
- Rahayu, Y. Y. S., Araki, T., & Rosleine, D. (2020). Factors affecting the use of herbal medicines in the universal health coverage system in Indonesia. *Journal of Ethnopharmacology*, 260, 112974. <https://doi.org/10.1016/j.jep.2020.112974>
- Rybczak, M., & Kozakiewicz, K. (2024a). Deep Machine Learning of MobileNet, Efficient, and Inception Models. *Algorithms*, 17(3), 96. <https://doi.org/10.3390/a17030096>
- Rybczak, M., & Kozakiewicz, K. (2024b). Deep Machine Learning of MobileNet, Efficient, and Inception Models. *Algorithms*, 17(3), 96. <https://doi.org/10.3390/a17030096>
- Saleem, M. H., Potgieter, J., & Arif, K. M. (2020). Plant Disease Classification: A Comparative Evaluation of Convolutional Neural Networks and Deep Learning Optimizers. *Plants*, 9(10), 1319. <https://doi.org/10.3390/plants9101319>
- Saleem, M. H., Potgieter, J., & Arif, K. M. (2021). Automation in Agriculture by Machine and Deep Learning Techniques: A Review of Recent Developments. *Precision Agriculture*, 22(6), 2053–2091. <https://doi.org/10.1007/s11119-021-09806-x>
- Salman, H. A., Kalakech, A., & Steiti, A. (2024). Random Forest Algorithm Overview. *Babylonian Journal of Machine Learning*, 2024, 69–79. <https://doi.org/10.58496/BJML/2024/007>

- Shafiq, M., & Gu, Z. (2022a). Deep Residual Learning for Image Recognition: A Survey. *Applied Sciences*, 12(18), 8972. <https://doi.org/10.3390/app12188972>
- Shafiq, M., & Gu, Z. (2022b). Deep Residual Learning for Image Recognition: A Survey. *Applied Sciences*, 12(18), 8972. <https://doi.org/10.3390/app12188972>
- Sheykhoum, M., Mahdianpari, M., Ghanbari, H., Mohammadimanesh, F., Ghamisi, P., & Homayouni, S. (2020). Support Vector Machine Versus Random Forest for Remote Sensing Image Classification: A Meta-Analysis and Systematic Review. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 13, 6308–6325. <https://doi.org/10.1109/JSTARS.2020.3026724>
- Shmilovici, A. (2023). Support Vector Machines. In *Machine Learning for Data Science Handbook* (pp. 93–110). Springer International Publishing. https://doi.org/10.1007/978-3-031-24628-9_6
- Singh, P., Yadav, S., Bidargaddi, A. P., H, V. S., & Boratti, A. (2024). Indonesia Medicinal Plant Recognition using Deep Learning: A Computational Study. *2024 International Conference on Advances in Modern Age Technologies for Health and Engineering Science (AMATHE)*, 1–7. <https://doi.org/10.1109/AMATHE61652.2024.10582068>
- Sonita, A., Anggriani, K., Vatesia, A., Putri, T. E., Darnita, Y., Zahra, S. A., Aprilia, V., & Aziz, D. A. (2025). Herbal Plant Classification Using EfficientNetV2B0 Model and CRISP-DM Approach. *Jurnal Teknik Informatika (Jutif)*, 6(4), 2253–2262. <https://doi.org/10.52436/1.jutif.2025.6.4.5141>
- Stahlschmidt, S. R., Ulfenborg, B., & Synnergren, J. (2022a). Multimodal deep learning for biomedical data fusion: a review. *Briefings in Bioinformatics*, 23(2). <https://doi.org/10.1093/bib/bbab569>
- Stahlschmidt, S. R., Ulfenborg, B., & Synnergren, J. (2022b). Multimodal deep learning for biomedical data fusion: a review. *Briefings in Bioinformatics*, 23(2). <https://doi.org/10.1093/bib/bbab569>
- Sun, Y., Xue, B., Zhang, M., Yen, G. G., & Lv, J. (2020). Automatically Designing CNN Architectures Using the Genetic Algorithm for Image Classification. *IEEE Transactions on Cybernetics*, 50(9), 3840–3854. <https://doi.org/10.1109/TCYB.2020.2983860>
- Tugrul, B., Elfatimi, E., & Eryigit, R. (2022). Convolutional Neural Networks in Detection of Plant Leaf Diseases: A Review. *Agriculture*, 12(8), 1192. <https://doi.org/10.3390/agriculture12081192>
- Utami, T. W., Novita, M., & Latifa, K. (2025). Implementation and Comparative Analysis of CNN and Transfer Learning Models (EfficientNetB0, MobileNetV2, and ResNet50) for Rice Leaf Disease Detection Based on Digital Images. *Journal of Applied Informatics and Computing*, 9(6), 3862–3870. <https://doi.org/10.30871/jaic.v9i6.11616>
- Vieira, S., Pinaya, W. H. L., Garcia-Dias, R., & Mechelli, A. (2020a). Multimodal integration. In *Machine Learning* (pp. 283–305). Elsevier. <https://doi.org/10.1016/B978-0-12-815739-8.00016-X>
- Vieira, S., Pinaya, W. H. L., Garcia-Dias, R., & Mechelli, A. (2020b). Multimodal integration. In *Machine Learning* (pp. 283–305). Elsevier. <https://doi.org/10.1016/B978-0-12-815739-8.00016-X>


- Wang, D., Cao, W., Zhang, F., Li, Z., Xu, S., & Wu, X. (2022). A Review of Deep Learning in Multiscale Agricultural Sensing. *Remote Sensing*, 14(3), 559. <https://doi.org/10.3390/rs14030559>
- Wang, J., Li, J., Shi, Y., Lai, J., & Tan, X. (2022a). AM³Net: Adaptive Mutual-Learning-Based Multimodal Data Fusion Network. *IEEE Transactions on Circuits and Systems for Video Technology*, 32(8), 5411–5426. <https://doi.org/10.1109/TCSVT.2022.3148257>
- Wang, J., Li, J., Shi, Y., Lai, J., & Tan, X. (2022b). AM³Net: Adaptive Mutual-Learning-Based Multimodal Data Fusion Network. *IEEE Transactions on Circuits and Systems for Video Technology*, 32(8), 5411–5426. <https://doi.org/10.1109/TCSVT.2022.3148257>
- Wang, J., Sun, K., Cheng, T., Jiang, B., Deng, C., Zhao, Y., Liu, D., Mu, Y., Tan, M., Wang, X., Liu, W., & Xiao, B. (2021). Deep High-Resolution Representation Learning for Visual Recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 43(10), 3349–3364. <https://doi.org/10.1109/TPAMI.2020.2983686>
- Xu, P., Zhu, X., & Clifton, D. A. (2023a). Multimodal Learning With Transformers: A Survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10), 12113–12132. <https://doi.org/10.1109/TPAMI.2023.3275156>
- Xu, P., Zhu, X., & Clifton, D. A. (2023b). Multimodal Learning With Transformers: A Survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10), 12113–12132. <https://doi.org/10.1109/TPAMI.2023.3275156>
- Yin, S., Xi, Y., Zhang, X., Sun, C., & Mao, Q. (2025). Foundation Models in Agriculture: A Comprehensive Review. *Agriculture*, 15(8), 847. <https://doi.org/10.3390/agriculture15080847>
- Yousfi, Y., Butora, J., Khvedchenya, E., & Fridrich, J. (2020). ImageNet Pre-trained CNNs for JPEG Steganalysis. *2020 IEEE International Workshop on Information Forensics and Security (WIFS)*, 1–6. <https://doi.org/10.1109/WIFS49906.2020.9360897>
- Zhang, C., Yang, Z., He, X., & Deng, L. (2020a). Multimodal Intelligence: Representation Learning, Information Fusion, and Applications. *IEEE Journal of Selected Topics in Signal Processing*, 14(3), 478–493. <https://doi.org/10.1109/JSTSP.2020.2987728>
- Zhang, C., Yang, Z., He, X., & Deng, L. (2020b). Multimodal Intelligence: Representation Learning, Information Fusion, and Applications. *IEEE Journal of Selected Topics in Signal Processing*, 14(3), 478–493. <https://doi.org/10.1109/JSTSP.2020.2987728>
- Zhao, F., Zhang, C., & Geng, B. (2024a). Deep Multimodal Data Fusion. *ACM Computing Surveys*, 56(9), 1–36. <https://doi.org/10.1145/3649447>
- Zhao, F., Zhang, C., & Geng, B. (2024b). Deep Multimodal Data Fusion. *ACM Computing Surveys*, 56(9), 1–36. <https://doi.org/10.1145/3649447>
- Zheng, Q., Zhu, J., Li, Z., Pang, S., Wang, J., & Li, Y. (2020). Feature concatenation multi-view subspace clustering. *Neurocomputing*, 379, 89–102. <https://doi.org/10.1016/j.neucom.2019.10.074>

LAMPIRAN:


CONFUSION MATRIX UNTUK MODEL VGG16




Gambar 8 Model VGG16 + Decision Tree




Gambar 9. Model VGG16 + Gradient Boosting




Gambar 10. Model VGG16 + KNN



Gambar 11. Model VGG16 + Random Forest



Gambar 12. Model VGG16 + SVM Linear



Gambar 13. Model VGG16 + SVM RBF

**SURAT TUGAS**Nomor : **006/DPPMP/UNISBANK/ST-PN/VI/2026**

Yang bertanda tangan dibawah ini. Direktur DPPMP Universitas Stikubank (UNISBANK)

Semarang menugaskan kepada :

- 1 Nama : Rr. DEWI HANDAYANI UNTARI NINGSIH RASJID SAPUTRA,
S.Kom., M.Kom. sebagai Ketua Tim Penelitian
NIDN : 616036902
Pangkat/Golongan : Pembina/IV-a
Jabatan Akademik : Lektor Kepala
- 2 Nama : Dr. Drs. ERI ZULIARSO, M.Kom. sebagai anggota 1
NIDN : 623116801
Pangkat/Golongan : Penata Tingkat I/III-d
Jabatan Akademik : Lektor
- 3 Nama : FELIX ANDREAS SUTANTO, S.Kom., M.Cs. sebagai anggota 2
NIDN : 625047801
Pangkat/Golongan : Penata/III-c
Jabatan Akademik : Lektor
- 4 Nama : AGUS PRASETYO UTOMO, S.Kom., M.M. sebagai anggota 3
NIDN : 614087201
Pangkat/Golongan : Penata/III-c
Jabatan Akademik : Lektor
- 5 Nama : HARI MURTI, S.Kom., M.Cs. sebagai anggota 4
NIDN : 611066501
Pangkat/Golongan : Penata Tingkat I/III-d
Jabatan Akademik : Lektor
- 6 Nama Mahasiswa 1 : REZA TANJUNG SETIAWAN, 24.01.55.3001, sebagai anggota 5
- 7 Nama Mahasiswa 2 : SEKAR AYU NINGTYAS, 25.01.55.7007, sebagai anggota 6

Unit Organisasi : Universitas Stikubank (UNISBANK) Semarang
Judul Penelitian : **ANALISIS PERBANDINGAN MODEL MACHINE LEARNING DAN
DEEP LEARNING UNTUK KLASIFIKASI TANAMAN OBAT
BERBASIS DATA CITRA DAN MULTIMODAL**

Jangka Waktu : 20 April s/d 30 November 2026

Demikian harap dilaksanakan dan setelah selesai diharap memberi laporan.

Semarang, 3 Juni 2026

Direktur DPPMP



UNIVERSITAS
STIKUBANK
DIGITAL YOUTH ENTREPRENEURSHIP UNIVERSITY

DIREKTORAT PENELITIAN, PENGABDIAN

Prof., Dr. Endang Tjahjaningsih, S.E., M.Kom.

NIDN: 0622056601

Tembusan kepada Yth.

1. Wakil Rektor I,II UNISBANK
2. Para Dekan
3. Kabag PSDM, DPPMP



SURAT PERJANJIAN
PELAKSANAAN KEGIATAN PENELITIAN DOSEN UNIVERSITAS STIKUBANK
TAHUN ANGGARAN 2026

No : 006/DPPMP/UNISBANK/KONTRAK-PN/VI/2026

Pada hari ini, Tanggal **Empat**, bulan **Juni** tahun **Dua Ribu Dua Puluh Enam**, kami yang bertanda tangan di bawah ini :

- 1 Prof., Dr. ENDANG
 TJAHJANINGSIH , S.E.,
 M.Kom. : Direktur DPPMP Universitas Stikubank berdasar Surat Keputusan No. 069/J.01/UNISBANK/SK/X/2025 bertindak untuk dan atas nama DPPMP Universitas Stikubank selanjutnya disebut PIHAK PERTAMA.
- 2 Rr. DEWI HANDAYANI UNTARI
 NINGSIH RASJID SAPUTRA,
 S.Kom., M.Kom., : Dosen Fakultas TEKNOLOGI INFORMASI DAN INDUSTRI bertindak untuk dan atas nama Tim Peneliti selaku Ketua Tim Peneliti yang selanjutnya disebut PIHAK KEDUA

Kedua belah pihak sepakat mengadakan perjanjian pelaksanaan kegiatan Penelitian sesuai ketentuan/syarat sebagai berikut :

Pasal 1

1. PIHAK PERTAMA memberikan tugas kepada PIHAK KEDUA dan PIHAK KEDUA menerima tugas untuk melaksanakan kegiatan penelitian :
 Judul : **ANALISIS PERBANDINGAN MODEL MACHINE LEARNING DAN DEEP LEARNING UNTUK KLASIFIKASI TANAMAN OBAT BERBASIS DATA CITRA DAN MULTIMODAL**
 Ketua Tim Peneliti : Rr. DEWI HANDAYANI UNTARI NINGSIH RASJID SAPUTRA, S.Kom., M.Kom..

 Anggota Tim Peneliti :
 a. Dr. Drs. ERI ZULIARSO, M.Kom.
 b. FELIX ANDREAS SUTANTO, S.Kom., M.Cs.
 c. AGUS PRASETYO UTOMO, S.Kom., M.M.
 d. HARI MURTI, S.Kom., M.Cs.
 e. REZA TANJUNG SETIAWAN
 f. SEKAR AYU NINGTYAS
2. Ketua Tim Peneliti wajib mengkoordinasikan dan bertanggungjawab terhadap substansi dan administrasi pelaksanaan kegiatan penelitian sebagaimana yang tercantum dalam surat perjanjian ini.

Pasal 2

PIHAK PERTAMA memberikan dana pelaksanaan kegiatan penelitian sebesar **Rp. 5.000.000 (Lima Juta Rupiah)** kepada PIHAK KEDUA dan dibayarkan dalam 2 (dua) tahap, yaitu :

1. Tahap pertama sebesar 50 % dari dana keseluruhan, yaitu sebesar Rp. 2.500.000 (**Dua Juta Lima Ratus Ribu Rupiah**) diberikan setelah proposal penelitian dinyatakan lolos dan Surat Perjanjian telah ditandatangani oleh kedua belah pihak.
2. Tahap kedua sebesar 50 % dari dana keseluruhan, yaitu sebesar Rp. 2.500.000 (**Dua Juta Lima Ratus Ribu Rupiah**) diberikan setelah Laporan Penelitian, draft artikel publikasi dan bukti submit diselesaikan oleh PIHAK KEDUA.
3. Pembayaran tahap kedua dilakukan setelah PIHAK PERTAMA selesai memeriksa kelengkapan unggahan sebagaimana disebut dalam pasal 3 di bawah ini.

Pasal 3

1. PIHAK KEDUA wajib menyelesaikan :
 - a. Laporanj Kemajuan
 - b. Catatan Harian (Logbook)
 - c. Laporan Penelitian
 - d. Draft artikel publikasi
 - e. Bukti submit artikel publikasi
 - f. Mengunggah di SIRISBANK paling lambat tanggal **13 Nopember 2026**.
2. Format, sistematika dan ketentuan lain terkait dengan Laporan Penelitian dan kelengkapan lainnya harus sesuai dengan ketentuan atau pedoman yang dibuat oleh PIHAK PERTAMA, sementara format artikel publikasi disesuaikan dengan jurnal yang dituju.
3. PIHAK PERTAMA wajib menyelesaikan pemeriksaan kelengkapan unggahan dan melaporkan pada Rektor paling lambat tanggal **27 Nopember 2026**.

Pasal 4

1. PIHAK KEDUA yang tidak memenuhi pasal 3 ayat 1 dan 2 :
 - a. 50 % pembayaran tahap kedua tidak dapat dicairkan
 - b. Ketua Tim Peneliti tidak bisa mengajukan proposal penelitian yang didanai oleh Universitas pada tahun berikutnya.
 - c. PIHAK KEDUA tetap wajib mengunggah Laporan Penelitian, draft artikel publikasi, dan bukti submit selambat lambatnya **7 Desember 2026**.
2. PIHAK KEDUA yang tidak mengunggah kelengkapan pasal 3 ayat 1 dan 2 selambat lambatnya ... Desember 2026, dikenakan sanksi berupa seluruh anggota Tim Peneliti tidak dapat mengajukan proposal penelitian yang didanai oleh universitas pada tahun berikutnya.
3. PIHAK KEDUA tetap dapat mengajukan insentif untuk luaran publikasi, apabila mengunggah kelengkapan pasal 3 ayat 1 dan 2 selambat lambatnya **11 Desember 2026**.
4. Luaran penelitian (artikel publikasi) minimal Jurnal Nasional Terakreditasi SINTA 4 atau Prosiding Internasional Teridkes Scopus harus sudah terbit dan harus diserahkan paling lambat **31 Nopember 2026**. Luaran Publikasi Jurnal Internasional Terideks Scopus Harus sudah terbit dan diserahkan paling lambat **26 Nopember 2027**. Jika PIHAK KEDUA tidak bisa maka Ketua Tim Peneliti tidak bisa mengajukan proposal penelitian dan luaran publikasi yang didanai oleh Universitas pada tahun berikutnya.
5. PIHAK PERTAMA wajib menyelesaikan pemeriksaan kelengkapan unggahan dan melaporkan pada Rektor paling lambat tanggal **8 Desember 2026**.

Pasal 5

1. Artikel publikasi yang terbit selambat lambatnya **31 Desember 2026** akan mendapat insentif sesuai dengan Surat Edaran Nomor : **085/J.01/UNISBANK/SK/XII/2023** tentang Ketentuan Pemberian Insentif Publikasi Ilmiah, Dan Hak Kekayaan Intelektual di Lingkungan Universitas Stikubank (Unisbank) Semarang.
2. Pembayaran insentif artikel publikasi akan dilakukan setelah PIHAK PERTAMA memeriksa dan menyatakan bahwa PIHAK KEDUA telah mengunggah luaran tersebut dalam SIRISBANK.

Pasal 6

1. Dalam hal Ketua Tim Peneliti sebagaimana pada Pasal 1 tidak dapat menyelesaikan pelaksanaan penelitian sepenuhnya, karena sesuatu hal maka anggota Tim Peneliti dengan nomor urut 1 menggantikannya sebagai Ketua Tim Peneliti.
2. Dalam hal Ketua atau Anggota Tim Peneliti sebagaimana pada Pasal 1 tidak dapat menyelesaikan pelaksanaan penelitian sepenuhnya, maka Ketua atau anggota Tim Peneliti dapat mengajukan permohonan penggantian ketua maupun anggota kepada PIHAK PERTAMA.
3. Hal hal terkait perubahan formasi Tim Peneliti wajib dilaporkan kepada PIHAK PERTAMA.

Pasal 7

1. Kekayaan Intelektual yang dihasilkan dari pelaksanaan penelitian ini adalah milik Universitas Stikubank.
2. Setiap publikasi dan ekspos dalam bentuk apapun yang berkaitan dengan hasil penelitian ini wajib mencantumkan nama Universitas Stikubank.

Pasal 8

Surat Perjanjian Pelaksanaan Penelitian dibuat rangkap 2 (dua) bermaterai sesuai ketentuan yang berlaku dan biaya materai dibebankan kepada PIHAK KEDUA.

PIHAK PERTAMA
Direktur DPPMP

4



Prof., Dr. ENDANG TJAHJANINGSIH, S.E., M.Kom.
NIDN: 0622056601

Semarang, 03 Juni 2026

PIHAK KEDUA
Ketua Tim Peneliti



Rr. DEWI HANDAYANI UNTARI NINGSIH RASJID SAPUTRA, S.Kom., M.Kom.,
NIDN. 616036902